UNIVERSIDADE FEDERAL DE LAVRAS

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

Dissertação (Mestrado em Ciência da Computação)

LAVRAS – MG

2026

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

Dissertação (Mestrado em Ciência da Computação)

Dissertação apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2026

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

OPTIMIZATION OF SQUAD BUILDING IN FOOTBALL: MACHINE LEARNING FOR REDUCING UNCERTAINTY IN PLAYER RECRUITMENT

Dissertação apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

APROVADA em 23 de março de 2026.
Prof. Dr. Mayron César de Oliveira Moreira UFLA
Prof. Dr. Cristiano Arbex Valle UFMG

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2026

Aos meus pais, pelo apoio incondicional e por tornar cada jornada minha possível.

AGRADECIMENTOS

Agradeço, em primeiro lugar, ao meu orientador, Prof. Dr. Dilson Lucas Pereira, pela excelente orientação, pela paciência ao longo de todo o processo e pela confiança depositada no desenvolvimento deste trabalho.

Ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Lavras (UFLA), bem como à própria UFLA, que desde a graduação até o mestrado me proporcionou a estrutura acadêmica necessária para minha formação.

À Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES), pelo apoio e fomento que contribuíram para a realização deste trabalho.

Aos meus pais, Mario e Gilda, por toda a base, incentivo e apoio incondicional ao longo da minha trajetória.

À minha namorada, Ana Paula, pelo apoio constante e pela compreensão durante toda a jornada do mestrado.

Ao meu primo Júlio, por acreditar com entusiasmo no meu projeto e sempre me incentivar a seguir em frente.

À professora Evelise, minha orientadora na graduação, que teve papel fundamental no início da minha jornada na programação e na formação que tornou possível chegar até aqui.

Aos professores Luiz Merschmann, Paulo Afonso e Mayron, cujos ensinamentos e contribuições foram fundamentais ao longo do mestrado.

À Josiane, pela dedicação e apoio na resolução de questões burocráticas relacionadas à defesa.

Por fim, agradeço aos colegas Danilo e João, pela companhia durante as aulas da pós-graduação.

"Quanto maior o artista, maior a dúvida; uma confiança perfeita é concedida aos menos talentosos como prêmio de consolação."

(Robert Hughes)

RESUMO

O futebol, o esporte mais popular do mundo, é marcado por sua alta imprevisibilidade, o que dificulta a montagem de elencos, as escolhas táticas e a seleção de jogadores para cada partida. Este estudo explora o uso de técnicas de Aprendizado de Máquina (AM) e Pesquisa Operacional (PO) como ferramentas de apoio à tomada de decisão no contexto esportivo. O objetivo é desenvolver um modelo preditivo capaz de estimar o desempenho dos clubes com base em dados estatísticos individuais dos jogadores. A partir dessas previsões, são aplicados algoritmos de otimização para orientar estratégias de contratações, permitindo decisões mais eficientes e fundamentadas em dados. Essa abordagem visa reduzir a subjetividade nos processos de gestão esportiva, promovendo maior assertividade nas decisões de mercado por parte dos clubes.

Palavras-chave: futebol; aprendizado de máquina; pesquisa operacional; otimização; análise de esportes; montagem de elenco.

ABSTRACT

Football, the most popular sport in the world, is marked by a high degree of unpredictability, which makes squad building, tactical planning, and player selection particularly challenging. This study explores the use of Machine Learning (ML) and Operations Research (OR) techniques as decision-support tools in the sports context. The objective is to develop a predictive model capable of estimating club performance based on individual player statistics. These predictions are then used as inputs for optimization algorithms aimed at guiding player recruitment strategies, enabling more efficient and data-driven decisions. This approach seeks to reduce subjectivity in sports management processes, promoting greater accuracy in market decisions and contributing to a more strategic, evidence-based decision-making framework within football clubs.

Keywords: football; machine learning; operations research; optimization; sports analytics; squad building.

INDICADORES DE IMPACTO

O presente trabalho apresenta impactos predominantemente tecnológicos e econômicos, com desdobramentos sociais em potencial, ao propor uma abordagem baseada em aprendizado de máquina e otimização para apoio à tomada de decisão na montagem de elencos no futebol. A metodologia desenvolvida integra técnicas de redução de dimensionalidade, redes neurais artificiais e heurísticas de busca local em um pipeline capaz de simular cenários de contratação sob restrições orçamentárias, contribuindo para a redução da imprevisibilidade associada a decisões tradicionalmente baseadas em critérios subjetivos. Do ponto de vista tecnológico, o estudo fortalece a aplicação da ciência de dados no contexto esportivo, oferecendo uma ferramenta replicável por clubes, analistas de desempenho e departamentos de scouting. Sob a perspectiva econômica, os resultados indicam potencial para otimizar a alocação de recursos financeiros, mitigando riscos em contratações e promovendo maior eficiência na gestão de elencos, especialmente em organizações com limitações orçamentárias. Os impactos sociais são considerados indiretos, uma vez que a melhoria na gestão esportiva pode influenciar positivamente a competitividade das equipes, a valorização de atletas e o engajamento de torcedores, além de contribuir para a formação de profissionais qualificados na interface entre tecnologia e esporte. O trabalho não apresenta caráter extensionista direto, mas possui potencial de aplicação prática em instituições esportivas e empresas do setor, com abrangência nacional e internacional. Em termos de classificação temática, enquadra-se principalmente na área de Tecnologia e Produção, com interfaces nas áreas de Educação e Trabalho. Ademais, a pesquisa apresenta alinhamento com os Objetivos de Desenvolvimento Sustentável da Organização das Nações Unidas, especialmente o ODS 8 (Trabalho Decente e Crescimento Econômico) e o ODS 9 (Indústria, Inovação e Infraestrutura), ao promover inovação tecnológica e maior eficiência econômica no contexto esportivo.

INDICADORES DE IMPACTO

This work presents predominantly technological and economic impacts, with potential social implications, by proposing an approach based on machine learning and optimization to support decision-making in football squad building. The developed methodology integrates dimensionality reduction techniques, artificial neural networks, and local search heuristics into a unified pipeline capable of simulating transfer scenarios under budget constraints, contributing to reducing the uncertainty traditionally associated with subjective decision-making processes. From a technological perspective, the study advances the application of data science in the sports domain, providing a framework that can be adopted by clubs, performance analysts, and scouting departments. From an economic standpoint, the results indicate potential to optimize financial resource allocation, mitigating risks in player recruitment and promoting more efficient squad management, particularly in organizations with limited budgets. The social impacts are considered indirect, as improvements in sports management may positively influence team competitiveness, player valuation, and fan engagement, in addition to contributing to the training of professionals at the intersection of technology and sports. Although the work does not present a direct extension component, it has practical application potential in sports institutions and industry-related organizations, with both national and international scope. In terms of thematic classification, it is primarily aligned with the area of Technology and Production, with secondary connections to Education and Work. Furthermore, the research aligns with the United Nations Sustainable Development Goals, particularly SDG 8 (Decent Work and Economic Growth) and SDG 9 (Industry, Innovation and Infrastructure), by fostering technological innovation and improving economic efficiency in the sports context.

LISTA DE FIGURAS

Figura 3.1 – Pipeline CRISP-DM 21
Figura 3.2 – AD para Iris 26

LISTA DE TABELAS

SUMÁRIO

1 INTRODUÇÃO 15
2 OBJETIVOS 18
2.1 Objetivo Geral 18
2.2 Objetivos Específicos 18
3 REFERENCIAL TEÓRICO 20
3.1 Aprendizado de Máquina (AM) 20
3.1.1 Generalização, Viés e Variância 22
3.1.2 Seleção de Atributos e Redução de Dimensionalidade 22
3.1.3 Regressão Linear (RL) 24
3.1.4 Árvore de Decisão (AD) 25
3.1.5 Random Forest (RF) 26
3.1.6 Gradient Boosting (XGBoost) 27
3.1.7 Multilayer Perceptron (MLP) 28
3.2 Pesquisa Operacional (PO) 30
3.2.1 Problema da Mochila 30
3.2.2 Algoritmo Guloso 32
3.2.3 Algoritmo de Busca Local 34
4 REVISÃO DE LITERATURA 37
4.1 Aprendizado de Máquina (AM) no contexto esportivo 37
4.1.1 Previsão de resultados de partidas 38
4.1.2 Aplicações recentes do Aprendizado de Máquina (AM) no futebol 39
4.1.3 Desempenho agregado e determinantes de temporada 40
4.2 Pesquisa Operacional (PO) no contexto esportivo 42
4.2.1 Otimização Prescritiva e Problemas Combinatórios no Esporte 43
REFERÊNCIAS 46
ANEXOS 51
APÊNDICES 53

1 INTRODUÇÃO

Futebol é o esporte mais popular do mundo (Almulla *et al.*, 2023). Nas últimas décadas, sua evolução tecnológica e analítica tem sido notável, acompanhada por um crescimento expressivo nos lucros gerados pelas atividades esportivas (Rodrigues; Pinto, 2023). No entanto, o futebol é um esporte altamente imprevisível. Um exemplo notável dessa imprevisibilidade foi a surpreendente conquista da English Premier League (EPL) pelo Leicester City em 2016, um feito que surpreendeu especialistas e torcedores em todo o mundo (Baboota; Kaur, 2019).

Dada a relevância econômica e o impacto do futebol como forma de entretenimento, pesquisadores da academia e profissionais da indústria têm se dedicado ao desafio de prever seus resultados (Baboota; Kaur, 2019). O crescimento do mercado de apostas reflete essa busca, impulsionando também os lucros da indústria de prognósticos esportivos (Rodrigues; Pinto, 2023). Para se ter uma noção da magnitude econômica do futebol, entre 1º de junho e 1º de setembro de 2023, as transferências de jogadores movimentaram R$ 36,6 bilhões, conforme relatório divulgado pela Federação Internacional de Futebol (FIFA) (GLOBO Esporte, 2023). No Brasil, em 2025, a janela de transferências da Série A brasileira bateu a marca de R$ 1 bilhão em movimentações financeiras (GLOBO Esporte, 2025).

No campo da Ciência da Computação, diversos estudos têm explorado técnicas de análise de dados e estatística com o objetivo de modelar padrões e realizar predições em ambientes complexos. Um exemplo relevante é o estudo de Joseph, Fenton e Neil (2006), que investigou o uso de redes Bayesianas e outras técnicas de Aprendizado de Máquinas (AM) para prever resultados do Tottenham Hotspur entre 1995 e 1997. Outro caso notável de aplicação de dados no futebol envolve o Brighton & Hove Albion, clube inglês que, sob a gestão de Tony Bloom, implementou uma estratégia fortemente orientada por análises estatísticas para recrutamento e tomada de decisões. Essa filosofia refletiu-se diretamente na política de transferências do clube, com a identificação sistemática de atletas subvalorizados no mercado. Entre os exemplos mais emblemáticos está Moisés Caicedo, contratado junto ao Independiente Del Valle em 2021 por cerca de £4,5 milhões e negociado com o Chelsea em 2023 por valores próximos a 115 milhões €, tornando-se uma das maiores vendas da história da EPL (BBC Sport, 2023; CNN Brasil, 2023). O mesmo caso de altos lucros em revendas se aplica a outros jogadores, como Alexis Mac Allister e Marc Cucurella, abordagem que permitiu que o Brighton se consolidasse como um dos clubes mais eficientes do mercado de transferências da EPL, reinvestindo

os recursos obtidos e mantendo a competitividade sustentável na elite do futebol inglês (Olley, 2023).

Na literatura acadêmica, observa-se que a maioria dos trabalhos envolvendo AM no futebol concentra-se na previsão de resultados de partidas, probabilidades de vitória ou otimização de ganhos no contexto de apostas esportivas. Em contraste, menos estudos direcionam esforços à construção e otimização de elencos com foco na avaliação e seleção de jogadores (Abidin, 2021). Essa lacuna é particularmente relevante, uma vez que a escolha de um atleta para compor um elenco envolve a análise simultânea de múltiplos parâmetros técnicos, físicos e mentais, além de fatores contextuais como estilo de jogo da equipe, liga disputada e momento da carreira do jogador (Abidin, 2021). A natureza não determinística inerente ao futebol torna esse processo ainda mais desafiador, pois mesmo contratações que aparentam ser ideais sob múltiplos critérios podem não atingir o desempenho esperado.

Segundo Ian Graham (2024), uma transferência pode ser considerada um sucesso se o jogador iniciar 50% das partidas nas primeiras duas temporadas ("The 50% rule"). Considerando todas as transferências de mais de € 10 milhões que ocorreram na EPL entre os anos de 1992 e 2021, perto da metade (46%) não atingiram o critério estabelecido e, portanto, podem ser classificadas como falhas (Graham, 2024). Entre os principais fatores associados a esses insucessos, destacam-se:

1. O jogador atual é melhor que o novo jogador;
2. O jogador não é tão bom quanto se pensava inicialmente;
3. O jogador não se encaixa no estilo do time;
4. O jogador joga fora de posição;
5. O técnico não aprova o jogador;
6. O jogador tem problemas de condicionamento físico ou pessoais.

Nos últimos anos, o AM tem ampliado significativamente a capacidade de análise de dados esportivos, permitindo a identificação de padrões antes imperceptíveis em grandes volumes de informação. Técnicas avançadas vêm sendo aplicadas para estimar desde a probabilidade de vitória em uma partida até o impacto de decisões táticas ao longo de uma temporada. Entretanto, tais modelos não eliminam a incerteza inerente ao futebol, atuando como ferramentas

de apoio à tomada de decisão humana, com o objetivo de reduzir riscos e embasar escolhas estratégicas.

Neste contexto, o presente trabalho investiga o uso de modelos preditivos para converter estatísticas históricas de desempenho individual em estimativas de desempenho esperado de jogadores quando inseridos em contextos específicos de equipe e temporada. Diferentemente de abordagens voltadas à previsão direta de resultados de partidas ou à avaliação de talento de forma isolada, a proposta concentra-se na análise contextualizada do jogador como parte de um sistema coletivo. As previsões geradas são utilizadas como subsídio em um processo de simulação e avaliação de cenários de contratação, visando apoiar decisões de mercado no futebol profissional de forma orientada por dados e alinhada a critérios de eficiência esportiva e financeira.

2 OBJETIVOS

2.1 Objetivo Geral

O presente estudo tem como objetivo principal desenvolver e validar um modelo de AM capaz de prever o desempenho de equipes de futebol a partir de dados estatísticos de desempenho individual de jogadores. Neste trabalho, entende-se por desempenho a pontuação esperada de uma equipe ao longo de uma temporada de uma competição esportiva.

Entretanto, o objetivo central não se limita ao desenvolvimento do modelo preditivo em si. Pretende-se que tal modelo seja utilizado como componente de algoritmos de otimização voltados ao apoio à tomada de decisão na montagem de elencos. Em particular, seja f o modelo de AM obtido e seja X um arranjo contendo as *features* correspondentes ao elenco de um determinado time. Embora o modelo possa ser utilizado para prever o desempenho de equipes existentes, uma vez treinado ele também pode ser empregado para estimar o desempenho de equipes hipotéticas.

Dessa forma, considere P o conjunto de todos os elencos X' que podem ser obtidos a partir do elenco atual X por meio da contratação de novos jogadores, respeitando um determinado orçamento disponível. O objetivo passa então a ser identificar, dentre todas as combinações possíveis de jogadores em P, aquela que maximiza o desempenho previsto pelo modelo de AM. Formalmente, busca-se resolver o problema

Formalmente, busca-se resolver o problema definido pela Equação 2.1:

$$\max_{X' \in P} f(X') \tag{2.1}$$

Observa-se, portanto, que o problema estudado configura um problema de otimização combinatória, no qual o modelo de AM desempenha o papel de função objetivo.

2.2 Objetivos Específicos

Com o intuito de atingir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

1. Coletar, estruturar e processar dados históricos de jogadores e partidas, abrangendo múltiplas temporadas, garantindo a qualidade e a integridade das informações utilizadas no desenvolvimento dos modelos preditivos.

2. Desenvolver uma metodologia para quantificar o impacto individual dos jogadores, combinando estatísticas históricas ao longo das temporadas por meio de um sistema de ponderação temporal, priorizando desempenhos mais recentes.

3. Construir modelos de AM para prever o desempenho agregado de uma equipe em uma determinada temporada, considerando a composição do elenco e os dados históricos dos jogadores.

4. Validar a eficácia dos modelos preditivos, comparando as estimativas com os resultados reais de temporadas subsequentes, utilizando métricas estatísticas como erro médio absoluto (MAE) e coeficiente de determinação (R^2).

5. Desenvolver modelos simples de otimização baseados no modelo de AM selecionado, visando a identificação de combinações de jogadores que maximizem o desempenho esperado da equipe sob restrições de mercado.

Ao integrar técnicas de AM e otimização, este estudo busca fornecer uma ferramenta analítica de apoio à decisão para a montagem de elencos no futebol profissional, contribuindo para práticas de gestão esportiva orientadas por dados.

3 REFERENCIAL TEÓRICO

Este capítulo apresenta os principais conceitos teóricos que fundamentam o desenvolvimento desta pesquisa. Inicialmente, são introduzidos os fundamentos de AM, destacando suas principais características e aplicações no contexto da modelagem preditiva. Na sequência, são abordados conceitos de PO, com ênfase em problemas de otimização combinatória e em métodos heurísticos que servem de base à abordagem de otimização da composição de elencos proposta neste trabalho.

3.1 Aprendizado de Máquina (AM)

Aprendizado de Máquina (AM) é o estudo de algoritmos e modelos estatísticos empregados por sistemas computacionais para realizar tarefas específicas de forma autônoma. Essa abordagem permite que as máquinas aprendam a partir de dados e melhorem seu desempenho sem necessidade de reprogramação explícita (Mahesh, 2020). Segundo Geron (2019), AM pode ser descrito como a ciência (ou arte) de programar computadores para que aprendam com os dados.

Um exemplo clássico de aplicação de AM é o filtro de *spam*, que permite que o sistema identifique automaticamente emails indesejados, diferenciando-os de mensagens legítimas com base em padrões aprendidos (Géron, 2019).

Com a crescente disponibilidade de *datasets*, o uso de AM tem apresentado um notável crescimento (Mahesh, 2020). Esse avanço pode ser atribuído à maior disponibilidade de dados e ao aumento da capacidade computacional. A constante conexão das pessoas a dispositivos digitais gera volumes massivos de dados, enquanto tecnologias modernas permitem o processamento eficiente dessas grandes quantidades de informação (Jordan; Mitchell, 2015).

Muitas indústrias têm adotado o AM com o objetivo de extrair insights relevantes de *databases*, facilitando o aprendizado a partir dos dados (Mahesh, 2020). Além disso, o AM tem sido amplamente aplicado em diversas áreas, incluindo reconhecimento facial, segmentação de imagens, detecção de câncer e previsão de classes e resultados, destacando-se também no contexto esportivo (Almulla *et al.*, 2023).

No desenvolvimento de sistemas de AM, a construção de modelos geralmente ocorre dentro de um pipeline composto por múltiplas etapas de processamento de dados. Em um

projeto típico de AM, os dados passam inicialmente por fases de coleta e preparação, seguidas por etapas de exploração e preparação dos dados, engenharia de atributos, seleção e treinamento de modelos, além de procedimentos de avaliação e ajuste de hiperparâmetros (Géron, 2019). Essas etapas são frequentemente organizadas em forma de pipeline, no qual cada componente executa uma transformação específica sobre os dados e produz uma saída que será utilizada pela etapa subsequente do processo (Géron, 2019). Essa estrutura modular permite organizar o fluxo de processamento e facilita a reprodução e manutenção dos modelos desenvolvidos. Um exemplo de organização dessas etapas no ciclo de vida de um projeto de análise de dados é apresentado na Figura 3.1, baseada no processo CRISP-DM, amplamente utilizado em projetos de mineração de dados e AM (Kelleher; Namee; D'Arcy, 2015).

Figura 3.1 – Pipeline CRISP-DM

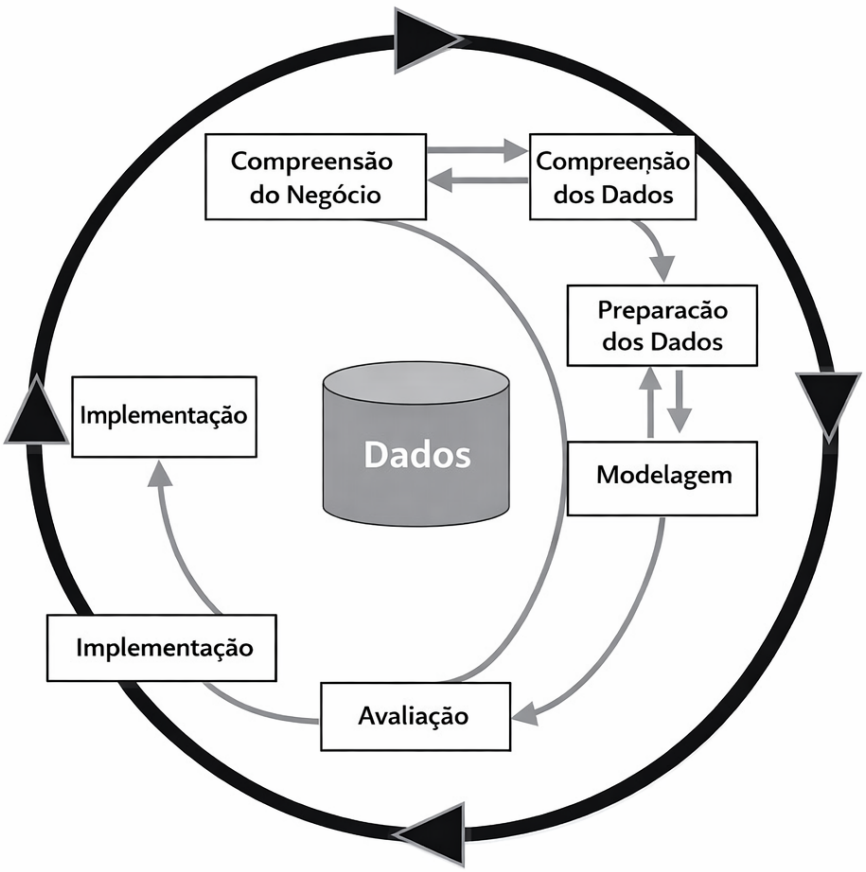

Fonte: Adaptado de (Kelleher; Namee; D'Arcy, 2015)

Dentro desse pipeline, a preparação e transformação dos dados desempenham papel fundamental, uma vez que os algoritmos de aprendizado frequentemente exigem representações específicas dos atributos para funcionar adequadamente.

3.1.1 Generalização, Viés e Variância

Um dos principais desafios em AM é garantir que o modelo apresente boa capacidade de generalização, isto é, desempenho satisfatório em dados não utilizados durante o treinamento (Goodfellow; Bengio; Courville, 2016).

Modelos excessivamente complexos podem se ajustar não apenas aos padrões relevantes, mas também ao ruído presente no conjunto de treinamento, fenômeno conhecido como *overfitting*. Em contrapartida, modelos demasiadamente simples podem não capturar relações importantes nos dados, resultando em *underfitting*.

Esse comportamento está diretamente relacionado ao equilíbrio entre viés e variância. Modelos com alto viés tendem a apresentar subajuste, enquanto modelos com alta variância tornam-se excessivamente sensíveis às particularidades do conjunto de treinamento. Técnicas como validação cruzada, regularização e controle da complexidade do modelo são estratégias amplamente utilizadas para mitigar esses problemas (Géron, 2019).

3.1.2 Seleção de Atributos e Redução de Dimensionalidade

Em problemas com elevado número de variáveis explicativas, a presença de atributos redundantes ou irrelevantes pode impactar negativamente o desempenho dos modelos preditivos. A seleção de atributos busca identificar subconjuntos de variáveis que contribuam de forma significativa para a tarefa de aprendizagem (Liu *et al.*, 2010).

Os métodos de seleção podem ser classificados em três categorias principais: filtros, que utilizam medidas estatísticas independentes do modelo; wrappers, que avaliam subconjuntos de atributos com base no desempenho de um algoritmo específico; e métodos embutidos, nos quais a seleção ocorre durante o próprio processo de treinamento (Guyon *et al.*, 2006).

Além da seleção direta de atributos, técnicas de redução de dimensionalidade, como a Análise de Componentes Principais (PCA), realizam uma transformação linear das variáveis originais em um novo conjunto de componentes ortogonais que preservam a maior parte da

variância dos dados. Essa abordagem pode reduzir complexidade computacional e mitigar problemas de multicolinearidade. Cabe ressaltar que a PCA não consiste em um método de seleção de atributos, mas sim em uma técnica de extração de atributos, pois cria novas variáveis a partir de combinações lineares das variáveis originais (Guyon *et al.*, 2006).

Além dos aspectos relacionados à preparação e transformação dos dados, também é importante distinguir os principais paradigmas de aprendizagem utilizados na construção de modelos preditivos. Em AM, os algoritmos podem ser classificados em diferentes categorias de acordo com a forma como aprendem a partir dos dados. Uma das distinções mais comuns ocorre entre aprendizado supervisionado e não supervisionado. No aprendizado supervisionado, o modelo é treinado a partir de um conjunto de dados rotulados, no qual cada instância possui uma variável alvo associada. O objetivo do algoritmo é aprender uma função que relacione os atributos de entrada com essa variável alvo, permitindo realizar previsões para novas instâncias (Géron, 2019). Por outro lado, no aprendizado não supervisionado os dados não possuem rótulos explícitos, e o objetivo do algoritmo consiste em identificar padrões, estruturas ou agrupamentos presentes nos dados (Géron, 2019). Técnicas como *clustering* e redução de dimensionalidade, incluindo a Análise de Componentes Principais (PCA), são exemplos de métodos amplamente utilizados nesse contexto.

Em problemas de aprendizado supervisionado, as tarefas podem ser geralmente divididas em classificação e regressão. Na classificação, o objetivo é atribuir cada instância a uma classe discreta previamente definida, como por exemplo identificar se um e-mail é *spam* ou não (Géron, 2019). Já na regressão, busca-se prever valores numéricos contínuos a partir de um conjunto de variáveis explicativas, como a previsão de preços, temperaturas ou outras quantidades mensuráveis (Géron, 2019). No contexto deste trabalho, o problema é formulado como uma tarefa de regressão, uma vez que o objetivo consiste em estimar a pontuação final de equipes em um campeonato a partir das características individuais dos jogadores que compõem o elenco.

Após as etapas de preparação, transformação e possível redução de dimensionalidade dos dados, diferentes algoritmos de AM podem ser empregados para construir modelos preditivos. A seguir, são apresentados alguns dos algoritmos mais comumente utilizados para a resolução de problemas de regressão, abordagem adotada no modelo proposto neste trabalho.

Entre os diversos algoritmos disponíveis na literatura, foram selecionados neste trabalho métodos amplamente utilizados em aprendizado supervisionado para tarefas de regressão,

incluindo modelos lineares, métodos baseados em árvores, métodos de *boosting* e redes neurais artificiais.

3.1.3 Regressão Linear (RL)

A regressão linear é uma técnica estatística amplamente utilizada para investigar e modelar a relação entre variáveis, sendo aplicada em diversas áreas da ciência, engenharia e ciências sociais (Montgomery; Peck; Vining, 2012). Nesse método, assume-se que a variável dependente pode ser expressa como uma combinação linear das variáveis explicativas.

Na forma mais geral, a RL pode ser expressa conforme a Equação 3.1:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \tag{3.1}$$

em que $\hat{y}$ representa o valor previsto da variável resposta, β_0 é o intercepto do modelo, $\beta_1, \beta_2, \ldots, \beta_p$ são os coeficientes associados às variáveis explicativas e $x_1, x_2, \ldots, x_p$ representam os atributos de entrada.

O processo de treinamento da RL consiste em estimar os coeficientes do modelo de forma a minimizar o erro entre os valores previstos e os valores observados no conjunto de treinamento. Uma abordagem amplamente utilizada para esse ajuste é o método dos mínimos quadrados ordinários, que busca minimizar a soma dos quadrados dos resíduos (Géron, 2019). Dessa forma, o modelo encontra a combinação linear dos atributos que melhor se ajusta aos dados segundo esse critério.

A RL apresenta como principais vantagens a simplicidade, a interpretabilidade e o baixo custo computacional. Por se tratar de um modelo linear, seus coeficientes podem ser interpretados como a contribuição de cada variável explicativa para a previsão da variável alvo, mantidas constantes as demais variáveis. Além disso, a RL costuma servir como modelo de referência (*baseline*) em tarefas preditivas, permitindo comparar o desempenho de modelos mais complexos (Géron, 2019).

Entretanto, a RL possui limitações importantes, especialmente quando a relação entre as variáveis explicativas e a variável resposta não pode ser adequadamente representada por uma função linear. Nesses casos, o modelo tende a apresentar desempenho inferior ao de métodos capazes de capturar padrões não lineares mais complexos. Ainda assim, sua utilização perma-

nece relevante tanto pela simplicidade quanto pelo seu papel como ponto de comparação em estudos de modelagem preditiva (Géron, 2019).

3.1.4 Árvore de Decisão (AD)

As Árvores de Decisão são algoritmos versáteis de AM que podem ser utilizados tanto para tarefas de classificação, quanto para tarefas de regressão (Géron, 2019). Esses algoritmos recebem dados de treinamento e retornam como saída uma estrutura em árvore capaz de realizar previsões para novas instâncias com base nos atributos de entrada (Géron, 2019).

A construção de uma árvore de decisão ocorre por meio de um processo recursivo de particionamento do espaço de atributos. Em cada nó interno da árvore, o algoritmo seleciona um atributo e um ponto de divisão que melhor separam os dados de acordo com um critério de qualidade da partição. Em tarefas de classificação, critérios como índice de Gini e entropia são amplamente utilizados, enquanto em problemas de regressão são comuns medidas baseadas na redução da variância ou do erro quadrático (Géron, 2019).

Além do processo de divisão recursiva, a geração de uma árvore de decisão envolve a escolha sucessiva dos melhores atributos e pontos de corte que maximizam a qualidade das partições geradas. Durante o treinamento, o algoritmo avalia diferentes possíveis divisões nos atributos disponíveis e seleciona aquela que produz o maior ganho de informação, a maior redução do índice de Gini ou a maior redução da variância/erro quadrático, dependendo da natureza do problema e do critério adotado. Esse procedimento é repetido de forma recursiva até que uma condição de parada seja satisfeita, como a profundidade máxima da árvore, o número mínimo de amostras em um nó ou a ausência de melhoria significativa na qualidade dos subconjuntos (Géron, 2019).

Em comparação com outras técnicas de aprendizado supervisionado, as árvores de decisão apresentam algumas características importantes. Uma de suas principais vantagens é a interpretabilidade, uma vez que a estrutura da árvore permite interpretar de forma transparente como as decisões são tomadas a partir dos atributos de entrada. Além disso, esses modelos requerem pouca preparação dos dados, pois não exigem normalização ou padronização das variáveis. Por outro lado, árvores de decisão individuais tendem a apresentar alta variância, sendo sensíveis a pequenas variações nos dados de treinamento. Essa característica pode levar ao fenômeno de *overfitting*, motivo pelo qual métodos baseados em conjuntos de árvores, como o

Random Forest, são frequentemente utilizados para melhorar a capacidade de generalização do modelo (Géron, 2019).

Um exemplo de AD pode ser visto na Figura 3.2.

Figura 3.2 – AD para Iris

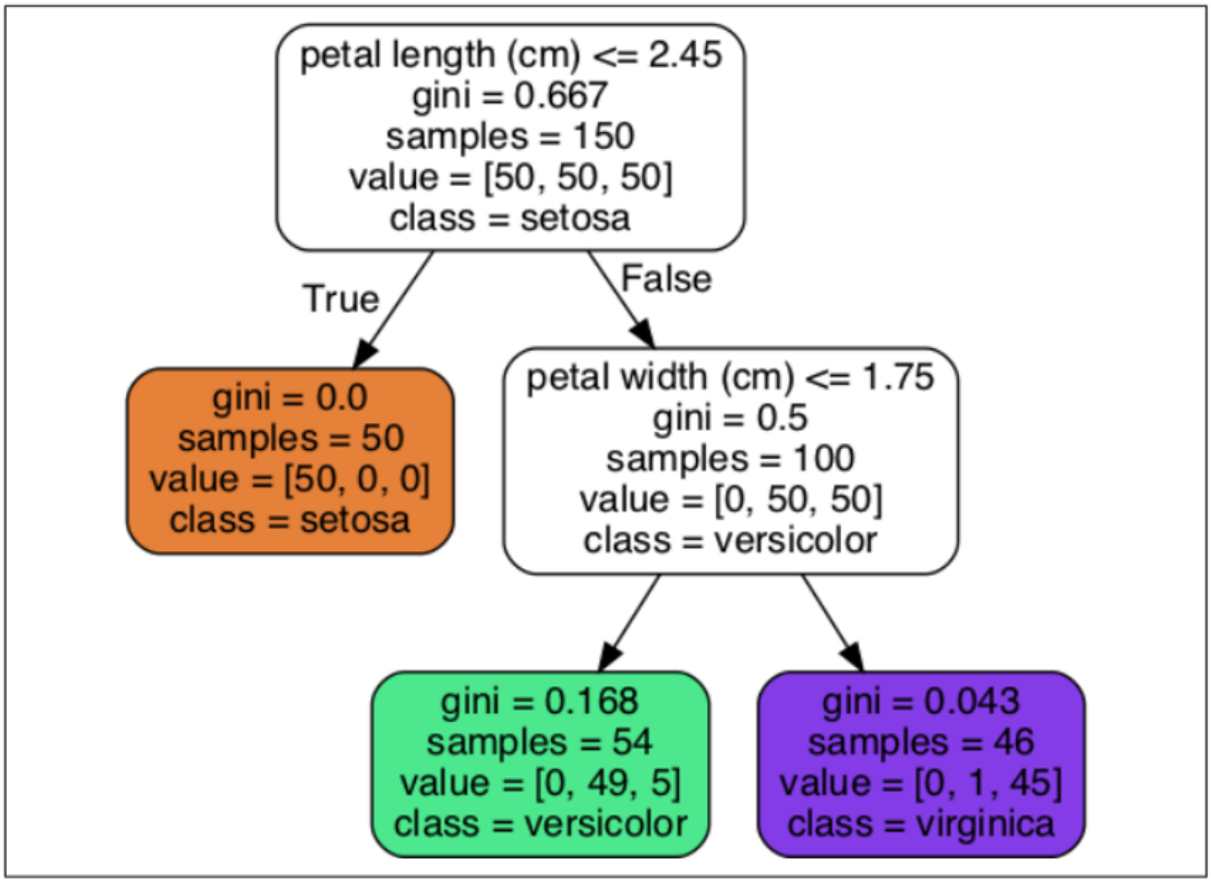

Fonte: (Géron, 2019))

Na Figura 3.2, é possível observar uma árvore de decisão utilizada para classificar flores do conjunto de dados *Iris*. O nó raiz divide as amostras com base no comprimento da pétala (*petal length* $\leq$ 2.45), separando a classe *setosa* (pura, Gini = 0). As amostras restantes são subdivididas pelo critério de largura da pétala (*petal width* $\leq$ 1.75), onde as classes *versicolor* e *virginica* são diferenciadas com alta precisão (Gini próximo de 0 nos nós finais). A árvore otimiza a classificação minimizando o índice de Gini em cada divisão (Géron, 2019).

3.1.5 Random Forest (RF)

O RF consiste em uma combinação de AD, geralmente treinadas por meio do método *bagging* (Géron, 2019). Diferente das ADs, RF utiliza uma randomização extra no crescimento

das árvores. Ao invés de buscar a melhor *feature* para dividir o nó, utiliza-se da melhor dentro de um *subset* randômico. Nesse caso, busca-se reduzir a variância do modelo por meio da agregação de múltiplas árvores, mantendo um viés relativamente baixo quando comparado a modelos excessivamente regularizados.

A motivação para essa estratégia está relacionada à redução da variância do modelo. ADs individuais são modelos de alta variância, ou seja, pequenas variações no conjunto de treinamento podem resultar em estruturas de árvore significativamente diferentes. Ao treinar múltiplas árvores em subconjuntos distintos dos dados e introduzir aleatoriedade na seleção de atributos, o RF reduz a correlação entre os modelos individuais. Como consequência, ao combinar as previsões das árvores, os erros individuais tendem a se compensar, produzindo um modelo mais estável e com melhor capacidade de generalização quando comparado a uma única AD (Géron, 2019).

Além da seleção aleatória de subconjuntos de atributos em cada divisão, o RF também utiliza amostragem com reposição (*bootstrap sampling*) para gerar diferentes subconjuntos de dados de treinamento para cada árvore. Esse procedimento, conhecido como *bootstrap aggregating* ou *bagging*, contribui para aumentar a diversidade entre os modelos individuais da floresta (Géron, 2019).

Durante a fase de predição, as saídas das árvores são agregadas para produzir o resultado final do modelo. Em tarefas de classificação, essa agregação ocorre por meio de votação majoritária entre as árvores, enquanto em problemas de regressão o resultado é geralmente obtido pela média das previsões individuais (Géron, 2019). Essa estratégia reduz a variância do modelo e tende a melhorar a capacidade de generalização quando comparada ao uso de uma única AD.

3.1.6 Gradient Boosting (XGBoost)

O *Gradient Boosting* é uma técnica de aprendizado baseada na combinação sequencial de modelos fracos, geralmente árvores de decisão rasas, com o objetivo de minimizar uma função de perda diferenciável (Géron, 2019). Diferentemente do *bagging*, no qual os modelos são treinados de forma independente, o *boosting* constrói cada novo preditor de maneira iterativa, ajustando-o aos resíduos (erros) cometidos pelo modelo anterior. Esse processo pode ser interpretado como uma otimização por gradiente no espaço funcional, na qual cada novo modelo aproxima a direção de maior redução da função de custo.

Formalmente, a cada iteração m, busca-se adicionar um novo modelo $h_m(x)$ de forma que o modelo final seja definido conforme a Equação 3.2:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \tag{3.2}$$

em que γ_m representa o passo ótimo na direção do novo preditor.

O *XGBoost* (*Extreme Gradient Boosting*) constitui uma implementação otimizada do *Gradient Boosting*, incorporando técnicas de regularização, paralelização e controle eficiente de memória (Géron, 2019). Além disso, sua função objetivo inclui termos de penalização que auxiliam na prevenção de *overfitting*, tornando-o especialmente eficaz em problemas de alta dimensionalidade e grandes volumes de dados.

3.1.7 Multilayer Perceptron (MLP)

O *Multilayer Perceptron* (MLP) é uma função matemática parametrizada que aprende a melhor forma de transformar um vetor de entrada $\mathbf{x}$ em uma saída $\mathbf{y}$. Assim, o MLP pode ser entendido como uma composição de várias funções aplicadas em sequência, formando um modelo de múltiplas camadas (Goodfellow; Bengio; Courville, 2016).

A arquitetura do MLP segue uma estrutura do tipo entrada $\rightarrow$ camadas ocultas $\rightarrow$ saída, utilizando uma função de ativação $g(\cdot)$ para introduzir não linearidade em cada camada. Essa relação pode ser expressa conforme a Equação 3.3:

$$h^{(l)} = g\left(W^{(l)} h^{(l-1)} + b^{(l)}\right) \tag{3.3}$$

em que $W^{(l)}$ e $b^{(l)}$ representam, respectivamente, a matriz de pesos e o vetor de vieses da camada l (Goodfellow; Bengio; Courville, 2016).

A introdução da função não linear $g(\cdot)$ é essencial, pois permite que o MLP aprenda relações complexas entre as variáveis de entrada e saída. Na ausência dessa não linearidade, o modelo se reduz a uma combinação linear das entradas, tornando-se incapaz de representar funções não lineares (Goodfellow; Bengio; Courville, 2016).

De forma geral, um MLP é composto por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída, com conexões totalmente conectadas entre camadas consecutivas. Nesse tipo de rede, o fluxo de informação ocorre em apenas uma direção, da entrada para

a saída, caracterizando uma arquitetura do tipo *feedforward* (Géron, 2019). Cada neurônio de uma camada recebe como entrada uma combinação linear das ativações da camada anterior, adiciona um termo de viés e aplica uma função de ativação não linear, produzindo uma nova representação intermediária dos dados.

A presença de múltiplas camadas ocultas permite que o modelo aprenda representações internas cada vez mais abstratas dos dados de entrada. Esse processo de transformação sucessiva possibilita que redes neurais representem funções altamente complexas, o que torna os MLPs capazes de resolver problemas que modelos lineares não conseguem modelar adequadamente (Goodfellow; Bengio; Courville, 2016; Géron, 2019).

O treinamento de um MLP é realizado por meio do algoritmo de retropropagação do erro (*backpropagation*), que calcula o gradiente da função de perda em relação aos parâmetros da rede. Esse gradiente é utilizado por métodos de otimização baseados em descida do gradiente para atualizar iterativamente os pesos e vieses da rede, minimizando o erro entre as previsões do modelo e os valores observados (Goodfellow; Bengio; Courville, 2016). De acordo com (Géron, 2019), o processo de treinamento envolve a propagação direta dos dados pela rede (*forward pass*), seguida do cálculo do erro e da propagação desse erro no sentido inverso para ajustar os parâmetros do modelo.

Os MLPs podem ser utilizados tanto em tarefas de regressão quanto de classificação. Em problemas de regressão, a camada de saída geralmente possui um único neurônio com ativação linear, enquanto em tarefas de classificação podem ser utilizadas funções de ativação como a logística ou *softmax*, dependendo da natureza do problema (Géron, 2019). Essa flexibilidade faz com que o MLP seja uma das arquiteturas mais amplamente utilizadas no contexto de aprendizado profundo.

Além disso, o desempenho do modelo depende fortemente da escolha de hiperparâmetros como o número de camadas ocultas, o número de neurônios por camada, a função de ativação e a taxa de aprendizado. A definição adequada desses parâmetros é fundamental para garantir a capacidade de generalização do modelo e evitar problemas como *overfitting* ou *underfitting* (Géron, 2019).

3.2 Pesquisa Operacional (PO)

A Pesquisa Operacional (PO) constitui um campo multidisciplinar dedicado ao desenvolvimento e aplicação de modelos matemáticos, estatísticos e computacionais com o objetivo de apoiar processos de tomada de decisão. De forma geral, a PO busca representar problemas reais por meio de formulações matemáticas, permitindo a identificação de soluções que maximizem ou minimizem determinados objetivos sob um conjunto de restrições (Hillier; Lieberman, 2001).

Historicamente, técnicas de PO têm sido aplicadas em uma ampla variedade de contextos organizacionais, incluindo manufatura, transportes, construção civil, telecomunicações, planejamento financeiro, sistemas de saúde e gestão pública (Hillier; Lieberman, 2001). Em muitos desses cenários, os problemas de decisão envolvem a seleção de recursos limitados ou a alocação eficiente de elementos dentro de determinadas restrições estruturais.

No contexto esportivo, problemas como a montagem de elencos e o planejamento competitivo podem ser formalizados como problemas de otimização matemática sob restrições estruturais e orçamentárias. Em tais situações, busca-se selecionar ou alocar recursos — como jogadores — de forma a maximizar algum critério de desempenho coletivo, respeitando limitações impostas por fatores como orçamento, composição do elenco ou regras da competição.

Dependendo da natureza do problema, tais formulações podem recorrer a abordagens heurísticas voltadas à resolução de problemas de otimização combinatória, nos quais o espaço de soluções possíveis cresce exponencialmente com o número de variáveis de decisão. Nesses casos, métodos heurísticos tornam-se particularmente úteis para explorar o espaço de soluções e identificar configurações de boa qualidade em tempo computacional viável.

Entre os problemas clássicos da otimização combinatória destacam-se modelos que envolvem decisões de seleção sob restrições de capacidade ou orçamento. Um dos exemplos mais conhecidos dessa classe de problemas é o Problema da Mochila, apresentado a seguir.

3.2.1 Problema da Mochila

Um dos problemas clássicos da otimização combinatória é o Problema da Mochila (*Knapsack Problem*), amplamente utilizado como modelo abstrato para representar situações de seleção de recursos sob restrições limitadas (Cormen *et al.*, 2009). Nesse problema, considera-

se um conjunto de n itens, no qual cada item i possui um valor associado v_i e um peso w_i. O objetivo consiste em selecionar um subconjunto desses itens de modo a maximizar o valor total transportado, sem que o peso total ultrapasse a capacidade máxima W da mochila.

Na formulação conhecida como *0-1 Knapsack Problem*, cada item pode ser selecionado integralmente ou não selecionado, caracterizando uma decisão binária para cada elemento do conjunto. Dessa forma, o problema pode ser formulado matematicamente conforme as Equações 3.4–3.6:

$$\max \sum_{i=1}^{n} v_i x_i \tag{3.4}$$

sujeito a

$$\sum_{i=1}^{n} w_i x_i \leq W \tag{3.5}$$

$$x_i \in \{0,1\}, \quad i = 1,2,\ldots,n \tag{3.6}$$

em que x_i representa a decisão de selecionar ($x_i = 1$) ou não ($x_i = 0$) o item i.

De acordo com (Cormen *et al.*, 2009), o problema da mochila apresenta a propriedade de subestrutura ótima, característica comum em diversos problemas de otimização combinatória. No entanto, diferentemente da variante fracionária do problema, na qual é permitido selecionar frações de itens, a versão 0-1 não admite, em geral, soluções ótimas por meio de estratégias puramente gulosas. Nesse caso, a decisão de incluir ou excluir um determinado item depende da comparação entre diferentes combinações possíveis de itens, o que torna o problema computacionalmente mais desafiador.

Problemas de seleção sob restrições orçamentárias frequentemente apresentam estrutura semelhante à do Problema da Mochila. No contexto deste trabalho, a tarefa de definir quais jogadores devem compor um elenco sob um limite financeiro pode ser interpretada como um problema de seleção de elementos cujo custo total não deve exceder um orçamento disponível. De maneira análoga ao problema clássico, cada jogador pode ser associado a um custo de contratação e a um valor estimado de contribuição para o desempenho da equipe, avaliado por meio do modelo de AM desenvolvido neste estudo. Sob essa perspectiva, o problema de montagem de elencos pode ser interpretado como uma variação do Problema da Mochila, no qual se busca

selecionar um conjunto de jogadores capaz de maximizar o desempenho previsto do time sem ultrapassar o orçamento disponível.

Entretanto, diferentemente da formulação clássica do problema, a seleção de jogadores envolve também restrições estruturais adicionais. Em um elenco de futebol, por exemplo, o número total de jogadores é limitado e a composição da equipe deve respeitar determinadas necessidades posicionais e funcionais. Essas características aproximam o problema de variantes mais gerais do Problema da Mochila, nas quais múltiplas restrições ou categorias de seleção são consideradas.

Dessa forma, embora o problema abordado neste trabalho não corresponda exatamente à formulação clássica do Problema da Mochila, sua estrutura de decisão apresenta forte analogia com esse modelo. Essa relação fornece uma base conceitual importante para compreender a natureza combinatória da montagem de elencos e justifica a adoção de heurísticas de otimização para a obtenção de soluções de boa qualidade em tempo computacional viável.

A partir dessa fundamentação, apresentam-se a seguir dois métodos heurísticos amplamente utilizados em problemas de otimização combinatória: os algoritmos gulosos e a busca local.

3.2.2 Algoritmo Guloso

Em problemas de otimização, um algoritmo é dito guloso quando realiza uma escolha localmente ótima, na esperança de que essa decisão conduza a uma solução globalmente ótima (Cormen *et al.*, 2009). Diferentemente de abordagens exaustivas, algoritmos gulosos tomam decisões irrevogáveis a cada etapa, baseando-se apenas na informação disponível no momento da escolha. É importante destacar que, conforme ressaltado por (Cormen *et al.*, 2009), algoritmos gulosos não garantem, em geral, a obtenção de soluções globalmente ótimas, sendo necessários argumentos específicos de corretude para justificar quando a estratégia gulosa é válida.

Conforme discutido por (Cormen *et al.*, 2009), algoritmos gulosos podem ser formulados de maneira iterativa ou recursiva. Na forma recursiva, o método costuma seguir um padrão *top-down*: realiza-se uma escolha gulosa, reduz-se o problema a um subproblema estritamente menor e repete-se o processo até a construção completa de uma solução. A justificativa de corretude, quando possível, normalmente se apoia em dois ingredientes: (i) a *propriedade da escolha gulosa*, isto é, a existência de uma solução ótima que contém a decisão local tomada; e (ii) a

subestrutura ótima, segundo a qual, após fixar a decisão gulosa, o restante do problema preserva a mesma estrutura do original, de modo que uma solução ótima do subproblema completa uma solução ótima do problema inicial.

Para ilustrar o funcionamento dessa estratégia, considere o problema do *Traveling Salesman Problem* (TSP), no qual se deseja encontrar um circuito Hamiltoniano de custo mínimo que visite exatamente uma vez cada cidade de um conjunto dado e retorne ao ponto inicial. Nesse contexto, uma heurística gulosa construtiva bastante conhecida é o método do *vizinho mais próximo* (*nearest neighbor*). O algoritmo inicia em uma cidade arbitrária e, a cada etapa, seleciona a cidade ainda não visitada que possui a menor distância em relação à cidade atual, repetindo o processo até que todas as cidades tenham sido visitadas e o ciclo seja fechado retornando à cidade inicial (Gendreau; Potvin, 2010).

Esse procedimento exemplifica claramente a lógica gulosa: em cada passo é realizada a escolha localmente mais vantajosa — visitar a cidade mais próxima — sem reconsiderar decisões anteriores. Embora tal estratégia permita construir rapidamente uma solução viável para o problema, não há garantia de que o circuito obtido seja globalmente ótimo, uma vez que decisões tomadas nas primeiras etapas podem restringir significativamente as escolhas disponíveis nas etapas subsequentes (Gendreau; Potvin, 2010).

O Algoritmo 1 apresenta o pseudocódigo dessa heurística gulosa aplicada ao TSP.

Algoritmo 1 Heurística Gulosa para o TSP (Vizinho Mais Próximo)

Require: Conjunto de cidades V, matriz de distâncias $d(i, j)$
Ensure: Ciclo Hamiltoniano T
  Escolher cidade inicial v_0
  Inicializar T com v_0
  Inicializar conjunto de cidades não visitadas $U \leftarrow V \setminus \{v_0\}$
  Definir cidade atual $v \leftarrow v_0$
  while existirem cidades não visitadas **do**
    Escolher $u \in U$ que minimize $d(v, u)$
    Adicionar u ao final de T
    Remover u de U
    Atualizar cidade atual $v \leftarrow u$
  end while
  Adicionar v_0 ao final de T ▷ retorno à cidade inicial
  return T

No contexto deste trabalho, um algoritmo guloso é utilizado de forma recursiva com o objetivo de gerar uma solução inicial para o problema de otimização da montagem de elencos. Dado um time e um orçamento, a cada iteração, o jogador com menor minutagem do elenco é

removido e substituído por candidatos externos. Para cada substituição possível, o modelo de AM é empregado como função objetivo, estimando a pontuação esperada do time resultante. A escolha gulosa consiste, portanto, em selecionar o(s) jogador(es) que cabem no orçamento do time e cuja inclusão maximiza a pontuação prevista, mantendo-se fixas as demais variáveis do elenco. Assim como no exemplo discutido anteriormente, a solução é construída incrementalmente por decisões locais irrevogáveis, produzindo rapidamente uma solução factível que servirá como ponto de partida para os procedimentos de refinamento realizados por busca local.

3.2.3 Algoritmo de Busca Local

Enquanto algoritmos gulosos constroem soluções de forma incremental a partir de decisões locais, métodos de busca local partem de uma solução inicial já factível e buscam refiná-la por meio da exploração iterativa de sua vizinhança. A busca local é uma técnica heurística amplamente utilizada em problemas de otimização combinatória, cujo objetivo é aprimorar uma solução inicial factível por meio da exploração iterativa de soluções vizinhas (Gendreau; Potvin, 2010). Diferentemente de métodos exatos, a busca local não realiza uma exploração global do espaço de soluções, concentrando-se na melhoria incremental da solução corrente a partir de movimentos locais.

Conforme descrito por (Gendreau; Potvin, 2010), um algoritmo de busca local é composto essencialmente por quatro elementos: uma solução inicial, a definição de uma vizinhança, um critério de aceitação de movimentos e uma condição de parada. A vizinhança determina o conjunto de soluções que podem ser alcançadas a partir da solução atual por meio de pequenas modificações estruturais, enquanto o critério de aceitação estabelece se uma solução vizinha deve ou não substituir a solução corrente. O processo é repetido iterativamente até que nenhuma melhoria adicional seja encontrada ou que um critério de parada seja satisfeito.

Um exemplo clássico da aplicação de busca local ocorre no Problema do Caixeiro Viajante (*Traveling Salesman Problem* – TSP). Croes (Croes, 1958) propôs um método de melhoria que parte de uma solução inicial e aplica transformações denominadas *inversions*, nas quais a ordem de uma subsequência de cidades do tour é invertida sempre que essa operação reduz o comprimento total do percurso. Essas transformações geram soluções vizinhas a partir da solução corrente e são aceitas apenas quando produzem melhoria na função objetivo. Esse

procedimento caracteriza uma estratégia típica de busca local, na qual soluções vizinhas são exploradas iterativamente até que nenhuma melhoria adicional possa ser obtida.

No contexto do TSP, uma operação de inversão consiste em selecionar duas posições do tour e inverter a ordem das cidades contidas no segmento compreendido entre essas posições. Essa modificação gera uma nova rota candidata que pode apresentar menor comprimento total quando comparada à solução original. Caso a nova solução produza melhoria na função objetivo, ela passa a substituir a solução corrente, e o processo de exploração da vizinhança continua até que nenhuma inversão adicional resulte em redução do custo do percurso.

Um pseudocódigo simplificado desse procedimento de busca local baseado em inversões é apresentado no Algoritmo 2.

Algoritmo 2 Busca local baseada em inversões para o TSP

Require: tour inicial T
Ensure: tour melhorado T^*

```
melhoria ← verdadeiro
while melhoria do
    melhoria ← falso
    for i = 1 até n − 1 do
        for j = i + 1 até n do
            T′ ← tour obtido invertendo o segmento entre i e j
            if dist(T′) < dist(T) then
                T ← T′
                melhoria ← verdadeiro
            end if
        end for
    end for
end while
return T
```

No problema abordado neste trabalho, a busca local é empregada para avaliar diferentes conjuntos de jogadores candidatos a contratação, respeitando uma restrição de orçamento. Cada solução é representada por um conjunto de jogadores de cardinalidade fixa, sendo a vizinhança definida por operações de substituição unitária (*swap neighborhood*). Em cada iteração, jogadores do conjunto atual são considerados candidatos à remoção e substituídos por jogadores externos ainda não selecionados, produzindo soluções vizinhas que preservam o tamanho do elenco. Cada solução vizinha gerada é avaliada por meio de uma função objetivo implementada a partir do modelo de AM, responsável por estimar a pontuação esperada do time na temporada considerada.

A restrição orçamentária é tratada como condição de factibilidade: soluções que excedem o orçamento estabelecido são descartadas durante o processo de busca. O critério de aceitação adotado é de melhoria estrita, isto é, uma solução vizinha é aceita apenas se apresentar valor superior da função objetivo em relação à solução corrente. O algoritmo é encerrado quando nenhuma substituição viável resulta em melhoria adicional, caracterizando a convergência para um ótimo local, conforme descrito em (Gendreau; Potvin, 2010).

4 REVISÃO DE LITERATURA

Após a apresentação dos principais fundamentos teóricos relacionados ao AM e aos métodos de otimização, torna-se importante analisar como essas abordagens têm sido aplicadas na literatura científica. Assim, este capítulo apresenta uma revisão de estudos que utilizam técnicas de AM e otimização no contexto esportivo, com ênfase em aplicações relacionadas ao futebol.

4.1 Aprendizado de Máquina (AM) no contexto esportivo

Em 2020, *Horvat & Job* apresentaram uma revisão abrangente sobre o uso de AM na predição de resultados esportivos, com foco principal em esportes coletivos, especialmente o futebol. Os autores destacam que o AM é particularmente adequado a essa tarefa, uma vez que modalidades esportivas geram grandes volumes de dados estruturados e não estruturados, provenientes de eventos de jogo, sistemas de *tracking*, probabilidades associadas às partidas e bases históricas consolidadas (Horvat; Job, 2020).

Conforme apontado por *Horvat & Job* (2020), a maior parte dos estudos que empregam métodos preditivos no contexto esportivo concentra-se na predição de resultados de partidas individuais, especialmente na classificação de vitórias, empates e derrotas. Essa predominância pode ser explicada tanto pelo interesse mercadológico associado às apostas esportivas, que incentiva o desenvolvimento de modelos voltados à antecipação de resultados (Abidin, 2021), quanto pela própria natureza técnica do problema, que se ajusta adequadamente aos algoritmos supervisionados mais difundidos e à disponibilidade de bases históricas amplamente registradas no futebol (Horvat; Job, 2020). Nesse contexto, observa-se menor atenção a problemas relacionados ao desempenho agregado ao longo de uma temporada, especialmente quando este é modelado de forma prospectiva como função da composição individual do elenco.

Em contraste com essa predominância de estudos voltados à predição de partidas isoladas, a revisão conduzida por (Abidin, 2021) identifica, ainda que em menor número, trabalhos que abordam diretamente o problema de seleção e formação de equipes sob uma perspectiva multicritério e de otimização. Entre os estudos mencionados, destacam-se (Tavana *et al.*, 2013), que propõem um sistema de inferência fuzzy em duas fases para seleção de jogadores e posterior arranjo tático da equipe, e (Qader *et al.*, 2017), que estruturam o problema de escolha

de atletas como uma análise multicritério baseada em múltiplas métricas de desempenho. Tais abordagens representam esforços relevantes no sentido de formalizar o processo de composição de elencos, ainda que se apoiem predominantemente em modelos fuzzy ou técnicas de agregação determinística, sem incorporar mecanismos de aprendizado supervisionado voltados à predição prospectiva de desempenho coletivo.

Os estudos voltados à predição de resultados, por sua vez, identificam o uso recorrente de algoritmos como regressão logística, *Support Vector Machines* (SVM), *Random Forest* e redes neurais, destacando que modelos que integram múltiplas fontes de informação — incluindo estatísticas tradicionais, indicadores derivados e variáveis contextuais — tendem a apresentar melhor desempenho preditivo (Horvat; Job, 2020). Ainda assim, a tarefa permanece desafiadora devido à natureza estocástica do futebol e à ausência de padronização entre bases de dados utilizadas em diferentes estudos. Cabe ressaltar que, nos últimos anos, a geração de dados aumentou significativamente com a maior disponibilidade de dados esportivos em larga escala, impulsionada pela expansão de sistemas de *tracking* e por bancos estruturados como *Opta* e *StatsBomb* (Horvat; Job, 2020).

4.1.1 Previsão de resultados de partidas

Conforme ressaltado anteriormente, os modelos de previsão de resultados de partidas constituem uma das aplicações mais tradicionais do AM no futebol, com foco na classificação de vitórias, empates e derrotas. A seguir, apresentam-se alguns estudos representativos dessa linha de pesquisa, com o objetivo de evidenciar sua evolução metodológica.

Um dos trabalhos pioneiros é o de *Joseph, Fenton & Neil* (2006) (Joseph; Fenton; Neil, 2006), que empregaram redes Bayesianas para prever resultados a partir de um conjunto reduzido de dados do *Tottenham Hotspur Football Club* (1995–1997). A base analisada compreendeu 76 partidas e 30 atributos, sendo 28 jogadores representados por variáveis binárias (presença ou ausência), além do local da partida e da qualidade do adversário. Os próprios autores reconhecem tratar-se de um cenário com disponibilidade limitada de dados, o que impõe desafios adicionais aos métodos de aprendizado supervisionado. Ainda assim, os resultados indicaram que a rede Bayesiana construída com conhecimento especializado apresentou melhor desempenho relativo nos experimentos realizados, mesmo diante da limitação amostral. Esse resultado reforça que, em contextos com bases reduzidas e forte especificidade estrutural, a mo-

delagem explícita das relações entre variáveis pode mitigar parcialmente os efeitos da escassez de dados. Entretanto, o estudo permanece circunscrito à predição de partidas individuais e a uma equipe específica.

Em contexto mais recente, *Baboota & Kaur* (2019) (Baboota; Kaur, 2019) investigaram a predição multiclasse de resultados na Premier League utilizando dados de duas temporadas (2014–2015 e 2015–2016). O estudo incorporou variáveis relacionadas ao desempenho recente das equipes, estatísticas técnicas de jogo (finalizações, posse de bola, escanteios), *ratings* derivados do FIFA Index e fator casa/fora. Foram avaliados algoritmos como *Random Forest*, SVM, Naive Bayes e XGBoost, sendo o *Gradient Boosting* o modelo de melhor desempenho. Ainda assim, os autores observam que os modelos não superaram as previsões das casas de apostas, que incorporam variáveis não observáveis pelos modelos estatísticos. Embora represente uma ampliação substancial em relação a trabalhos anteriores — tanto em volume de dados quanto na diversidade de algoritmos avaliados — o problema permanece centrado na predição do desfecho de partidas individuais.

No âmbito do Aprendizado Profundo, *Awadallah & Khandelwal* (2020) (Awadallah; Khandelwal, 2020) compararam regressão logística, *Random Forest*, redes neurais densas (DNN) e LSTM na predição de resultados da EPL ao longo de dez temporadas (2008–2019), utilizando aproximadamente 4.180 partidas e um conjunto reduzido de 24 *features*. O modelo LSTM apresentou o melhor desempenho, alcançando cerca de 58% de acurácia em teste. Apesar do avanço metodológico representado pelo uso de redes neurais profundas, os autores destacam limitações relacionadas à generalização e à natureza estocástica do futebol.

De modo geral, observa-se uma evolução metodológica significativa, desde bases reduzidas com forte dependência de conhecimento especializado até modelos supervisionados e redes neurais aplicados a bases mais amplas. Ainda assim, a unidade analítica predominante permanece sendo a partida individual, com ênfase na classificação do resultado do jogo.

4.1.2 Aplicações recentes do Aprendizado de Máquina (AM) no futebol

Para além da predição de partidas isoladas, a literatura recente evidencia uma ampliação do escopo de aplicação do AM no futebol. *Rico-González et al.* (2023) demonstram que o AM tem sido empregado em diversas frentes, como análise de desempenho físico, detecção de padrões táticos, avaliação de risco de lesões e modelagem espacial com dados de *tracking*

(Rico-González *et al.*, 2023). A crescente disponibilidade de dados tem impulsionado abordagens metodológicas cada vez mais complexas, incluindo redes neurais profundas, modelos probabilísticos e métodos baseados em séries temporais.

Além das aplicações voltadas à predição de partidas, estudos recentes evidenciam a incorporação crescente de dados espaciais e fisiológicos na modelagem do desempenho esportivo. O volume *Machine Learning and Data Mining for Sports Analytics* (MLSA, 2023) destaca a integração entre dados de eventos e informações de *tracking*, ressaltando que modelos exclusivamente baseados em eventos enfrentam limitações estruturais pela ausência de contexto espacial e pressão defensiva (Brefeld *et al.*, 2024). De forma complementar, pesquisas como a de Majumdar et al. (2022) exploram a aplicação de AM na predição de lesões a partir de variáveis relacionadas à carga de treino e competição, utilizando desde regressão logística até redes neurais artificiais. Essas abordagens evidenciam a ampliação temática e metodológica do campo, mas permanecem majoritariamente voltadas à modelagem de situações específicas de jogo ou risco individual, não se direcionando à modelagem prospectiva do desempenho agregado de temporada como função da composição do elenco.

No contexto nacional, observa-se também o crescimento da área de *sports analytics*, com iniciativas acadêmicas como o Sports Analytics Lab (SALab) da UFMG, voltadas à aplicação de métodos quantitativos no futebol.

Apesar dessa expansão metodológica e temática, observa-se que a maior parte dos estudos ainda se concentra na modelagem de eventos específicos ou na predição de partidas isoladas, conforme destacado por *Horvat & Job* (2020). Em contraste, verifica-se menor atenção a abordagens voltadas à modelagem do desempenho agregado das equipes ao longo de uma temporada, especialmente quando esse desempenho é tratado como função da composição individual do elenco. Essa constatação reforça a necessidade de examinar de forma mais sistemática como a literatura tem abordado o desempenho agregado sob perspectivas estatísticas e econômicas.

4.1.3 Desempenho agregado e determinantes de temporada

Além da predição de partidas individuais, parte da literatura tem investigado determinantes do desempenho agregado ao longo de uma temporada. Lago-Ballesteros e Lago-Peñas (2010), ao analisarem todas as 380 partidas da temporada 2008–2009 da La Liga espanhola, identificaram diferenças estatisticamente significativas entre equipes do topo e da parte inferior

da tabela em variáveis como gols marcados, total de finalizações, finalizações no alvo, assistências e posse de bola (Lago-Ballesteros; Lago-Peñas, 2010). Os resultados indicam que o sucesso competitivo agregado pode ser parcialmente explicado por padrões estatísticos observáveis ao longo da temporada.

Sob a ótica econômica, estudos como os de Carmichael, McHale e Thomas (2011) analisam o desempenho agregado das equipes a partir de variáveis estruturais, como gastos salariais e receitas, evidenciando associação entre investimento financeiro e posição final na liga (Carmichael; McHale; Thomas, 2011). De forma complementar, Totty e Owens (2011) discutem como mecanismos institucionais, como tetos salariais, influenciam o equilíbrio competitivo das ligas profissionais (Totty; Owens, 2011). Essas abordagens indicam que o desempenho ao longo de uma temporada pode ser parcialmente explicado por fatores estruturais e de alocação de recursos, reforçando a ideia de que o sucesso competitivo agregado não é puramente aleatório.

Herold, Memmert e Perl (2019) investigaram a aplicação de AM no futebol profissional masculino, utilizando variáveis como passes, finalizações, dribles e métricas derivadas, como Gols Esperados (xG). O estudo demonstra que padrões técnicos individuais podem ser representados matematicamente e modelados por meio de algoritmos supervisionados e não supervisionados, incluindo redes neurais, árvores de decisão e regressão logística (Herold; Memmert; Perl, 2019). Tais evidências reforçam que estatísticas de desempenho individual constituem insumos mensuráveis e potencialmente preditivos do sucesso competitivo.

Complementarmente, Kite e Nevill (2017) investigaram preditores de sucesso ao longo de temporadas consecutivas de uma mesma equipe, demonstrando que determinados indicadores de desempenho apresentam capacidade explicativa sobre a posição final e os resultados obtidos (Kite; Nevill, 2017). Tais resultados evidenciam que métricas de jogo podem ser utilizadas para modelar o sucesso competitivo.

Embora o estudo de *Kite e Nevill* (2017) represente um avanço ao empregar modelos estatísticos com finalidade preditiva, sua modelagem permanece centrada no nível da partida individual. O sucesso é operacionalizado a partir do desfecho dos jogos (vitória, empate ou derrota), e as variáveis explicativas derivam predominantemente de indicadores agregados por partida (Kite; Nevill, 2017). Dessa forma, ainda que tais contribuições ampliem a compreensão dos determinantes estatísticos do desempenho competitivo, não há uma modelagem explícita do desempenho agregado da temporada como função da composição estrutural do elenco. Essa lacuna torna-se particularmente relevante quando se considera que decisões estratégicas no fu-

tebol profissional — especialmente no mercado de transferências — são tomadas com base na expectativa de desempenho ao longo de toda a competição, e não apenas em resultados isolados.

De modo semelhante, embora essas contribuições identifiquem determinantes técnicos e econômicos do sucesso competitivo, elas concentram-se majoritariamente na análise de resultados já observados ou em relações estruturais agregadas. Não modelam explicitamente, de forma prospectiva, a pontuação esperada de uma equipe como função direta da composição individual do elenco, tampouco integram tais estimativas a problemas formais de decisão.

4.2 Pesquisa Operacional (PO) no contexto esportivo

A Pesquisa Operacional (PO) constitui um conjunto de métodos analíticos voltados à modelagem e otimização de processos decisórios (Medri; Yotsumoto, 2009; Wright, 2009). No contexto esportivo, sua aplicação abrange desde problemas estratégicos, como o gerenciamento de equipes, até decisões táticas e logísticas (Gerchak, 1994).

Técnicas como Programação Linear, Programação Dinâmica e Processos de Markov têm sido empregadas na análise de substituições, estratégias de jogo e planejamento competitivo (Clarke; Norman, 1998; Hirotsu; Wright, 2002). Em muitos casos, tais problemas apresentam natureza combinatória e elevada complexidade computacional.

Conforme discutido por (Kendall; Parkes; Spoerer, 2010), diversos problemas de organização competitiva e escalonamento esportivo (*sports scheduling*) apresentam elevada complexidade combinatória, sendo muitos deles classificados como NP-difíceis ou NP-completos em suas versões formais. Entre os exemplos destacados estão o Traveling Tournament Problem (TTP), que busca minimizar as distâncias percorridas pelas equipes sob restrições estruturais de calendário; o problema de minimização de *breaks* em torneios round-robin, cuja versão com calendário parcial é NP-difícil; e variantes do problema de alocação de árbitros, cuja versão de decisão é NP-completa. Diante dessa complexidade, especialmente em instâncias de grande porte e com múltiplas restrições, a literatura recorre amplamente a heurísticas e metaheurísticas, como busca local, *simulated annealing*, *tabu search* e métodos híbridos, visando à obtenção de soluções de alta qualidade em tempo computacional viável.

Nesse contexto, destaca-se o trabalho de Ribeiro e Urrutia (Ribeiro; Urrutia, 2007), que aborda a variante *mirrored traveling tournament problem* (mTTP), uma extensão do TTP em que o calendário da segunda metade da competição replica a primeira com inversão de mandos

de campo. Os autores propõem heurísticas construtivas e metaheurísticas híbridas baseadas em GRASP e *iterated local search*, demonstrando a eficácia dessas abordagens na obtenção de soluções de alta qualidade para problemas de grande porte. Esse trabalho evidencia tanto a complexidade inerente ao escalonamento esportivo quanto a relevância de métodos heurísticos sofisticados para sua resolução.

Além da dificuldade computacional inerente a esses problemas, observa-se também uma limitação recorrente na modelagem adotada. Na maior parte dos trabalhos, a função objetivo é definida por métricas simplificadas ou parâmetros fixos, não incorporando modelos preditivos baseados no desempenho individual de atletas como componente central do problema decisório. Assim, permanece inexplorada a integração entre modelos preditivos de desempenho agregado e técnicas de otimização aplicadas à montagem de elenco.

Problemas de montagem de elenco também têm sido abordados sob a ótica da otimização matemática. Pantuso (Pantuso, 2017) propõe o *Football Team Composition Problem* por meio de um modelo de programação estocástica multietapa, no qual a incerteza sobre o desenvolvimento futuro dos atletas é incorporada explicitamente à formulação. De forma complementar, Boon e Sierksma (Boon; Sierksma, 2003) modelam a formação de equipes como um problema de alocação ótima jogador–posição, formulado via programação linear inteira e equivalente a um problema de *matching* máximo ponderado. Já Becker e Sun (Becker; Sun, 2015) aplicam uma estrutura análoga ao problema da mochila para otimizar decisões de seleção em *fantasy football* sob restrições orçamentárias.

Embora esses trabalhos avancem na formalização matemática da montagem de equipes, observa-se que a função objetivo permanece baseada em avaliações previamente definidas, pontuações atribuídas a priori ou estimativas paramétricas fixadas antes do processo de otimização. Não há, nesses estudos, a incorporação explícita de modelos preditivos de desempenho agregado aprendidos diretamente a partir de dados históricos como componente central da função objetivo. Dessa forma, permanece uma lacuna na literatura quanto à integração estruturada entre modelos de AM e problemas combinatórios de montagem de elenco.

4.2.1 Otimização Prescritiva e Problemas Combinatórios no Esporte

A transição de *predictive analytics* para *prescriptive analytics*, conforme discutido por (Bertsimas; Kallus, 2019), consiste na integração entre modelos preditivos e problemas de oti-

mização, permitindo que estimativas estatísticas sejam incorporadas diretamente na definição de políticas ótimas de decisão. Nesse paradigma, modelos de AM deixam de atuar apenas como ferramentas de previsão e passam a compor a função objetivo de problemas decisórios.

Além das abordagens clássicas de otimização, a literatura recente evidencia uma aproximação crescente entre PO e métodos de Inteligência Artificial (IA). Conforme discutido por (Chmait; Westerbeek, 2021), técnicas como aprendizado por reforço e algoritmos evolutivos vêm sendo empregadas em problemas decisórios no esporte, aproximando modelos de aprendizado e processos de otimização. Esse movimento reforça a convergência entre predição estatística e decisão prescritiva, abrindo espaço para estruturas integradas nas quais modelos de AM podem ser incorporados diretamente à função objetivo de problemas combinatórios.

No contexto esportivo, decisões estratégicas como montagem de elenco e planejamento competitivo podem ser formalizadas como problemas de otimização sob restrições orçamentárias e estruturais. Tais problemas frequentemente assumem estrutura combinatória análoga àquela observada em problemas clássicos de escalonamento esportivo (Kendall; Parkes; Spoerer, 2010; Kendall *et al.*, 2010), os quais envolvem múltiplos agentes, restrições e objetivos, sendo tradicionalmente abordados por meio de técnicas como programação inteira, programação por restrições e metaheurísticas. Tal complexidade justifica o uso de heurísticas e metaheurísticas para obtenção de soluções viáveis.

No futebol, essa formulação tem sido investigada sob diferentes perspectivas, sendo frequentemente referida como *Football Team Composition Problem* (FTCP), que consiste em determinar a melhor composição de elenco considerando simultaneamente restrições financeiras, regulatórias e táticas. Trabalhos recentes, como o de (Dantas; Ritt, 2025), propõem abordagens baseadas em programação inteira para maximizar métricas de habilidade dos jogadores, incorporando requisitos táticos e estruturais na modelagem do problema. Embora Dantas (2025) proponha um objetivo mais alinhado ao desempenho esportivo, sua abordagem ainda se fundamenta predominantemente em métricas estáticas de desempenho individual, sem modelar explicitamente o impacto prospectivo da composição do elenco sobre o desempenho competitivo coletivo da equipe. Nesse sentido, a metodologia aqui apresentada diferencia-se ao incorporar modelos preditivos na definição da função objetivo, permitindo capturar de forma mais direta os efeitos futuros das decisões de montagem de elenco.

Nesse contexto, o presente estudo insere-se nessa interseção entre AM e PO ao propor um modelo capaz de estimar a pontuação esperada de uma equipe em uma temporada a partir

do desempenho individual de seus jogadores na temporada anterior. Diferentemente das abordagens focadas na previsão de partidas isoladas ou na análise retrospectiva de determinantes agregados, o modelo desenvolvido busca capturar prospectivamente o impacto da composição do elenco sobre o desempenho competitivo. Posteriormente, essa estimativa é incorporada como função objetivo em um problema combinatório de montagem de elenco sob restrição orçamentária, aproximando predição estatística e decisão prescritiva no contexto do futebol profissional.

REFERÊNCIAS

ABIDIN, D. A case study on player selection and team formation in football with machine learning. **Turkish Journal of Electrical Engineering and Computer Sciences**, v. 29, n. 3, 2021. Disponível em: https://journals.tubitak.gov.tr/elektrik/vol29/iss3/23.

ALMULLA, J. *et al.* Soccernet: A gated recurrent unit-based model to predict soccer match winners. **PLoS ONE**, ago. 2023. Disponível em: https://doi.org/10.1371/journal.pone.0288933.

AWADALLAH, A. A.; KHANDELWAL, R. Football match prediction using deep learning (recurrent neural network). 2020. CS230 Deep Learning Project. Disponível em: https://github.com/raghav68/CS230DLProject.

BABOOTA, R.; KAUR, H. Predictive analysis and modelling football results using machine learning approach for english premier league. **International Journal of Forecasting**, v. 35, n. 2, p. 741–755, 2019. Disponível em: https://doi.org/10.1016/j.ijforecast.2018.01.003.

BBC Sport. **Moises Caicedo transfer news: Chelsea agree £115m deal for Brighton midfielder**. 2023. Accessed: 28 Jan. 2026. Disponível em: https://www.bbc.com/sport/football/66491106.

BECKER, A.; SUN, X. A. An analytical approach for fantasy football draft and lineup management. **Journal of Quantitative Analysis in Sports**, De Gruyter, v. 11, n. 1, p. 13–27, 2015.

BERTSIMAS, D.; KALLUS, N. From predictive to prescriptive analytics. **Management Science**, INFORMS, v. 65, n. 3, p. 1025–1044, 2019.

BOON, B. H.; SIERKSMA, G. Team formation: Matching quality supply and quality demand. **European Journal of Operational Research**, Elsevier, v. 148, n. 1, p. 71–82, 2003.

BREFELD, U. *et al.* (Ed.). **Machine Learning and Data Mining for Sports Analytics**: 10th international workshop, mlsa 2023, turin, italy, september 18, 2023, revised selected papers. [*S.l.*]: Springer Nature Switzerland, 2024. v. 2035. (Communications in Computer and Information Science, v. 2035). ISBN 978-3-031-53832-2.

CARMICHAEL, F.; MCHALE, I.; THOMAS, D. Maintaining market position: Team performance, revenue and wage expenditure in the english premier league. **Bulletin of Economic Research**, v. 63, n. 4, 2011.

CHMAIT, N.; WESTERBEEK, H. Artificial intelligence and machine learning in sport research: An introduction for non-data scientists. **Frontiers in Sports and Active Living**, v. 3, p. 682287, 2021. Disponível em: https://doi.org/10.3389/fspor.2021.682287.

CLARKE, S. R.; NORMAN, J. M. When to rush a behind in australian rules football: A dynamic programming approach. **Journal of the Operational Research Society**, Palgrave Macmillan, v. 49, n. 5, p. 530–536, 1998.

CNN Brasil. **Moisés Caicedo no Chelsea: de desconhecido a jogador mais caro do futebol inglês**. 2023. Accessed: 28 Jan. 2026. Disponível em: https://www.cnnbrasil.com.br/esportes/futebol/futebol-internacional/moises-caicedo-no-chelsea-de-desconhecido-a-jogador-mais-caro-do-futebol-ingles/.

CORMEN, T. H. *et al.* **Introduction to Algorithms**. 3rd. ed. Cambridge, MA: The MIT Press, 2009. ISBN 978-0262033848.

CROES, G. A. A method for solving traveling-salesman problems. **Operations Research**, v. 6, n. 6, p. 791–812, 1958.

DANTAS, G. P.; RITT, M. Squad optimizing: Integrating tactics into football team composition problem via integer programming. **Environment Systems and Decisions**, Springer, v. 45, p. 36, 2025.

GENDREAU, M.; POTVIN, J.-Y. (Ed.). **Handbook of Metaheuristics**. 2. ed. New York, NY: Springer, 2010. (International Series in Operations Research & Management Science).

GERCHAK, Y. Operations research in sports. In: **Handbooks in Operations Research & Management Science**. [*S.l.*]: Elsevier Science B.V., 1994. v. 6, p. 507–512.

GLOBO Esporte. **Mercado de transferências bate recorde em 2023: R$ 36,6 bilhões**. 2023. Acesso em: 11 fev. 2025. Disponível em: https://ge.globo.com/futebol/futebol-internacional/noticia/2023/09/08/mercado-de-transferencias-bate-recorde-em-2023-r-366-bilhoes.ghtml.

GLOBO Esporte. **Janela da Série A bate marca de R$ 1 bilhão em reforços; veja quem mais gastou**. 2025. Acesso em: 24 fev. 2025. Disponível em: https://ge.globo.com/espiao-estatistico/noticia/2025/02/06/janela-da-serie-a-bate-marca-de-r-1-bilhao-em-reforcos-veja-quem-mais-gastou.ghtml.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016. ISBN 978-0-262-03561-3. Disponível em: https://www.deeplearningbook.org.

GRAHAM, I. **How to Win the Premier League**. [*S.l.*]: Century, 2024.

GUYON, I. *et al.* (Ed.). **Feature Extraction: Foundations and Applications**. Berlin Heidelberg: Springer, 2006. v. 207. (Studies in Fuzziness and Soft Computing, v. 207). ISBN 978-3-540-35487-1.

GéRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow**. 2nd. ed. [S.l.]: O'Reilly Media, 2019.

HEROLD, M.; MEMMERT, D.; PERL, J. Machine learning in men's professional football: Current applications and future directions for improving attacking play. **International Journal of Sports Science & Coaching**, SAGE Publications, v. 14, n. 6, p. 798–817, 2019.

HILLIER, F. S.; LIEBERMAN, G. J. **Introduction to Operations Research**. 7. ed. New York: McGraw-Hill, 2001. ISBN 978-0072416186.

HIROTSU, N.; WRIGHT, M. Using a markov process model of an association football match to determine the optimal timing of substitution and tactical decisions. **Journal of the Operational Research Society**, v. 53, p. 88–96, 2002.

HORVAT, T.; JOB, J. The use of machine learning in sport outcome prediction: A review. **WIREs Data Mining and Knowledge Discovery**, Wiley, v. 10, n. 6, p. e1382, 2020.

JORDAN, M. I.; MITCHELL, T. M. Machine learning: Trends, perspectives, and prospects. **Science**, v. 349, n. 6245, p. 255–260, 2015.

JOSEPH, A.; FENTON, N. E.; NEIL, M. Predicting football results using bayesian nets and other machine learning techniques. **Knowledge-Based Systems**, v. 19, 2006.

KELLEHER, J. D.; NAMEE, B. M.; D'ARCY, A. **Fundamentals of Machine Learning for Predictive Data Analytics: Algorithms, Worked Examples, and Case Studies**. Cambridge, MA: MIT Press, 2015. ISBN 978-0262029445.

KENDALL, G. *et al.* Scheduling in sports: An annotated bibliography. **Computers & Operations Research**, Elsevier, v. 37, n. 1, p. 1–19, 2010.

KENDALL, G.; PARKES, A.; SPOERER, K. A survey of np-complete scheduling problems. **Journal of Scheduling**, Springer, v. 13, n. 3, p. 257–276, 2010.

KITE, C. S.; NEVILL, A. The predictors and determinants of inter-seasonal success in a professional soccer team. **Journal of Human Kinetics**, v. 58, p. 157–167, 2017.

LAGO-BALLESTEROS, J.; LAGO-PEñAS, C. Performance in team sports: Identifying the keys to success in soccer. **Journal of Human Kinetics**, v. 25, p. 85–91, 2010.

LIU, H. *et al.* Feature selection: An ever evolving frontier in data mining. In: LAWRENCE, N. (Ed.). **JMLR: Workshop and Conference Proceedings - The Fourth Workshop on Feature Selection in Data Mining (FSDM 2010)**. [*S.l.*]: JMLR Workshop and Conference Proceedings, 2010. v. 10, p. 4–13.

MAHESH, B. Machine learning algorithms - a review. **International Journal of Science and Research (IJSR)**, v. 9, p. 381–386, jan. 2020. Disponível em: https://doi.org/10.21275/ART20203995.

MEDRI, W.; YOTSUMOTO, A. **Pesquisa Operacional na Tomada de Decisão**. [*S.l.: s.n.*], 2009.

MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. **Introduction to Linear Regression Analysis**. 5. ed. [*S.l.*]: Wiley, 2012.

OLLEY, J. **How Brighton's transfer mastery broke Premier League profit record**. ESPN, 2023. Acesso em: 11 fev. 2025. Disponível em: https://www.espn.com/soccer/story/_/id/40069726/how-brightons-transfer-mastery-broke-premier-league-profit-record.

PANTUSO, G. The football team composition problem: A stochastic programming approach. **Journal of Quantitative Analysis in Sports**, 2017.

QADER, M. A. *et al.* A methodology for football players selection problem based on multi-measurements criteria analysis. **Measurement**, v. 111, p. 38–50, 2017.

RIBEIRO, C. C.; URRUTIA, S. Heuristics for the mirrored traveling tournament problem. **European Journal of Operational Research**, Elsevier, v. 179, n. 3, p. 775–787, 2007.

RICO-GONZÁLEZ, M. *et al.* Machine learning application in soccer: a systematic review. **Biology of Sport**, Institute of Sport, v. 40, n. 1, p. 249–263, 2023.

RODRIGUES, F.; PINTO, A. Prediction of football match results with machine learning. **Procedia Computer Science**, v. 204, p. 463–470, jan. 2023. Disponível em: https://doi.org/10.1016/j.procs.2022.08.057.

TAVANA, M. *et al.* A fuzzy inference system with application to player selection and team formation in multi-player sports. **Sport Management Review**, v. 16, p. 97–110, 2013.

TOTTY, E. S.; OWENS, M. F. Salary caps and competitive balance in professional sports leagues. **Journal for Economic Educators**, v. 11, n. 2, p. 46–56, 2011.

WRIGHT, M. B. 50 years of or in sport. **Journal of the Operational Research Society**, Palgrave Macmillan, v. 60, n. S1, p. S161–S168, 2009.

ANEXOS

ANEXO A – LOREM IPSUM

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Vivamus semper, libero egestas pellentesque vulputate, velit felis commodo ante, vel bibendum velit turpis eu felis. Donec viverra quam nisi, vel tincidunt enim tristique interdum. Integer tincidunt a lectus vel porttitor. Nulla venenatis vitae enim ut semper. Nunc in sagittis massa, sit amet dapibus quam. Mauris cursus, ligula ac pretium imperdiet, lectus libero egestas mi, quis tristique leo urna nec erat. In vitae dui maximus, imperdiet massa euismod, auctor enim. Morbi urna odio, accumsan quis magna id, fringilla gravida purus. Aenean facilisis est nisi, nec porttitor purus ullamcorper ut. Proin ac risus congue, aliquet elit in, cursus est.

Vivamus lorem diam, molestie ut ultrices at, feugiat quis tortor. Mauris feugiat, augue at molestie malesuada, purus erat sagittis tellus, sit amet posuere lacus nisl non eros. Sed enim justo, sagittis id elementum quis, commodo ut nibh. Aenean mauris odio, efficitur vel purus sit amet, molestie pharetra arcu. Nunc vel eros sodales, aliquam diam eu, rutrum nisi. Morbi non scelerisque diam. Suspendisse sed dapibus mi, ut sagittis nunc. Praesent ornare, est in rutrum dapibus, tortor massa ornare dolor, at ullamcorper metus augue et ipsum. Sed ut nulla in dolor aliquet faucibus. Quisque rhoncus auctor tellus eu lobortis. Proin rhoncus nisi sit amet nibh tempor hendrerit.[1]

ANEXO B – LOREM IPSUM PT. 2

Aliquam tempus vehicula risus sit amet consequat. Donec eu mattis lorem. Maecenas tincidunt a massa ut ultricies. Ut id lacus sapien. Suspendisse ac auctor lectus. Maecenas vehicula sagittis metus, eget luctus ipsum imperdiet at. Nullam eu vestibulum leo. Fusce mauris ligula, consequat ut felis a, ornare bibendum quam. Maecenas posuere sem sit amet volutpat interdum. Integer aliquet bibendum luctus. Nulla non viverra eros. Fusce egestas scelerisque augue ac tempor.

[1] Lorem ipsum dolor sit amet, consectetur adipiscing elit. Vivamus semper, libero egestas pellentesque vulputate, velit felis commodo ante, vel bibendum velit turpis eu felis. Donec viverra quam nisi, vel tincidunt enim tristique interdum. Integer tincidunt a lectus vel porttitor.

Aliquam tempus vehicula risus sit amet consequat. Donec eu mattis lorem. Maecenas tincidunt a massa ut ultricies. Ut id lacus sapien. Suspendisse ac auctor lectus. Maecenas vehicula sagittis metus, eget luctus ipsum imperdiet at. Nullam eu vestibulum leo. Fusce mauris ligula, consequat ut felis a, ornare bibendum quam. Maecenas posuere sem sit amet volutpat interdum. Integer aliquet bibendum luctus. Nulla non viverra eros. Fusce egestas scelerisque augue ac tempor.

Aliquam tempus vehicula risus sit amet consequat. Donec eu mattis lorem. Maecenas tincidunt a massa ut ultricies. Ut id lacus sapien. Suspendisse ac auctor lectus. Maecenas vehicula sagittis metus, eget luctus ipsum imperdiet at. Nullam eu vestibulum leo. Fusce mauris ligula, consequat ut felis a, ornare bibendum quam. Maecenas posuere sem sit amet volutpat interdum. Integer aliquet bibendum luctus. Nulla non viverra eros. Fusce egestas scelerisque augue ac tempor.

APÊNDICES

APÊNDICE A – O QUE SÃO APÊNDICES

Um apêndice é um suporte elucidativo e ilustrativo do texto principal. Sua função é agrupar elementos que são úteis à compreensão do texto e que, no entanto, podem ser apresentados à parte sem prejuízo à compreensão. É útil para a apresentação de modelagens, diagramas extensos, listagens de código-fonte de programas e demais elementos que o autor julgar necessário à complementação do tema abordado no texto principal.