LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

Exame de Qualificação

LAVRAS – MG

2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
Exame de Qualificação

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
OPTIMIZATION OF SQUAD BUILDING IN FOOTBALL: MACHINE
LEARNING FOR REDUCING UNCERTAINTY IN PLAYER RECRUITMENT

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

APROVADA em 24 de Março de 2025.

Prof. Dr. Luiz Henrique de Campos Merschmann	UFLA
Prof. Dr. Júlio Cesar Alves	UFLA
Profa. Dra. Elaine Cecília Gatto	UFLA

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

RESUMO

O futebol, o esporte mais popular do mundo, é marcado por sua alta imprevisibilidade, o que dificulta a montagem de elencos, as escolhas táticas e a seleção de jogadores para cada partida. Este estudo explora o uso de técnicas de Aprendizado de Máquina (AM) e Pesquisa Operacional (PO) como ferramentas de apoio à tomada de decisão no contexto esportivo. O objetivo é desenvolver um modelo preditivo capaz de estimar o desempenho dos clubes com base em dados estatísticos individuais dos jogadores. A partir dessas previsões, são aplicados algoritmos de otimização para orientar estratégias de contratações, permitindo decisões mais eficientes e fundamentadas em dados. Essa abordagem visa reduzir a subjetividade nos processos de gestão esportiva, promovendo maior assertividade nas decisões de mercado por parte dos clubes.

Palavras-chave: Futebol. Aprendizado de Máquina. Elenco.

ABSTRACT

Football, the most popular sport in the world, is marked by a high degree of unpredictability, which makes squad building, tactical planning, and player selection particularly challenging. This study explores the use of Machine Learning (ML) and Operations Research (OR) techniques as decision-support tools in the sports context. The objective is to develop predictive models capable of estimating club performance based on individual player statistics. These predictions are then used as inputs for optimization algorithms aimed at guiding player recruitment strategies, enabling more efficient and data-driven decisions. This approach seeks to reduce subjectivity in sports management processes, promoting greater accuracy in market decisions and contributing to a more strategic, evidence-based decision-making framework within football clubs.

Keywords: Football. Machine Learning. Squad.

LISTA DE FIGURAS

Figura 4.1 – AD para Iris 28
Figura 4.2 – Dados da Wyndor Glass Co. 37
Figura 4.3 – Valores de (x_1, x_2) que maximizam $3x_1 + 5x_2$. 38
Figura 5.1 – Escolha do Número Ideal de Componentes do PCA 43
Figura 6.1 – Relação entre pontuações reais e previstas pelo modelo MLP na Premier League. 53

SUMÁRIO

1 INTRODUÇÃO

Futebol é o esporte mais popular do mundo (**??**). Nas últimas décadas, sua evolução tecnológica e analíticatem sido notável, acompanhada por um crescimento expressivo nos lucros gerados pelas atividades esportivas (**??**). No entanto, o futebol é um esporte altamente imprevisível. Um exemplo notável dessa imprevisibilidade foi a surpreendente conquista da English Premier League (EPL) pelo Leicester City em 2016, um feito que surpreendeu especialistas e torcedores em todo o mundo (**??**).

Dada a relevância econômica e o impacto do futebol como forma de entretenimento, pesquisadores da academia e profissionais da indústria têm se dedicado ao desafio de prever seus resultados (**??**). O crescimento do mercado de apostas reflete essa busca, impulsionando também os lucros da indústria de prognósticos esportivos (**??**). Para se ter uma noção da magnitude econômica do futebol, entre 1º de junho e 1º de setembro de 2023, as transferências de jogadores movimentaram R$ 36,6 bilhões, conforme relatório divulgado pela Federação Internacional de Futebol (FIFA) (**??**). No Brasil, em 2025, a janela de transferências da Série A brasileira bateu a marca de R$ 1 bilhão em movimentações financeiras (**??**).

No campo da Ciência da Computação, diversos estudos têm explorado técnicas de análise de dados e estatística com o objetivo de modelar padrões e realizar predições em ambientes complexos. Um exemplo relevante é o estudo de Joseph, Fenton e Neil (2006), que investigou o uso de redes Bayesianas e outras técnicas de Aprendizado de Máquinas (AM) para prever resultados do Tottenham Hotspur entre 1995 e 1997. Outro caso notável de aplicação de dados no futebol envolve o *Brighton & Hove Albion*, clube inglês que, sob a gestão de Tony Bloom, implementou uma estratégia fortemente orientada por análises estatísticas para recrutamento e tomada de decisões. Essa filosofia refletiu-se diretamente na política de transferências do clube, com a identificação sistemática de atletas subvalorizados no mercado. Entre os exemplos mais emblemáticos está Moisés Caicedo, contra-

tado junto ao Independiente Del Valle em 2021 por cerca de £4,5 milhões e negociado com o Chelsea em 2023 por valores próximos a 115 milhões €, tornando-se uma das maiores vendas da história da EPL (**????**). O mesmo caso de altos lucros em revendas se aplica a outros jogadores, como Alexis Mac Allister e Marc Cucurella, abordagem que permitiu que o *Brighton* se consolidasse como um dos clubes mais eficientes do mercado de transferências da EPL, reinvestindo os recursos obtidos e mantendo a competitividade sustentável na elite do futebol inglês (**??**).

Na literatura acadêmica, observa-se que a maioria dos trabalhos envolvendo AM no futebol concentra-se na previsão de resultados de partidas, probabilidades de vitória ou otimização de ganhos no contexto de apostas esportivas. Em contraste, poucos estudos direcionam esforços à construção e otimização de elencos com foco na avaliação e seleção de jogadores (**??**). Essa lacuna é particularmente relevante, uma vez que a escolha de um atleta para compor um elenco envolve a análise simultânea de múltiplos parâmetros técnicos, físicos e mentais, além de fatores contextuais como estilo de jogo da equipe, liga disputada e momento da carreira do jogador (**??**). A natureza não determinística inerente ao futebol torna esse processo ainda mais desafiador, pois mesmo contratações que aparentam ser ideais sob múltiplos critérios podem não atingir o desempenho esperado.

Segundo Ian Graham (2024), uma transferência pode ser considerada um sucesso se o jogador iniciar 50% das partidas nas primeiras duas temporadas ("The 50% rule"). Considerando todas as transferências de mais de € 10 milhões que ocorreram na EPL entre os anos de 1992 e 2021, perto da metade (46%) não atingiram o critério estabelecido e, portanto, podem ser classificadas como falhas (**??**). Entre os principais fatores associados a esses insucessos, destacam-se:

1. O jogador atual é melhor que o novo jogador;

2. O jogador não é tão bom quanto se pensava inicialmente;

3. O jogador não se encaixa no estilo do time;

4. O jogador joga fora de posição;

5. O técnico não aprova o jogador;

6. O jogador tem problemas de condicionamento físico ou pessoais.

Nos últimos anos, o Aprendizado de Máquinas tem ampliado significativamente a capacidade de análise de dados esportivos, permitindo a identificação de padrões antes imperceptíveis em grandes volumes de informação. Técnicas avançadas vêm sendo aplicadas para estimar desde a probabilidade de vitória em uma partida até o impacto de decisões táticas ao longo de uma temporada. Entretanto, tais modelos não eliminam a incerteza inerente ao futebol, atuando como ferramentas de apoio à tomada de decisão humana, com o objetivo de reduzir riscos e embasar escolhas estratégicas.

Neste contexto, o presente trabalho investiga o uso de modelos preditivos para converter estatísticas históricas de desempenho individual em estimativas de desempenho esperado de jogadores quando inseridos em contextos específicos de equipe e temporada. Diferentemente de abordagens voltadas à previsão direta de resultados de partidas ou à avaliação de talento de forma isolada, a proposta concentra-se na análise contextualizada do jogador como parte de um sistema coletivo. As previsões geradas são utilizadas como subsídio em um processo de simulação e avaliação de cenários de contratação, visando apoiar decisões de mercado no futebol profissional de forma orientada por dados e alinhada a critérios de eficiência esportiva e financeira.

2 OBJETIVOS

2.1 Objetivo Geral

O presente estudo tem como objetivo principal desenvolver, avaliar e comparar modelos de Aprendizado de Máquinas (AM) capazes de prever o desempenho de equipes, entendido neste trabalho como a pontuação esperada ao longo da competição, a partir de dados estatísticos de desempenho individual de jogadores. Uma vez definido o modelo preditivo com melhor desempenho, este será utilizado como função objetivo em modelos simples de otimização, com o intuito de auxiliar o processo de tomada de decisão em contratações, buscando identificar soluções de mercado mais adequadas para a composição de elencos no futebol profissional.

2.2 Objetivos Específicos

Com o intuito de atingir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

1. Coletar, estruturar e processar dados históricos de jogadores e partidas, abrangendo múltiplas temporadas, garantindo a qualidade e a integridade das informações utilizadas no desenvolvimento dos modelos preditivos.

2. Desenvolver uma metodologia para quantificar o impacto individual dos jogadores, combinando estatísticas históricas ao longo das temporadas por meio de um sistema de ponderação temporal, priorizando desempenhos mais recentes.

3. Construir modelos de AM para prever o desempenho agregado de uma equipe em uma determinada temporada, considerando a composição do elenco e os dados históricos dos jogadores.

4. Validar a eficácia dos modelos preditivos, comparando as estimativas com os resultados reais de temporadas subsequentes, utilizando métricas esta-

tísticas como erro médio absoluto (MAE) e coeficiente de determinação (R^2).

5. Desenvolver modelos simples de otimização baseados no modelo de AM selecionado, visando a identificação de combinações de jogadores que maximizem o desempenho esperado da equipe sob restrições de mercado.

Ao integrar técnicas de AM e otimização, este estudo busca fornecer uma ferramenta analítica de apoio à decisão para a montagem de elencos no futebol profissional, contribuindo para práticas de gestão esportiva orientadas por dados.

3 REVISÃO DE LITERATURA

3.1 Aprendizado de Máquina no contexto esportivo

Em 2020, *Horvat & Job* apresentaram uma revisão abrangente sobre o uso de AM para prever resultados esportivos, com foco principal em esportes coletivos, especialmente o futebol. Os autores destacam que AM é particularmente adequado para essa tarefa, pois modalidades esportivas geram grandes volumes de dados estruturados e não estruturados (eventos, informações de *tracking*, histórico, probabilidade, entre outros) (**??**).

Conforme abordado anteriormente, a maioria dos estudos que empregam métodos preditivos no contexto esportivo concentra-se na predição de resultados de partidas. Tal predominância é reforçada pelo forte apelo mercadológico associado ao mercado de apostas esportivas, que incentiva o desenvolvimento de modelos capazes de antecipar vitórias, empates e derrotas com maior precisão (**??**). Ainda assim, *Horvat &Job* observam que a predominância desse tipo de estudo não se explica apenas por fatores externos, mas também pela própria natureza técnica do problema, que se ajusta bem aos algoritmos mais utilizados em AM e à disponibilidade de dados históricos amplamente registrados no futebol.

No artigo de revisão de literatura publicado por *Horvat & Job*, os autores destacam que diferentes algoritmos supervisionados têm sido empregados em estudos anteriores, entre eles regressão logística, *Support Vector Machine* (SVM), *Random Forest* e redes neurais. Segundo os autores, modelos que integram múltiplas fontes de informação — como estatísticas tradicionais, indicadores derivados e dados contextuais — tendem a alcançar resultados superiores. Os autores também ressaltam que a tarefa permanece desafiadora, em especial devido à natureza estocástica do futebol. Outro fator limitante é a ausência de padronização entre as bases de dados utilizadas nos diferentes estudos (**??**). Nos últimos anos, a geração de dados aumentou significativamente com a maior disponibilidade de *big*

data esportiva, impulsionada pela expansão de sistemas de *tracking* e por bancos estruturados como *Opta* e *StatsBomb* (**??**).

De forma complementar ao panorama apresentado por *Horvat & Job* (2020), o estudo sistemático conduzido por *Rico-González et al.* (2023) identifica que AM vem sendo empregado no futebol em uma variedade crescente de tarefas, incluindo análise de desempenho físico, detecção de padrões táticos, avaliação de risco de lesões, classificação de ações de jogo e modelagem espacial por meio de dados de *tracking*. Assim como *Horvat & Job*, os autores apontam para a evolução recente da disponibilidade de dados, fator que tem impulsionado abordagens cada vez mais complexas, como redes neurais profundas, modelos probabilísticos e métodos baseados em séries temporais.

A partir desse panorama fornecido pelas revisões de literatura mais recentes, diversos estudos empíricos têm explorado aplicações específicas de AM no futebol, variando quanto ao tipo de dado empregado, ao período analisado e ao objetivo da modelagem. A literatura aplicada pode ser organizada em diferentes eixos temáticos, sendo um dos mais tradicionais a previsão de resultados de partidas.

3.1.1 Previsão de resultados de partidas

Como discutido anteriormente, modelos de previsão de resultados constituem uma das áreas mais tradicionais do uso de AM no futebol. Os estudos variam quanto ao tipo de dado utilizado, à complexidade dos modelos e ao período analisado, mas compartilham o objetivo de estimar probabilidades de vitória, empate ou derrota.

No ano de 2006, *Joseph, Fenton & Neil* utilizaram redes Bayesianas para prever resultados de partidas de futebol. O estudo foi baseado em dados do *Tottenham Hotspur Football Club* referentes às temporadas de 1995 a 1997. A principal dificuldade na construção do modelo foi a quantidade limitada de dados disponí-

veis, composta por apenas 76 partidas e um total de 30 atributos, sendo 28 jogadores, local das partidas e a qualidade dos adversários. Para lidar com mudanças no elenco ao longo das temporadas, os autores introduziram as variáveis "playing"e "not-playing", indicando a presença ou ausência dos jogadores em campo. Além das redes Bayesianas, os autores compararam seu desempenho com um modelo baseado em *K-Nearest Neighbors* (KNN) e uma árvore de decisão (*Decision Tree*) MC4. Os resultados indicaram que redes Bayesianas construídas com conhecimento especializado superam modelos puramente baseados em dados, especialmente em cenários onde a quantidade de informações disponíveis é reduzida.

Enquanto o estudo de *Joseph et al.* explora uma abordagem baseada em conhecimento especializado para lidar com bases reduzidas, pesquisas mais recentes passaram a empregar algoritmos de classificação aplicados a conjuntos de dados mais amplos e com maior variedade de atributos, como em *Baboota &Kaur* (2018). *Baboota & Kaur* (2018) investigaram a aplicação de técnicas de AM para prever resultados da EPL. Para tal tarefa, os autores também utilizaram dados de duas temporadas (2014-2015 e 2015-2016) realizando um estudo de classificação multiclasse, buscando prever vitória do time da casa, vitória do visitante e empate. As variáveis utilizadas pelos autores consistiam no desempenho recente do time, estatísticas de jogo (chutes no alvo, escanteios, posse de bola...), *rating* dos times (obtido com base no FIFA Index) e fator casa/fora, buscando avaliar o impacto do mando de campo. Cabe ressaltar que, ao longo do estudo, observaram que os atributos derivados de desempenho recente foram mais impactantes do que estatísticas isoladas. *Baboota & Kaur* (2018) testaram os algoritmos de RF, SVM, XGBoost e NB, obtendo um melhor desempenho na utilização do *Gradient Boost*. Mesmo obtendo bons resultados, o melhor modelo não superou as previsões das casas de apostas, uma vez que estas incorporam variáveis não observadas pelos modelos, como lesões e aspectos táticos.

Em termos de Aprendizado Profundo e Redes Neurais (RN), *Awadallah & Khandelwal* (2020) buscaram prever resultados de partidas de futebol (vitória do mandante, empate ou vitória do visitante) na EPL utilizando modelos de RNs profundas, comparando diferentes abordagens e analisando suas performances. Os autores partiram da ideia de que o futebol, embora seja altamente aleatório, contém padrões históricos detectáveis por meio de dados estatísticos. O estudo buscou verificar até que ponto modelos estatísticos conseguem capturar esses padrões e prever resultados de partidas. Para essa tarefa, foram analisadas 10 temporadas da EPL (2008–2019), com cerca de 4180 partidas e 78 colunas originais, reduzidas posteriormente a 24 *features*, que incluíam *Elo ratings*, taxas de vitórias, empates e derrotas, sequências de resultados recentes, entre outros (**??**). No estudo em questão, foram comparados modelos de Regressão Logística, *Random Forest*, Rede Neural Densa (DNN) e LSTM (RNN). Entre os métodos analisados, o LSTM foi o mais promissor, alcançando aproximadamente **58% de acurácia de teste**, mas todos os modelos apresentaram vieses e limitações de generalização.

3.1.2 Análise de desempenho técnico e estatísticas derivadas

Em 2019, (**??**) investigou como o AM pode ser aplicado no futebol profissional masculino, especialmente buscando melhorar o desempenho ofensivo. Para isso, foram utilizados dados de passes, finalizações, dribles, entre outros. Modelos supervisionados foram empregados com o objetivo de prever gols, vitórias e classificar passes como bons ou ruins. Por outro lado, modelos não supervisionados foram utilizados para identificar padrões, formações e estilos de jogo. Entre os algoritmos aplicados, destacam-se redes neurais, árvores de decisão, k-means, regressão logística e redes neurais recorrentes (LSTM) (**??**). *Herold, Memmert e Perl* (2019) concluíram que padrões de passes podem ser detectados e classificados por meio dessas técnicas. Métricas como Gols Esperados (xG) e Oportunidade de Finalização Sem Bola (Off-Ball Scoring Opportunity) demonstraram potencial

para avaliar chances reais de gol. Além disso, o comportamento coletivo das equipes — como táticas e movimentações coordenadas — podem ser representadas matematicamente.

3.1.3 Modelagem tática e dados de tracking

Além das abordagens tradicionais baseadas em dados de eventos, estudos recentes destacam o valor do contexto espacial dos jogadores no momento de uma ação, buscando metrificar táticas. O livro *Machine Learning and Data Mining for Sports Analytics (MLSA 2023)* enfatiza esse aspecto ao mostrar que análises mais modernas atuam na integração entre dados de evento e dados de *tracking* espacial. O livro reforça ainda que modelos construídos exclusivamente com dados de evento enfrentam limitações estruturais, sobretudo pela ausência de informação sobre posicionamento defensivo e pressão exercida no lance (**??**). Outra contribuição relevante do livro em questão consiste na discussão sobre novas métricas probabilísticas como o *xCounter*, que quantifica o perigo imediato após a perda da bola (*turnover*). Estudos apresentados no volume mostram que, utilizando modelos de *XGBoost*, é possível identificar padrões que levam a contra-ataques perigosos com maior precisão, reforçando o potencial do AM na modelagem de transições rápidas, um aspecto crítico no futebol moderno (**??**).

3.1.4 Predição de lesões

Majumdar et al. (2022) discutem como o AM pode ser aplicado na compreensão e predição de lesões no futebol, explorando variáveis relacionadas à carga de treino e competição. Para tal foram utilizadas abordagens de regressão logística, árvores de decisão e k-vizinhos mais próximos (KNN), além de métodos mais complexos, como *Random Forest*, máquinas de vetor de suporte (SVM) e redes neurais artificiais. Apesar do potencial identificado, os autores destacam limitações relevantes, como o desbalanceamento das bases de dados, a falta de consenso

sobre quais variáveis são mais preditivas e a predominância de estudos restritos a apenas uma temporada. O trabalho conclui que, com a inclusão de dados longitudinais, técnicas de balanceamento e o uso de abordagens de inteligência artificial explicável (*Explainable AI*), o AM pode oferecer novas perspectivas para reduzir riscos de lesão e otimizar o processo de treinamento no futebol.

3.1.5 Panorama nacional

Essa expansão do uso de AM no futebol não se limita ao cenário internacional. Iniciativas brasileiras têm desempenhado papel relevante na consolidação da área de sports analytics. Um exemplo é o Sports Analytics Lab (SALab), vinculado ao Departamento de Ciência da Computação da UFMG, que desenvolve pesquisas aplicadas em ciência de dados no esporte e promove eventos de divulgação científica, como o Football Analytics Modelling & Experience (FAME). Esses eventos reúnem pesquisadores, profissionais de clubes e estudantes, fomentando discussões sobre métodos modernos de análise de desempenho, modelagem tática, uso de dados de *tracking* e aplicações de AM no futebol. A existência de iniciativas como o SALab e o FAME evidencia que o campo de análise quantitativa no esporte tem se expandido também no contexto brasileiro, acompanhando a evolução global descrita nas revisões de *Horvat &Job* (2020) e *Rico-González et al.* (2023).

3.2 Pesquisa Operacional no contexto esportivo

Pesquisa Operacional (PO) é um conjunto de métodos analíticos que auxiliam na tomada de decisões, utilizando modelos matemáticos, estatísticos e computacionais para otimizar processos (**??**). A PO tem sido amplamente utilizada na resolução de problemas complexos de tomada de decisão em diversas áreas, incluindo esportes, logística, manufatura e gestão (**??**).

Segundo Gerchak (1994), a aplicação da PO, no contexto esportivo, abrange desde problemas estratégicos, como o gerenciamento de equipes, até a análise de táticas e logística operacional. Entre as principais técnicas utilizadas na PO, destacam-se:

1. **Programação Linear**: Utilizada para otimização de recursos e eficiência em processos (**??**);

2. **Programação Dinâmica (PD)**: Aplicada em decisões sequenciais, como substituições de jogadores ou estratégias de jogo (**??**);

3. **Processos de Markov**: Modelagem probabilística utilizada para tomada de decisões de forma estratégica no futebol, bem como substituições e alterações táticas (**??**).

A PO tem sido empregada em análises de estratégias esportivas, auxiliando na tomada de decisão para melhora de perfomance e otimização de resultados. Um exemplo disso é o estudo do melhor momento para realizar substituição de jogadores em uma partida de futebol, aplicando modelos de Markov e PD na busca por maximizar o desempenho do time (**??**).

Outro exemplo consiste na técnica de *"rushing behind"* do futebol australiano analisada por Clarke & Norman (1998), na qual foi demonstrado como a PD pode ser aplicada para decidir quando é vantajoso conceder um ponto ao adversário para obter uma melhor posição em campo.

O campo da PO segue em constante evolução, especialmente com o avanço da ciência de dados e de ML. A integração de *Big Data* e Inteligência Artificial (IA) tem permitido uma análise mais profunda dos eventos esportivos, potencializando as tomadas de decisão orientadas a dados.

A crescente adoção de IA e AM no contexto esportivo reforça a proximidade conceitual entre essas técnicas e a Pesquisa Operacional. Segundo (**??**), métodos de IA têm sido empregados não apenas para predição, mas também para

apoiar tomadas de decisão complexas, como planejamento tático, avaliação da eficácia de formações, escolha de ações sequenciais e otimização de estratégias. Abordagens como aprendizado por reforço, que busca maximizar recompensas acumuladas ao longo de uma sequência de decisões, e algoritmos evolutivos, que realizam busca e aprimoramento iterativo de soluções, aproximam-se diretamente de problemas tradicionalmente tratados pela PO, como alocação ótima de recursos, seleção estratégica de ações e resolução de problemas combinatórios. Dessa forma, a literatura recente evidencia que IA e ML têm atuado de maneira complementar à PO, expandindo a capacidade analítica e automatizando processos de otimização aplicados ao desempenho esportivo.

Além das abordagens clássicas apresentadas, a Pesquisa Operacional também contempla técnicas heurísticas e metaheurísticas voltadas à resolução de problemas combinatórios de grande porte, especialmente quando métodos exatos se tornam computacionalmente inviáveis. Essa perspectiva será explorada na seção seguinte.

3.3 Otimização Prescritiva e Problemas Combinatórios no Esporte

O avanço recente da ciência de dados tem ampliado o papel dos modelos preditivos no suporte à tomada de decisão. Entretanto, previsões isoladas não são suficientes para orientar escolhas estratégicas. Segundo (**??**), a transição de *predictive analytics* para *prescriptive analytics* consiste na integração entre modelos preditivos e problemas de otimização, permitindo que estimativas estatísticas sejam incorporadas diretamente na definição de políticas ótimas de decisão. Nesse paradigma, modelos de AM deixam de atuar apenas como ferramentas de previsão e passam a compor a função objetivo de problemas decisórios, aproximando análise estatística e otimização operacional.

No contexto esportivo, diversas decisões estratégicas — como montagem de elenco, definição de escalações e planejamento competitivo — podem ser for-

malizadas como problemas de otimização sob restrições orçamentárias e estruturais. Tais problemas frequentemente apresentam natureza combinatória e elevada complexidade computacional. Conforme evidenciado por (**??**), problemas esportivos de escalonamento e organização competitiva são, em muitos casos, classificados como NP-difíceis, tornando inviável a aplicação de métodos exatos em instâncias de grande porte.

Diante desse cenário, a literatura de Pesquisa Operacional recorre amplamente ao uso de heurísticas e metaheurísticas, como busca local, simulated annealing e tabu search, para obtenção de soluções aproximadas de alta qualidade em tempo computacional razoável (**??**). Essas abordagens tornam-se particularmente adequadas quando a função objetivo é não linear ou depende de modelos complexos, como aqueles baseados em AM.

O presente estudo insere-se nessa interseção entre AM e PO, ao utilizar um modelo preditivo para estimar o desempenho esperado de jogadores e, posteriormente, empregar uma heurística de busca local para resolver o problema de montagem de elenco sob restrição orçamentária.

4 REFERENCIAL TEÓRICO

4.1 Aprendizado de Máquina

Aprendizado de Máquina (AM) é o estudo de algoritmos e modelos estatísticos empregados por sistemas computacionais para realizar tarefas específicas de forma autônoma. Essa abordagem permite que as máquinas aprendam a partir de dados e melhorem seu desempenho sem necessidade de reprogramação explícita (**??**). Segundo Geron (2019), AM pode ser descrito como a ciência (ou arte) de programar computadores para que aprendam com os dados.

Um exemplo clássico de aplicação de AM é o filtro de *spam*, que permite que o sistema identifique automaticamente emails indesejados, diferenciando-os de mensagens legítimas com base em padrões aprendidos (**??**).

Com a crescente disponibilidade de *datasets*, o uso de AM tem apresentado um notável crescimento (**??**). Esse avanço pode ser atribuído à maior disponibilidade de dados e ao aumento da capacidade computacional. A constante conexão das pessoas a dispositivos digitais gera volumes massivos de dados, enquanto tecnologias modernas permitem o processamento eficiente dessas grandes quantidades de informação (**??**).

Muitas indústrias têm adotado o AM com o objetivo de extrair insights relevantes de *databases*, facilitando o aprendizado a partir dos dados (**??**). Além disso, o AM tem sido amplamente aplicado em diversas áreas, incluindo reconhecimento facial, segmentação de imagens, detecção de câncer e previsão de classes e resultados, destacando-se também no contexto esportivo (**??**).

AM utiliza diferentes algoritmos para resolver problemas relacionados com dados. Cientistas de dados destacam que não há um único algoritmo universalmente superior para resolver todos os tipos de problemas (**??**). Esta seção apresenta uma breve descrição de alguns dos modelos mais comumente utilizados em AM para a resolução de problemas.

4.1.1 Árvore de Decisão (AD)

As Árvores de Decisão são algoritmos versáteis de AM que podem ser utilizados tanto para tarefas de classificação, quanto para tarefas de regressão (**??**). Esses algoritmos recebem um *input* de dados de treinamento (conjunto de atributos independentes + atributo classe) e retornam como saída uma árvore de decisão que permite classificar uma nova instância a partir de seus atributos independentes (**??**).

Um exemplo de AD pode ser visto na Figura **??**

Figura 4.1 – AD para Iris

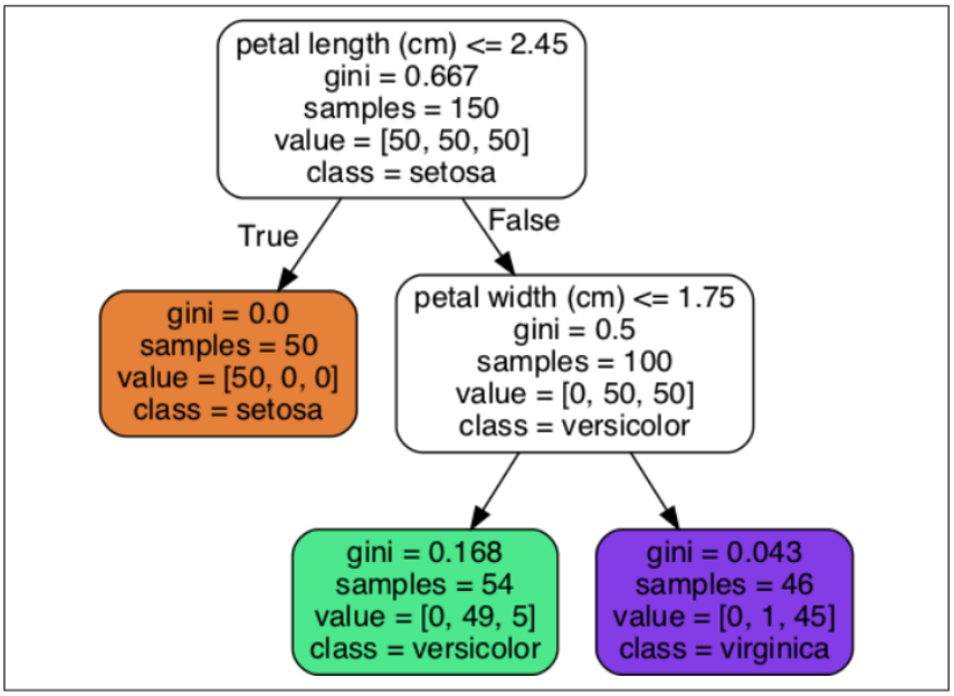

Fonte: Geron, 2019

Na Figura **??**, é possível observar uma árvore de decisão utilizada para classificar flores do conjunto de dados *Iris*. O nó raiz divide as amostras com base no comprimento da pétala (*petal length* ≤ 2.45), separando a classe *setosa* (pura, Gini = 0). As amostras restantes são subdivididas pelo critério de largura da pétala

(*petal width* ≤ 1.75), onde as classes *versicolor* e *virginica* são diferenciadas com alta precisão (Gini próximo de 0 nos nós finais). A árvore otimiza a classificação minimizando o índice de Gini em cada divisão (**??**).

4.1.2 Random Forest (RF)

O RF consiste em uma combinação de AD, geralmente treinadas por meio do método *bagging* (**??**). Diferente das ADs, RF utiliza uma randomização extra no crescimento das árvores. Ao invés de buscar a melhor *feature* para dividir o nó, utiliza-se da melhor dentro de um *subset* randômico. Nesse caso, busca-se reduzir a variância do modelo por meio da agregação de múltiplas árvores, mantendo um viés relativamente baixo quando comparado a modelos excessivamente regularizados.

4.1.3 Support Vector Machine (SVM)

O *Support Vector Machine* (SVM) é um algoritmo de AM supervisionado utilizado para tarefas de classificação e regressão. O seu princípio básico é encontrar um hiperplano ótimo que separe os dados em diferentes classes, maximizando a margem entre os pontos mais próximos das classes opostas (**??**).

O hiperplano utilizado pelo SVM consiste em uma superfície de decisão que separa os pontos de dados em classes distintas. Em um espaço 2D, ele é uma linha; em 3D, um plano e, em dimensões superiores, uma hiper-superfície (**??**)

Cabe ressaltar que nem sempre os dados são linearmente separáveis. Sendo assim, o SVM utiliza funções *kernel* para projetar os dados em um espaço de maior dimensão, onde a separação linear se torna possível (**??**). As principais funções *kernel* são:

1. **Linear**: Quando os dados já são linearmente separáveis.

2. **Polinomial**: Para capturar relações não lineares.

3. **RBF (Radial Basis Function - Gaussiana)**: Amplamente usada para capturar padrões complexos.

4. **Sigmoid**: Similar a redes neurais.

4.1.4 Gradient Boosting (XGBoost)

O *Gradient Boosting* é uma técnica de aprendizado baseada na combinação sequencial de modelos fracos, geralmente árvores de decisão rasas, com o objetivo de minimizar uma função de perda diferenciável (**??**). Diferentemente do *bagging*, no qual os modelos são treinados de forma independente, o *boosting* constrói cada novo preditor de maneira iterativa, ajustando-o aos resíduos (erros) cometidos pelo modelo anterior. Esse processo pode ser interpretado como uma otimização por gradiente no espaço funcional, na qual cada novo modelo aproxima a direção de maior redução da função de custo.

Formalmente, a cada iteração m, busca-se adicionar um novo modelo $h_m(x)$ de forma que o modelo final seja dado por:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x),$$

onde γ_m representa o passo ótimo na direção do novo preditor.

O *XGBoost* (*Extreme Gradient Boosting*) constitui uma implementação otimizada do *Gradient Boosting*, incorporando técnicas de regularização, paralelização e controle eficiente de memória (**??**). Além disso, sua função objetivo inclui termos de penalização que auxiliam na prevenção de *overfitting*, tornando-o especialmente eficaz em problemas de alta dimensionalidade e grandes volumes de dados.

4.1.5 Multilayer Perceptron (MLP)

O *Multilayer Perceptron* (MLP) é uma função matemática parametrizada que aprende a melhor forma de transformar um vetor de entrada $\mathbf{x}$ em uma saída $\mathbf{y}$. Assim, o MLP pode ser entendido como uma composição de várias funções aplicadas em sequência, formando um modelo de múltiplas camadas (**??**).

A arquitetura do MLP segue uma lógica de entrada $\rightarrow$ camadas ocultas $\rightarrow$ saída, utilizando uma função de ativação $g(\cdot)$ para introduzir não linearidade em cada camada. Essa relação é expressa por:

$$h^{(l)} = g\left(W^{(l)}h^{(l-1)} + b^{(l)}\right),$$

onde $W^{(l)}$ e $b^{(l)}$ representam, respectivamente, a matriz de pesos e o vetor de vieses da camada l (**??**).

A introdução da função não linear $g(\cdot)$ é essencial, pois permite que o MLP aprenda relações complexas entre as variáveis de entrada e saída. Sem ela, o modelo se reduziria a uma simples combinação linear, incapaz de representar funções não lineares (**??**).

4.1.6 Generalização, Viés e Variância

Um dos principais desafios em AM é garantir que o modelo apresente boa capacidade de generalização, isto é, desempenho satisfatório em dados não utilizados durante o treinamento (**??**).

Modelos excessivamente complexos podem se ajustar não apenas aos padrões relevantes, mas também ao ruído presente no conjunto de treinamento, fenômeno conhecido como *overfitting*. Em contrapartida, modelos demasiadamente simples podem não capturar relações importantes nos dados, resultando em *underfitting*.

Esse comportamento está diretamente relacionado ao equilíbrio entre viés e variância. Modelos com alto viés tendem a apresentar subajuste, enquanto modelos com alta variância tornam-se excessivamente sensíveis às particularidades do conjunto de treinamento. Técnicas como validação cruzada, regularização e controle da complexidade do modelo são estratégias amplamente utilizadas para mitigar esses problemas (**??**).

4.1.7 Seleção de Atributos e Redução de Dimensionalidade

Em problemas com elevado número de variáveis explicativas, a presença de atributos redundantes ou irrelevantes pode impactar negativamente o desempenho dos modelos preditivos. A seleção de atributos busca identificar subconjuntos de variáveis que contribuam de forma significativa para a tarefa de aprendizagem (**??**).

Os métodos de seleção podem ser classificados em três categorias principais: filtros, que utilizam medidas estatísticas independentes do modelo; wrappers, que avaliam subconjuntos de atributos com base no desempenho de um algoritmo específico; e métodos embutidos, nos quais a seleção ocorre durante o próprio processo de treinamento (**??**).

Além da seleção direta de atributos, técnicas de redução de dimensionalidade, como a Análise de Componentes Principais (PCA), realizam uma transformação linear das variáveis originais em um novo conjunto de componentes ortogonais que preservam a maior parte da variância dos dados. Essa abordagem pode reduzir complexidade computacional e mitigar problemas de multicolinearidade. Cabe ressaltar que a PCA não consiste em um método de seleção de atributos, mas sim em uma técnica de extração de atributos, pois cria novas variáveis a partir de combinações lineares das variáveis originais (**??**).

As técnicas apresentadas nesta seção constituem a base teórica para os modelos preditivos empregados neste trabalho, sendo posteriormente integradas a métodos de otimização para apoio à tomada de decisão no contexto esportivo.

4.2 Pesquisa Operacional

Como tratado anteriormente, a área da PO consiste em um campo multidisciplinar que aplica modelos matemáticos, estatísticos e computacionais. PO vem sendo amplamente utilizada em diversas áreas organizacionais, tais como manufatura, transportes, construção civil, telecomunicações, planejamento financeiro, planos de saúde, serviço público, entre outros (**??**).

Problemas de montagem de elenco no futebol têm sido abordados na literatura sob a ótica da otimização matemática, incluindo formulações baseadas em programação estocástica e heurísticas (**??**).

Entre os principais métodos da PO, destacam-se a Programação Linear, a Programação Dinâmica e os Processos de Markov.

4.2.1 Algoritmo Guloso

Em problemas de otimização, um algoritmo é dito guloso quando o mesmo faz uma escolha localmente ótima, na esperança de que essa escolha leve a uma solução globalmente ótima (**??**). Diferentemente de abordagens exaustivas, algoritmos gulosos tomam decisões irrevogáveis a cada etapa, baseando-se apenas na informação disponível no momento da escolha. É importante destacar que, conforme ressaltado por (**??**), algoritmos gulosos não garantem, em geral, a obtenção de soluções globalmente ótimas.

Conforme discutido por (**??**), algoritmos gulosos podem ser formulados de maneira iterativa ou recursiva, sendo esta última caracterizada pela decomposição do problema em subproblemas menores. A cada chamada recursiva, uma

escolha localmente ótima é realizada, reduzindo o espaço de busca e permitindo a construção incremental de uma solução inicial factível.

No contexto deste trabalho, um algoritmo guloso é utilizado de forma recursiva com o objetivo de gerar uma solução inicial para o problema de otimização da montagem de elencos. Dado um time e um orçamento, a cada iteração, o jogador com menor minutagem do elenco é removido e substituído por candidatos externos. Para cada substituição possível, o modelo de AM é empregado como função objetivo, estimando a pontuação esperada do time resultante. A escolha gulosa consiste, portanto, em selecionar o(s) jogador(es) que cabem no orçamento do time e cuja inclusão maximiza a pontuação prevista, mantendo-se fixas as demais variáveis do elenco.

4.2.2 Algoritmo de Busca Local

A busca local é uma técnica heurística amplamente utilizada em problemas de otimização combinatória, cujo objetivo é aprimorar uma solução inicial factível por meio da exploração iterativa de sua vizinhança (**??**). Diferentemente de métodos exatos, a busca local não realiza uma exploração global do espaço de soluções, concentrando-se na melhoria incremental da solução corrente a partir de movimentos locais.

Conforme descrito por (**??**), um algoritmo de busca local é composto essencialmente por três elementos: a definição de uma vizinhança, um critério de aceitação de movimentos e uma condição de parada. A vizinhança determina o conjunto de soluções que podem ser alcançadas a partir da solução atual por meio de pequenas modificações estruturais, enquanto o critério de aceitação estabelece se uma solução vizinha deve ou não substituir a solução corrente. O processo é repetido iterativamente até que nenhuma melhoria adicional seja encontrada ou que um critério de parada seja satisfeito.

No problema abordado neste trabalho, a busca local é empregada para avaliar diferentes conjuntos de jogadores candidatos a contratação, respeitando uma restrição de orçamento. Cada solução é representada por um conjunto de jogadores de cardinalidade fixa, sendo a vizinhança definida por operações de substituição unitária. Em cada iteração, os jogadores do conjunto atual com menor minutagem são selecionados como candidatos à remoção e substituídos por jogadores externos ainda não selecionados, produzindo soluções vizinhas que preservam o tamanho do elenco. Cada solução vizinha gerada é avaliada por meio de uma função objetivo, implementada como um modelo de aprendizado de máquina, responsável por estimar a pontuação esperada do time na temporada considerada.

A restrição orçamentária é tratada como condição de factibilidade: soluções que excedem o orçamento estabelecido são descartadas durante o processo de busca. O critério de aceitação adotado é de melhoria estrita, isto é, uma solução vizinha é aceita apenas se apresentar valor superior da função objetivo em relação à solução corrente. O algoritmo é encerrado quando nenhuma substituição viável resulta em melhoria adicional, caracterizando a convergência para um ótimo local, conforme descrito em (**??**).

4.2.3 Programação Linear (PL)

A Programação Linear (PL) é considerada um dos mais importantes avanços científicos do meio do século 20. Essa ferramenta já foi responsável por economizar milhões de dólares para companhias e negócios ao redor do mundo (**??**).

PL utiliza funções lineares simples para buscar o resultado ótimo (**??**). Um exemplo clássico de PL apresentado por Hillier (2001) é o problema da empresa *Wyndor Glass Co.*.

4.2.3.1 *Wyndor Glass Co.*

A empresa *Wyndor Glass Co.* fabrica produtos de vidro de alta qualidade, incluindo janelas e portas de vidro. Possui três fábricas: a Fábrica 1, que produz molduras de alumínio e ferragens; a Fábrica 2, que fabrica molduras de madeira; e a Fábrica 3, responsável pela produção do vidro e pela montagem dos produtos. Devido a uma reestruturação, a empresa decidiu lançar dois novos produtos: o Produto 1, uma porta de vidro de 8 pés com moldura de alumínio, e o Produto 2, uma janela dupla de madeira de 4x6 pés. Cada produto exige capacidade produtiva específica das fábricas. O Produto 1 utiliza as Fábricas 1 e 3, enquanto o Produto 2 depende das Fábricas 2 e 3. O objetivo do problema é determinar a combinação ideal de produção desses produtos para maximizar o lucro total.

Definem-se as seguintes variáveis de decisão:

- x_1: número de lotes do Produto 1 a serem produzidos por semana.
- x_2: número de lotes do Produto 2 a serem produzidos por semana.

As restrições de capacidade produtiva devem ser respeitadas conforme os limites de produção de cada fábrica:

- **Fábrica 1**: Pode produzir no máximo 4 unidades do Produto 1 por semana:

$$x_1 \leq 4 \tag{4.1}$$

- **Fábrica 2**: Pode produzir no máximo 6 unidades do Produto 2 por semana:

$$x_2 \leq 6 \tag{4.2}$$

- **Fábrica 3**: Possui um limite semanal de 18 horas de produção:

$$3x_1 + 2x_2 \leq 18 \tag{4.3}$$

Os dados apresentados encontram-se ilustrados na Figura **??**

Figura 4.2 – Dados da Wyndor Glass Co.

Fábrica	**Tempo de Produção por lote (horas)**		**Tempo de produção disponível por semana (horas)**
	Produto		
	1	**2**	
1	1	0	4
2	0	2	12
3	3	2	18
Lucro por lote	€ 3.000,00	€ 5.000,00	

Fonte: Hillier, 2001 (Adaptado)

O objetivo é determinar a combinação de produção que maximize o lucro total. A equação que representa essa otimização é:

$$\max Z = 3.000x_1 + 5.000x_2 \tag{4.4}$$

onde cada lote do Produto 1 gera um lucro de \$ 3.000 e cada lote do Produto 2 gera um lucro de \$ 5.000. Além disso, deve-se garantir que os valores das variáveis de decisão sejam não negativos:

$$x_1 \geq 0, \quad x_2 \geq 0 \tag{4.5}$$

Uma maneira intuitiva de resolver esse problema é por meio da representação gráfica. As restrições são desenhadas no plano cartesiano, delimitando uma região viável. O ponto ótimo é encontrado na interseção das restrições ativas, onde a função objetivo atinge seu valor máximo dentro da região factível. Tal solução pode ser vista na Figura **??**.

Após essa análise, a solução ótima encontrada é:

Figura 4.3 – Valores de (x_1, x_2) que maximizam $3x_1 + 5x_2$.

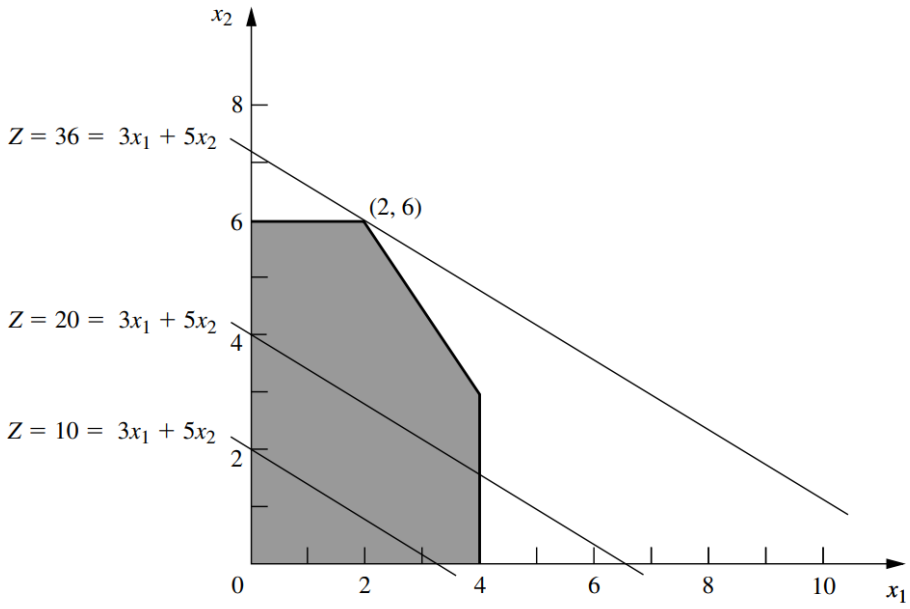

Fonte: Hillier, 2001

$$x_1 = 2, \quad x_2 = 6 \tag{4.6}$$

O lucro máximo alcançado pela empresa ao adotar essa estratégia de produção será:

$$Z^* = 3.000(2) + 5.000(6) = 36.000 \tag{4.7}$$

Portanto, a Wyndor Glass Co. deve produzir 2 lotes do Produto 1 e 6 lotes do Produto 2 por semana para maximizar seus lucros.

Embora a PL seja uma ferramenta poderosa para problemas de otimização linear, existem outras abordagens que lidam com problemas mais complexos. A Programação Dinâmica (PD), por exemplo, trata de decisões sequenciais, enquanto os Processos de Markov são amplamente utilizados para modelagem de processos estocásticos. Essas abordagens serão discutidas a seguir.

4.2.4 Programação Dinâmica (PD)

A PD é uma técnica de otimização recursiva aplicada a problemas que podem ser decompostos em subproblemas menores interdependentes (**??**). Esse método foi formalizado por Richard Bellman na década de 1950, se baseando no princípio da otimalidade, o qual postula que uma solução ótima para um problema contém soluções ótimas para seus subproblemas.

Bellman (1957) demonstrou que problemas de otimização sequencial podem ser resolvidos de maneira eficiente ao quebrá-los em estágios e resolver cada estágio de forma independente. A PD é amplamente utilizada em processos determinísticos e estocásticos, sendo a base para técnicas modernas como aprendizado por reforço. Além disso, essa técnica é muito utilizada na busca por soluções ótimas de problemas clássicos da computação, como o Problema da Mochila (**??**).

O desenvolvimento de um algoritmo de PD segue uma sequência de quatro etapas (**??**):

1. Caracterizar a estrutura de uma solução ótima.

2. Definir recursivamente o valor de uma solução ótima.

3. Calcular o valor de uma solução ótima, normalmente de baixo para cima.

4. Construir uma solução ótima com as informações calculadas.

4.2.5 Processos de Markov

A teoria dos processos de Markov é originária da década de 1950 com R. Bellman e L. Shapley. Essa teoria cresceu ao longo dos anos e encontrou aplicações em diversas áreas, como ciência da computação, engenharia, pesquisa operacional, biologia e economia (**??**).

Os Processos de Decisão de Markov (MDPs) consistem em um modelo matemático para tomada de decisão sequencial sob incerteza (**??**).

Formalmente, a MDP é definida por:

$$(E, A, Q, r)$$

onde:

- E é o espaço de estados, contendo todos os possíveis estados do sistema.
- A é o espaço de ações, representando todas as escolhas disponíveis ao tomador de decisão.
- $Q(x'|x,a)$ é a função de transição de probabilidade, que define a distribuição de probabilidades para o próximo estado x', dado o estado atual x e a ação tomada a.
- $r(x,a)$ é a função de recompensa, que determina o valor imediato recebido ao tomar a ação a no estado x.

O objetivo do MDP é encontrar uma política ótima π, que mapeia cada estado x para uma ação a, de forma a maximizar a soma esperada das recompensas futuras. A equação fundamental para esse cálculo é a Equação de Bellman:

$$V(x) = \max_{a \in A} \left\{ r(x,a) + \sum_{x'} Q(x'|x,a) V(x') \right\} \tag{4.8}$$

onde $V(x)$ representa o valor ótimo esperado de um estado x.

Para resolver um MDP, podem ser usados métodos como, por exemplo, PL, garantido a convergência para a política ótima sob certas condições.

5 METODOLOGIA

5.1 Coleta dos Dados

Com o intuito de coletar os dados, foi desenvolvido um algoritmo de *web scraping*, utilizando a biblioteca *Beautiful Soup* da linguagem *Python*. Essa biblioteca é amplamente empregada para extração e manipulação de informações a partir de páginas HTML e XML, permitindo a coleta automatizada e estruturada de grandes volumes de dados provenientes da web (**??**). O algoritmo implementado automatiza o acesso às páginas de estatísticas, realiza a extração das tabelas correspondentes a cada clube e temporada e armazena os dados de forma padronizada para posterior análise.

O site utilizado para a extração foi o FBref, uma ampla base de dados de estatísticas de futebol que disponibiliza dados detalhados de jogadores e equipes de diversas competições ao redor do mundo. O FBref se destaca por fornecer estatísticas avançadas, como gols esperados (xG), ações de pressão, passes progressivos e estatísticas defensivas, tornando-se uma fonte relevante para análises preditivas e modelagem estatística no contexto do futebol.

Com o objetivo de utilizar um volume de dados superior ao empregado por *Baboota & Kaur* (2018) e *Joseph, Fenton & Neil* (2006), bem como reduzir o risco de *overfitting*, foram coletados os dados de todos os jogadores da *Serie A* italiana e da *Premier League* que atuaram ao longo de cinco temporadas (2019-2020, 2020-2021, 2021-2022, 2022-2023 e 2023-2024), além das tabelas de resultados de todos os jogos disputados nesse mesmo período.

A utilização de duas ligas distintas neste estudo possui o papel metodológico deevitar a ocorrência de *data leakage* entre os conjuntos de treinamento, teste e validação dos modelos de aprendizado de máquina. Para isso, os dados de uma liga são utilizados exclusivamente na etapa de treinamento, enquanto os dados da outra liga são reservados para teste e validação. Essa estratégia asse-

gura que o modelo seja avaliado em um contexto completamente distinto daquele empregado no aprendizado, eliminando dependências estruturais entre amostras e proporcionando uma avaliação mais realista de sua capacidade de generalização.

Os dados obtidos foram armazenados no formato CSV, organizados em arquivos distintos para cada clube e temporada. Dessa forma, cada arquivo contém as estatísticas individuais dos jogadores de um determinado time em uma temporada específica, facilitando a organização, o pré-processamento e as etapas subsequentes da análise.

5.2 Pré-processamento dos Dados

5.2.1 Base de Dados dos Jogadores

As tabelas extraídas do site FBref para todos os times e temporadas foram estruturadas de forma idêntica, contendo 47 atributos relacionados à idade, posição, minutos jogados, bem como estatísticas ofensivas (gols, assistências, passes decisivos, entre outras) e defensivas (bloqueios, desarmes, erros graves, entre outras) de cada jogador. Esses dados foram carregados em diferentes *dataframes*, um para cada liga considerada, e posteriormente organizados por jogador, incluindo informações de clube, temporada e respectivos indicadores de desempenho. Ressalta-se que um mesmo atleta pode aparecer em diferentes temporadas e clubes dentro da organização adotada.

Após a etapa de organização, os dados estruturados foram armazenados em um repositório público na plataforma GitHub, com o objetivo de garantir reprodutibilidade, transparência metodológica e facilidade de acesso para futuras análises. O repositório utilizado neste estudo está disponível em <https://github.com/LunusMax/epl-seriea-data>.

Em seguida, os *dataframes* correspondentes a cada liga foram concatenados em um único conjunto, englobando todos os jogadores considerados no estudo, o qual foi utilizado nas etapas subsequentes da análise.

Considerando o elevado número de atributos e a possível correlação entre variáveis, foi aplicada uma técnica de redução de dimensionalidade com o objetivo de mitigar *overfitting* e melhorar a eficiência computacional dos modelos de AM. Para isso, utilizou-se o Principal Component Analysis (PCA), conforme descrito na subseção a seguir.

5.2.1.1 Principal Component Analysis (PCA)

Para determinar o número ideal de componentes principais que a serem utilizados no PCA, foi gerado um *Scree Plot*, conforme ilustrado na Figura **??**.

Figura 5.1 – Escolha do Número Ideal de Componentes do PCA

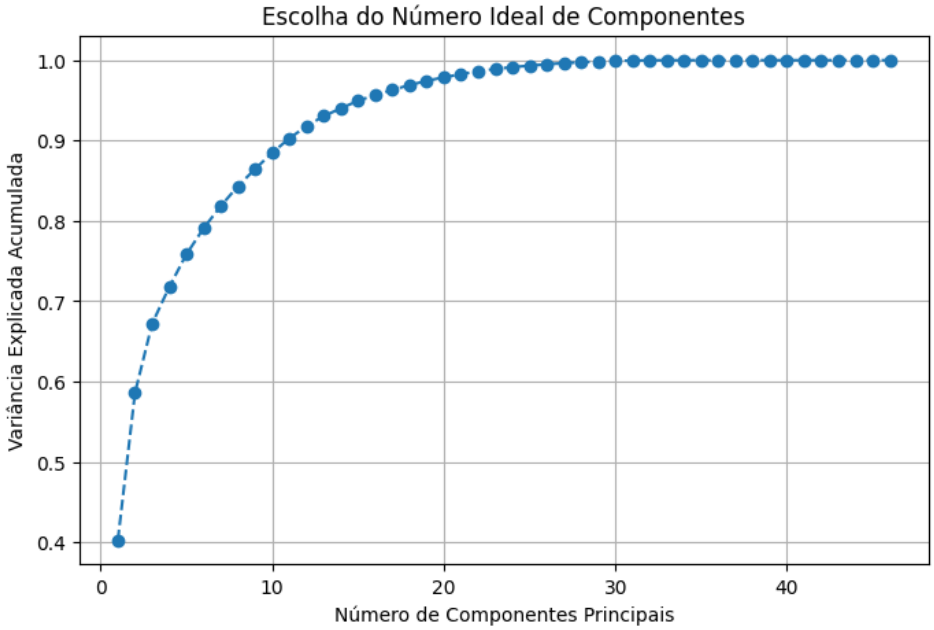

Fonte: do Autor, 2025

O gráfico apresenta a variância explicada acumulada em função do número de componentes principais, permitindo identificar o ponto de inflexão, ou seja, o momento em que a adição de novos componentes passa a contribuir de forma marginal para a variância total dos dados. O eixo x representa o número de componentes principais, enquanto o eixo y exibe a variância explicada acumulada.

A partir da Figura **??**, observa-se que, acima de 20 componentes principais, o ganho de informação adicional se torna insignificante. Com base nessa análise, foram realizados testes com diferentes quantidades de componentes, garantindo que sempre eram utilizados no mínimo 20 componentes, de forma a preservar a maior quantidade possível de variância dos dados sem comprometer a eficiência do modelo.

5.2.2 Base de Dados dos Jogos

Os dados dos jogos realizados entre as temporadas 2019-2020 e 2023-2024, obtidos na etapa de coleta, estavam organizados em 14 colunas. No entanto, grande parte dessas informações era irrelevante para a análise (por exemplo, horário e data das partidas, público, local e árbitro). Assim, para otimizar o conjunto de dados, foram removidos os atributos considerados ruído, mantendo-se apenas três elementos essenciais: time mandante, time visitante e resultado da partida.

A coluna de resultados foi transformada em valores numéricos por meio de um algoritmo em Python, em processo análogo a um *encoder*: vitória do mandante foi codificada como '1', vitória do visitante como '2' e empate como '0'.

Com base nessa codificação, percorreu-se a base atribuindo três pontos a cada vitória e um ponto a cada empate. O resultado desse processamento foi uma tabela organizada por temporada, contendo cada clube e a respectiva pontuação acumulada.

5.3 Treinamento do Modelo de AM

Os dados de pontuação dos clubes foram organizados por temporada, enquanto as estatísticas individuais dos jogadores corresponderam sempre à temporada anterior. Dessa forma, o modelo utiliza informações conhecidas de desempenho prévio para estimar a pontuação final do clube na temporada subsequente. Adicionalmente, a pontuação dos clubes na temporada anterior foi incorporada

como variável explicativa, de modo a capturar o histórico de desempenho recente da equipe.

O modelo de AM foi desenvolvido para prever a pontuação dos clubes ao longo das temporadas, com base no desempenho individual de seus jogadores. Para evitar vazamento de dados entre treinamento e teste, a base da Série A italiana foi utilizada no treinamento do modelo, enquanto a base da EPL foi destinada à etapa de teste.

5.3.1 Modelo de Aprendizado de Máquina

Para a etapa de previsão da pontuação dos clubes, foi implementado o modelo de MLP utilizando a biblioteca *Keras*. O modelo foi construído no formato *Sequential*, contendo três camadas densamente conectadas. A primeira camada recebe como entrada um vetor com dimensão igual ao número de atributos disponíveis, seguido por uma camada densa com 128 neurônios e função de ativação ReLU. Esta camada foi regularizada por meio de penalização L1, de forma a reduzir o risco de sobreajuste.

Em seguida, aplicou-se normalização em lote (*Batch Normalization*) e uma camada de *Dropout* com taxa de 60%, visando maior robustez e generalização. A segunda camada oculta é composta por 32 neurônios, também com ativação ReLU e regularização L1, seguida novamente por *Batch Normalization* e *Dropout* de 60%. Por fim, a camada de saída é formada por um único neurônio linear, responsável por produzir a previsão da pontuação final do clube na temporada.

A arquitetura do modelo pode ser resumida da seguinte forma:

- Camada de entrada: vetor de dimensão n (atributos do jogador e do clube).
- Primeira camada oculta: `Dense(128)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.

- Segunda camada oculta: `Dense(32)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.
- Camada de saída: `Dense(1)`, ativação linear.

O MLP foi escolhido como base para o modelo de previsão de pontuação no contexto do futebol por reunir propriedades teóricas e práticas que o tornam adequado para lidar com a natureza complexa e não linear dos dados esportivos. Entre as principais razões para essa escolha, destacam-se:

1. **Capacidade de representação universal** — Um MLP com pelo menos uma camada oculta e funções de ativação não lineares é capaz de aproximar qualquer função mensurável (**??**). No contexto do futebol, isso significa que o modelo pode aprender padrões não lineares entre variáveis de desempenho (como gols, desarmes, progressão). Assim, o MLP não depende de hipóteses rígidas sobre a forma das relações entre variáveis, sendo capaz de aprendê-las diretamente dos dados.

2. **Flexibilidade para entradas de alta dimensão** — De acordo com *Goodfellow et. al., 2016*, cada camada de uma rede *feedforward* aprende uma representação do vetor de entrada que torna mais fácil a predição da saída desejada. Essa característica confere ao MLP flexibilidade para lidar com conjuntos de dados de alta dimensionalidade, nos quais múltiplas variáveis interagem de forma não linear. Mesmo com a aplicação prévia da técnica de *Principal Component Analysis* (PCA), que reduz a dimensionalidade de 48 para 20 componentes principais, o problema ainda envolve um espaço vetorial de considerável complexidade. Nesse contexto, o MLP é capaz de explorar as relações não lineares entre os componentes principais,

aprendendo representações mais informativas que auxiliam na previsão de desempenho esportivo.

3. **Treinamento eficiente via retropropagação** — O algoritmo de *backpropagation*, apresentado em (**??**), permite o cálculo eficiente dos gradientes de erro e a atualização simultânea dos pesos da rede por meio de gradiente descendente. Isso viabiliza o treinamento em grandes bases de dados de futebol, reduz o tempo de convergência e possibilita otimizar métricas contínuas.

Além dessas vantagens teóricas, o MLP oferece um equilíbrio entre capacidade de generalização, interpretabilidade e eficiência computacional, características desejáveis em modelos aplicados ao futebol, onde os dados são heterogêneos, ruidosos e interdependentes.

5.4 Otimização

Uma vez identificado o modelo de ML com melhor capacidade de predizer a pontuação final dos times em uma liga a partir das informações estatísticas de seus elencos, inicia-se a segunda etapa do projeto, dedicada à busca de soluções capazes de otimizar esse desempenho. Nessa fase, o problema passa a ser tratado como um processo de otimização sob restrições, no qual diferentes composições de elenco são avaliadas de acordo com sua pontuação estimada pelo modelo de aprendizado de máquina.

5.4.1 Cálculo do Valor de Mercado Sintético

Para viabilizar o processo de otimização, torna-se necessário incorporar restrições financeiras que reflitam, ainda que de forma simplificada, as limitações orçamentárias enfrentadas por clubes de futebol em contextos reais. Nesse sentido,

foi definida uma métrica sintética de valor de mercado dos jogadores, construída a partir de dois fatores principais: idade e desempenho estatístico agregado.

A Equação **??** apresenta formalmente o cálculo adotado para essa métrica.

$$V_i = 1000 \cdot \left(1000 \cdot \max(0, 30 - I_i) + 10 \cdot \sum_{j=1}^{n} x_{ij} \right) \tag{5.1}$$

onde:

- V_i representa o valor de mercado sintético do jogador i;
- I_i corresponde à idade do jogador i;
- x_{ij} representa o valor da j-ésima estatística numérica associada ao jogador i;
- n é o número total de variáveis estatísticas consideradas.

O primeiro termo da equação corresponde a um fator etário, que atribui maior peso a jogadores mais jovens, considerando um limite superior de 30 anos. Jogadores com idade superior a esse limiar não recebem penalização adicional, evitando a atribuição de valores negativos. Essa escolha busca refletir uma característica recorrente do mercado do futebol, no qual atletas mais jovens tendem a apresentar maior potencial de valorização, longevidade esportiva e retorno econômico futuro.

O segundo termo da equação agrega o desempenho estatístico do jogador por meio da soma de suas variáveis numéricas, escalonada por um fator constante. Essa agregação tem como objetivo capturar, de forma simplificada, o impacto global do desempenho esportivo individual, sem privilegiar métricas específicas ou posições em campo.

Por fim, o fator multiplicativo externo é aplicado exclusivamente para reescalonamento da variável, de modo a produzir valores em uma ordem de grandeza mais próxima às estimativas observadas no mercado real. Esse reescalonamento

facilita tanto a interpretação dos valores obtidos quanto a utilização da métrica como restrição orçamentária nos modelos de otimização empregados na etapa subsequente.

Dessa forma, jogadores que combinam alto desempenho estatístico com menor idade tendem a apresentar valores de mercado sintético mais elevados, enquanto atletas mais velhos ou com desempenho inferior são associados a custos reduzidos, em consonância com evidências empíricas da literatura que apontam idade e desempenho como fatores centrais na formação do valor econômico de jogadores profissionais. (**????**) Ressalta-se que essa métrica não tem como objetivo reproduzir valores reais de mercado, mas sim fornecer uma função custo coerente e monotônica, adequada ao processo de otimização proposto.

5.4.2 Busca Local para Otimização do Elenco

O problema de montagem de elenco abordado neste trabalho pode ser caracterizado como um problema de otimização combinatória sob restrições, no qual se busca selecionar um subconjunto de jogadores que maximize a função objetivo — neste caso, a pontuação do time ao final do campeonato —, respeitando limitações orçamentárias e estruturais, conforme formalizado por (**??**).

6 RESULTADOS E DISCUSSÕES

6.1 Modelos de Aprendizado de Máquinas

O melhor modelo de AM desenvolvido neste estudo apresentou acurácia máxima de aproximadamente 60% na tarefa de prever a pontuação final de um time em sua liga nacional, utilizando como base os dados estatísticos de desempenho individual de seus jogadores na temporada anterior.

Para avaliar o desempenho dos diferentes algoritmos aplicados à tarefa de previsão, foram calculadas métricas amplamente utilizadas em problemas de regressão, incluindo o coeficiente de determinação (R^2), o erro absoluto médio (MAE), o erro quadrático médio (MSE), a raiz do erro quadrático médio (RMSE), o erro percentual absoluto médio (MAPE) e o tempo de processamento de cada modelo. A Tabela **??** apresenta um resumo comparativo dos resultados obtidos, permitindo analisar tanto a qualidade preditiva quanto o custo computacional de cada abordagem.

Tabela 6.1 – Comparação de desempenho entre os modelos de Machine Learning avaliados

Modelo	**R^2**	**MAE**	**MSE**	**RMSE**	**MAPE**	**Tempo (s)**
RL	0.41	11.48	191.78	13.85	0.2580	2.15
RF	0.28	12.05	234.05	15.30	0.2690	423.13
XGBoost	0.41	11.48	191.78	13.85	0.2580	2.86
MLP	0.48	11.08	170.42	13.05	0.2424	161.68

Fonte: Elaborado pelo autor.

Os resultados apresentados na Tabela **??** evidenciam um comportamento consistente entre os algoritmos avaliados, com desempenho moderado na tarefa de previsão da pontuação final dos times. Embora a acurácia máxima tenha alcançado aproximadamente 60%, observa-se que todos os modelos enfrentam limitações inerentes à natureza imprevisível, ruidosa e não linear do problema. A pontuação de um time ao longo de uma temporada é influenciada também por fato-

res não refletidos nas estatísticas individuais de jogadores, como variações táticas, mudanças de treinador, lesões, contexto competitivo e dinâmica coletiva, o que naturalmente reduz o teto preditivo esperável.

Entre as abordagens testadas, a Rede Neural Multicamadas (MLP) apresentou o melhor equilíbrio entre qualidade preditiva e estabilidade, alcançando o maior valor de R^2 (0,48) e os menores erros MAE, MSE, RMSE e MAPE. Esse resultado sugere que a arquitetura densa foi mais capaz de capturar as relações não lineares presentes nos componentes principais gerados pelo PCA, aproveitando estruturas de dependência que modelos lineares ou baseados em árvores não exploram de maneira tão eficaz.

O desempenho mais modesto dos modelos de *Random Forest* (RF) e *XGBoost* indica que, apesar de serem métodos robustos e amplamente utilizados em tarefas de AM, quando reduzidos por PCA, funcionaram de forma mais limitada. Além disso, o custo computacional do RF foi significativamente superior, tornando-o menos atrativo para cenários de larga escala ou simulações repetidas de montagem de elenco.

O modelo de Regressão Linear (RL) apresentou desempenho comparável ao *XGBoost*, demonstrando que uma parte da variabilidade explicável está capturada em relações aproximadamente lineares entre os componentes principais do PCA e a pontuação final dos times. No entanto, o ganho obtido pela MLP reforça que há padrões não lineares relevantes que justificam a adoção de modelos mais complexos.

6.1.1 Predição do Modelo MLP

Com o intuito de compreender a predição realizada pelo melhor modelo (MLP) foi realizada uma análise visual da relação entre as pontuações reais dos clubes da Premier League na temporada e as pontuações previstas pelo modelo.

A Figura **??** apresenta o gráfico de comparação entre as pontuações reais e previstas pelo modelo MLP.

Figura 6.1 – Relação entre pontuações reais e previstas pelo modelo MLP na Premier League.

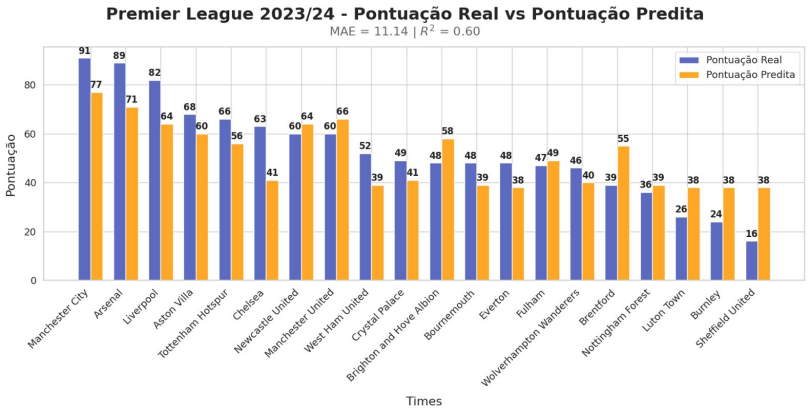

Os resultados apresentados na Figura **??** indicam que o modelo MLP apresenta maior precisão ao estimar as pontuações de clubes que terminaram a temporada com valores próximos da média da liga. Times posicionados no centro da distribuição como Fulham, Manchester United e Newcastle United tendem a ter suas pontuações previstas com menor erro, comportamento comum em modelos preditivos sob alta incerteza: quando os atributos disponíveis não capturam toda a variabilidade do fenômeno, as previsões convergem naturalmente para valores intermediários. Esse resultado alinha-se com a literatura clássica, segundo a qual modelos preditivos em ambientes de alta variabilidade, como é o caso do futebol, tendem a gerar funções de saída menos extremas e com menor amplitude, aproximando-se de valores centrais, devido a mecanismos de *shrinkage* e ao balanço entre viéses e variância discutidos por Bishop (**??**). Esse comportamento é análogo ao fenômeno estatístico conhecido como regressão à média.

Dessa forma, observa-se que o modelo MLP é capaz de capturar tendências gerais de desempenho dos clubes com base nas estatísticas individuais de seus jogadores, porém nota-se uma subestimação sistemática das equipes de desempe-

nho elevado, como Manchester City, Arsenal e Liverpool, e uma superestimação das equipes de baixo desempenho, como Sheffield United, Burnley e Luton Town.

6.2 Otimização de Montagem de Elenco

7 CONCLUSÃO

Teste