LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

Exame de Qualificação

LAVRAS – MG

2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
Exame de Qualificação

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
OPTIMIZATION OF SQUAD BUILDING IN FOOTBALL: MACHINE
LEARNING FOR REDUCING UNCERTAINTY IN PLAYER RECRUITMENT

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

APROVADA em 24 de Março de 2025.

Prof. Dr. Luiz Henrique de Campos Merschmann	UFLA
Prof. Dr. Júlio Cesar Alves	UFLA
Profa. Dra. Elaine Cecília Gatto	UFLA

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

RESUMO

O futebol, o esporte mais popular do mundo, é marcado por sua alta imprevisibilidade, o que dificulta a montagem de elencos, as escolhas táticas e a seleção de jogadores para cada partida. Este estudo explora o uso de técnicas de Aprendizado de Máquina (AM) e Pesquisa Operacional (PO) como ferramentas de apoio à tomada de decisão no contexto esportivo. O objetivo é desenvolver um modelo preditivo capazes de estimar o desempenho dos clubes com base em dados estatísticos individuais dos jogadores. A partir dessas previsões, são aplicados algoritmos de otimização para orientar estratégias de contratações, permitindo decisões mais eficientes e fundamentadas em dados. Essa abordagem visa reduzir a subjetividade nos processos de gestão esportiva, promovendo maior assertividade nas decisões de mercado por parte dos clubes.

Palavras-chave: Futebol. Aprendizado de Máquina. Elenco.

ABSTRACT

Football, the most popular sport in the world, is marked by a high degree of unpredictability, which makes squad building, tactical planning, and player selection particularly challenging. This study explores the use of Machine Learning (ML) and Operations Research (OR) techniques as decision-support tools in the sports context. The objective is to develop predictive models capable of estimating club performance based on individual player statistics. These predictions are then used as inputs for optimization algorithms aimed at guiding player recruitment strategies, enabling more efficient and data-driven decisions. This approach seeks to reduce subjectivity in sports management processes, promoting greater accuracy in market decisions and contributing to a more strategic, evidence-based decision-making framework within football clubs.

Keywords: Football. Machine Learning. Squad.

LISTA DE FIGURAS

SUMÁRIO

1 INTRODUÇÃO

Futebol é o esporte mais popular do mundo (**??**). Nas últimas décadas, sua evolução tem sido notável, acompanhada por um crescimento expressivo nos lucros gerados pelas atividades esportivas (**??**). No entanto, o futebol é um esporte altamente imprevisível. Um exemplo notável dessa imprevisibilidade foi a surpreendente conquista da English Premier League (EPL) pelo Leicester City em 2016, um feito que surpreendeu especialistas e torcedores em todo o mundo (**??**).

Dada a relevância econômica e o impacto do futebol como forma de entretenimento, pesquisadores da academia e profissionais da indústria têm se dedicado ao desafio de prever seus resultados (**??**). O crescimento do mercado de apostas reflete essa busca, impulsionando também os lucros da indústria de prognósticos esportivos (**??**). Para se ter uma noção da magnitude econômica do futebol, entre 1º de junho e 1º de setembro de 2023, as transferências de jogadores movimentaram R$ 36,6 bilhões, conforme relatório divulgado pela Federação Internacional de Futebol (FIFA) (**??**). No Brasil, em 2025, a janela de transferências da Série A brasileira bateu a marca de R$ 1 bilhão em movimentações financeiras (**??**).

No campo da Ciência da Computação, muitos estudos voltam-se para a análise de dados e estatística, explorando métodos para modelar padrões e fazer previsões. Um exemplo relevante é o estudo de Joseph, Fenton e Neil (2006), que investigou o uso de redes Bayesianas e outras técnicas de Machine Learning (ML) para prever resultados do Tottenham Hotspur entre 1995 e 1997. Outro caso notável de aplicação de dados no futebol envolve o *Brighton Hove Albion*, clube inglês que, sob a gestão de Tony Bloom, implementou uma estratégia baseada em análises estatísticas para recrutamento e tomada de decisões. Essa abordagem permitiu que o *Brighton* se tornasse um dos clubes mais eficientes do mercado de transferências da EPL, consolidando-se como uma equipe competitiva na elite do futebol inglês (**??**).

Na literatura, diversos estudos propõem a utilização de algoritmos de Machine Learning (ML) para prever resultados, com o objetivo de otimizar ganhos financeiros no contexto de apostas. No entanto, poucos trabalhos focam na construção de elencos com o objetivo de aprimorar a seleção de jogadores (**??**). A escolha de um jogador para compor um elenco envolve a análise de múltiplos parâmetros, incluindo características técnicas, físicas e mentais (**??**). Conforme discutido anteriormente, a imprevisibilidade inerente ao futebol torna essa tarefa ainda mais desafiadora. Mesmo uma contratação que atenda a todos os critérios desejados pode, ainda assim, não atingir o desempenho esperado.

Segundo Ian Graham (2024), uma transferência pode ser considerada um sucesso se o jogador iniciar 50% das partidas nas primeiras duas temporadas ("The 50% rule"). Considerando todas as transferências de mais de € 10 milhões que ocorreram na EPL entre os anos de 1992 e 2021, perto da metade (46%) não atingiram o critério estabelecido e, portanto, podem ser consideradas como falhas (**??**). Alguns dos principais motivos para essas falhas são:

1. O jogador atual é melhor que o novo jogador;
2. O jogador não é tão bom quanto se pensava inicialmente;
3. O jogador não se encaixa no estilo do time;
4. O jogador joga fora de posição;
5. O técnico não aprova o jogador;
6. O jogador tem problemas de condicionamento físico ou pessoais.

Nos últimos anos, o aprendizado de máquina tem revolucionado a maneira como os dados esportivos são analisados, permitindo que padrões antes imperceptíveis sejam descobertos a partir de grandes volumes de informação. Técnicas avançadas vêm sendo aplicadas para prever desde a probabilidade de vitória em

uma partida até o impacto de decisões táticas ao longo de um campeonato. Neste estudo, é explorado o uso de modelos preditivos com o intuito de converter estatísticas históricas de jogadores em insights estratégicos, auxiliando clubes na tomada de decisões, principalmente nas aquisições de jogadores no mercado de transferências.

2 REVISÃO DE LITERATURA

2.1 *Aprendizado de Máquina* no contexto esportivo

Conforme abordado anteriormente, a maioria dos estudos que aplicam previsões no contexto esportivo concentra-se na predição de resultados de partidas. Essa abordagem é amplamente influenciada pelo grande apelo mercadológico das apostas esportivas (**??**).

No ano de 2006, *Joseph, Fenton & Neil* utilizaram redes Bayesianas para prever resultados de partidas de futebol. O estudo foi baseado em dados do *Tottenham Hotspur Football Club* referentes às temporadas de 1995 a 1997. A principal dificuldade na construção do modelo foi a quantidade limitada de dados disponíveis, composta por apenas 76 partidas e um total de 30 atributos, sendo 28 jogadores, local das partidas e a qualidade dos adversários.

Para lidar com mudanças no elenco ao longo das temporadas, os autores introduziram as variáveis "playing"e "not-playing", indicando a presença ou ausência dos jogadores em campo. Além das redes Bayesianas, o estudo comparou seu desempenho com um modelo baseado em *K-Nearest Neighbors* (KNN) e uma árvore de decisão (*Decision Tree*) MC4.

Os resultados indicaram que redes Bayesianas construídas com conhecimento especializado superam modelos puramente baseados em dados, especialmente em cenários onde a quantidade de informações disponíveis é reduzida.

Ainda no contexto da previsão de resultados esportivos, *Baboota & Kaur* (2018) investigaram a aplicação de técnicas de AM para prever resultados da EPL. Para tal tarefa, os autores também utilizaram dados de duas temporadas (2014-2015 e 2015-2016) realizando um estudo de classificação multiclasse, buscando prever vitória do time da casa, vitória do visitante e empate.

As variáveis utilizadas pelos autores consistiam no desempenho recente do time, estatísticas de jogo (chutes no alvo, escanteios, posse de bola...), *rating*

dos times (obtido com base no FIFA Index) e fator casa/fora, buscando avaliar o impacto do mando de campo. Cabe ressaltar que, ao longo do estudo, descobriram que as ***features*** **derivadas de desempenho recente foram mais impactantes do que estatísticas isoladas**.

Baboota & Kaur (2018) testaram os algoritmos de RF, SVM, XGBoost e NB, obtendo um melhor desempenho na utilização do *Gradient Boost*. Mesmo obtendo bons resultados, o melhor modelo não superou previsões das casas de apostas, uma vez que as mesmas utilizam variáveis ocultas como lesões e táticas de jogo.

Em 2019, (**??**) investigou como o AM pode ser aplicado no futebol profissional masculino, especialmente buscando melhorar o desempenho ofensivo. Para isso, foram utilizados dados de passes, finalizações, dribles, entre outros.

Modelos supervisionados foram empregados com o objetivo de prever gols, vitórias e classificar passes como bons ou ruins. Por outro lado, modelos não supervisionados foram utilizados para identificar padrões, formações e estilos de jogo. Entre os algoritmos aplicados, destacam-se redes neurais, árvores de decisão, k-means, regressão logística e redes neurais recorrentes (LSTM). (**??**)

Herold, Memmert e Perl (2019) concluíram que padrões de passes podem ser detectados e classificados por meio dessas técnicas. Métricas como Gols Esperados (xG) e Oportunidade de Finalização Sem Bola (Off-Ball Scoring Opportunity) demonstraram potencial para avaliar chances reais de gol. Além disso, o comportamento coletivo das equipes — como táticas e movimentações coordenadas — podem ser representadas matematicamente.

Majumdar et al. (2022) discutem como o AM pode ser aplicado na compreensão e previsão de lesões no futebol, explorando variáveis relacionadas à carga de treino e competição. Para tal foram utilizadas abordagens de regressão logística, árvores de decisão e k-vizinhos mais próximos (KNN), além de métodos mais complexos, como *Random Forest*, máquinas de vetor de suporte (SVM) e redes

neurais artificiais. Apesar do potencial identificado, os autores destacam limitações relevantes, como o desbalanceamento das bases de dados, a falta de consenso sobre quais variáveis são mais preditivas e a predominância de estudos restritos a apenas uma temporada. O trabalho conclui que, com a inclusão de dados longitudinais, técnicas de balanceamento e o uso de abordagens de inteligência artificial explicável (*Explainable AI*), o AM pode oferecer novas perspectivas para reduzir riscos de lesão e otimizar o processo de treinamento no futebol.

Em termos de Aprendizado Profundo e Redes Neurais (RN), *Awadallah & Khandelwal* (2020) buscaram prever resultados de partidas de futebol (vitória do mandante, empate ou vitória do visitante) na EPL utilizando modelos de RNs profundas, comparando diferentes abordagens e analisando suas performances. Os autores partiram da ideia de que o futebol, embora seja altamente aleatório, contém padrões históricos detectáveis por meio de dados estatísticos. O estudo buscou verificar até que ponto modelos estatísticos conseguem capturar esses padrões e prever resultados de partidas.

Para essa tarefa, foram analisadas 10 temporadas da EPL (2008–2019), com cerca de 4180 partidas e 78 colunas originais, reduzidas posteriormente a 24 *features*, que incluíam *Elo ratings*, taxas de vitórias, empates e derrotas, sequências de resultados recentes, entre outros (**??**).

No estudo em questão, foram comparados modelos de Regressão Logística, *Random Forest*, Rede Neural Densa (DNN) e LSTM (RNN). Entre os métodos analisados, o LSTM foi o mais promissor, alcançando aproximadamente **58% de acurácia de teste**, mas todos os modelos apresentaram vieses e limitações de generalização.

2.2 Pesquisa Operacional no contexto esportivo

Pesquisa Operacional (PO) é um conjunto de métodos analíticos que auxiliam na tomada de decisões, utilizando modelos matemáticos, estatísticos e com-

putacionais para otimizar processos (**??**). A PO tem sido amplamente utilizada na resolução de problemas complexos de tomada de decisão em diversas áreas, incluindo esportes, logística, manufatura e gestão (**??**).

Segundo Gerchak (1994), a aplicação da PO, no contexto esportivo, abrange desde problemas estratégicos, como o gerenciamento de equipes, até a análise de táticas e logística operacional. Entre as principais técnicas utilizadas na PO, destacam-se:

1. **Programação Linear**: Utilizada para otimização de recursos e eficiência em processos (**??**);

2. **Programação Dinâmica (PD)**: Aplicada em decisões sequenciais, como substituições de jogadores ou estratégias de jogo (**??**);

3. **Processos de Markov**: Modelagem probabilística utilizada para tomada de decisões de forma estratégica no futebol, bem como substituições e alterações táticas (**??**).

A PO tem sido empregada em análises de estratégias esportivas, auxiliando na tomada de decisão para melhora de perfomance e otimização de resultados. Um exemplo disso é o estudo do melhor momento para realizar substituição de jogadores em uma partida de futebol, aplicando modelos de Markov e PD na busca por maximizar o desempenho do time (**??**).

Outro exemplo consiste na técnica de *"rushing behind"* do futebol australiano analisada por Clarke & Norman (1998), na qual foi demonstrado como a PD pode ser aplicada para decidir quando é vantajoso conceder um ponto ao adversário para obter uma melhor posição em campo.

O campo da PO segue em constante evolução, especialmente com o avanço da ciência de dados e de ML. A integração de *Big Data* e Inteligência Artificial (IA) têm permitido uma análise mais profunda dos eventos esportivos, potencializando as tomadas de decisão orientadas a dados.

3 REFERENCIAL TEÓRICO

3.1 Aprendizado de Máquina

Aprendizado de Máquina (AM) é o estudo de algoritmos e modelos estatísticos empregados por sistemas computacionais para realizar tarefas específicas de forma autônoma. Essa abordagem permite que as máquinas aprendam a partir de dados e melhorem seu desempenho sem necessidade de reprogramação explícita (**??**). Segundo Geron (2019), AM pode ser descrito como a ciência (ou arte) de programar computadores para que aprendam com os dados.

Um exemplo clássico de aplicação de AM é o filtro de *spam*, que permite que o sistema identifique automaticamente emails indesejados, diferenciando-os de mensagens legítimas com base em padrões aprendidos (**??**).

Com a crescente disponibilidade de *datasets*, o uso de Machine Learning (ML) tem apresentado um notável crescimento (**??**). Esse avanço pode ser atribuído à maior disponibilidade de dados e ao aumento da capacidade computacional. A constante conexão das pessoas a dispositivos digitais gera volumes massivos de dados, enquanto tecnologias modernas permitem o processamento eficiente dessas grandes quantidades de informação (**??**).

Muitas indústrias têm adotado o AM com o objetivo de extrair insights relevantes de *databases*, facilitando o aprendizado a partir dos dados (**??**). Além disso, o AM tem sido amplamente aplicado em diversas áreas, incluindo reconhecimento facial, segmentação de imagens, detecção de câncer e previsão de classes e resultados, destacando-se também no contexto esportivo (**??**).

AM utiliza diferentes algoritmos para resolver problemas relacionados com dados. Cientistas de dados destacam que não há um único algoritmo universalmente superior para resolver todos os tipos de problemas (**??**). Esta seção apresenta uma breve descrição de alguns dos modelos mais comumente utilizados em ML para a resolução de problemas.

3.1.1 Árvore de Decisão (AD)

As Árvores de Decisão são algoritmos versáteis de ML que podem ser utilizados tanto para tarefas de classificação, quanto para tarefas de regressão (**??**). Esses algoritmos recebem um *input* de dados de treinamento (conjunto de atributos independentes + atributo classe) e retorna como saída uma árvore de decisão que permite classificar uma nova instância a partir de seus atributos independentes (**??**).

Um exemplo de AD pode ser visto na Figura **??**

Figura 3.1 – AD para Iris

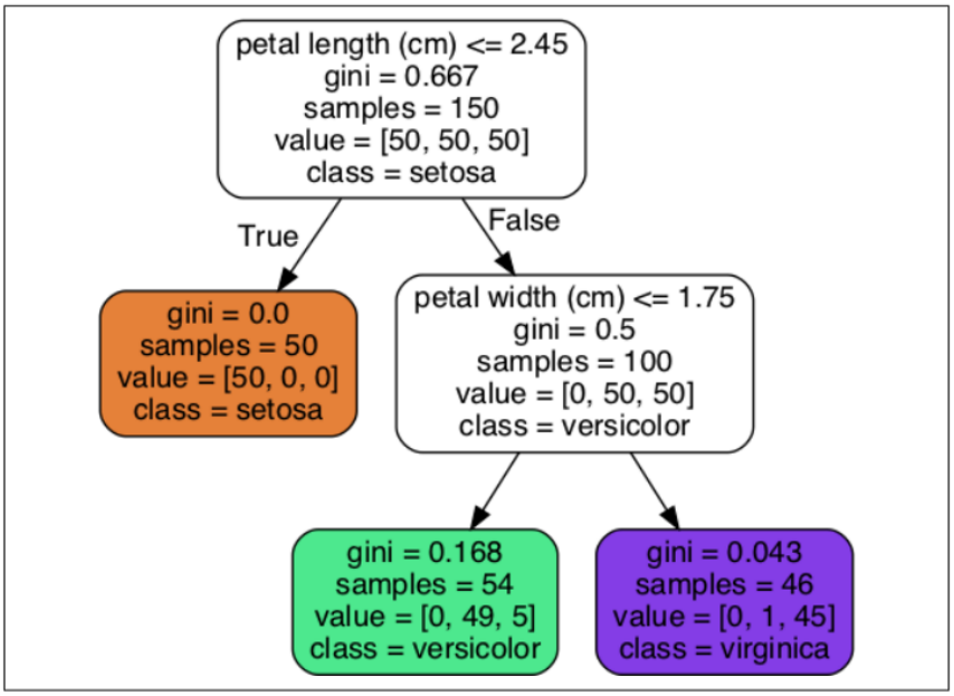

Fonte: Geron, 2019

Na Figura **??**, é possível observar uma árvore de decisão utilizada para classificar flores do conjunto de dados *Iris*. O nó raiz divide as amostras com base no comprimento da pétala (*petal length* ≤ 2.45), separando a classe *setosa* (pura, Gini = 0). As amostras restantes são subdivididas pelo critério de largura da pétala

(*petal width* ≤ 1.75), onde as classes *versicolor* e *virginica* são diferenciadas com alta precisão (Gini próximo de 0 nos nós finais). A árvore otimiza a classificação minimizando o índice de Gini em cada divisão (**??**).

3.1.2 Random Forest (RF)

O RF consiste em uma combinação de AD, geralmente treinadas por meio do método *bagging* (**??**). Diferente das ADs, RF utiliza uma randomização extra no crescimento das árvores. Ao invés de buscar a melhor *feature* para dividir o nó, utiliza-se da melhor dentro de um *subset* randômico. Nesse caso, troca-se um maior viés por uma menor variância (**??**).

3.1.3 Support Vector Machine (SVM)

O *Support Vector Machine* (SVM) é um algoritmo de ML supervisionado utilizado para tarefas de classificação e regressão. O seu princípio básico é encontrar um hiperplano ótimo que separe os dados em diferentes classes, maximizando a margem entre os pontos mais próximos das classes opostas (**??**).

O hiperplano utilizado pelo SVM consiste em uma superfície de decisão que separa os pontos de dados em classes distintas. Em um espaço 2D, ele é uma linha; em 3d, um plano e, em dimensões superiores, uma hiper-superfície (**??**)

Cabe ressaltar que nem sempre os dados são linearmente separáveis. Sendo assim, o SVM utiliza funções *kernel* para projetar os dados em um espaço de maior dimensão, onde a separação linear se torna possível (**??**). As principais funções *kernel* são:

1. **Linear**: Quando os dados já são linearmente separáveis.

2. **Polinomial**: Para capturar relações não lineares.

3. **RBF (Radial Basis Function - Gaussiana)**: Amplamente usada para capturar padrões complexos.

4. **Sigmoid**: Similar a redes neurais.

3.1.4 Gradient Boost (XGBoost)

O *Gradient Boosting* é uma técnica amplamente utilizada em competições de ciência de dados, como as promovidas pelo Kaggle. Ele funciona adicionando preditores ao modelo de forma sequencial, em que cada novo preditor busca corrigir os erros cometidos pelo anterior (GÉRON, 2019).

O *Gradient Boosting* é implementado em sua forma otimizada, na linguagem Python, a partir da biblioteca *XGBoost* (*Extreme Gradient Boosting*). Esse pacote foi desenvolvido de forma a mirar a velocidade e a eficiência de processamento, especialmente em competições e aplicações que lidam com grandes volumes de dados (GÉRON, 2019).

3.1.5 Multilayer Perceptron (MLP)

O *Multilayer Perceptron* (MLP) é uma função matemática parametrizada que aprende a melhor forma de transformar um vetor de entrada $\mathbf{x}$ em uma saída $\mathbf{y}$. Assim, o MLP pode ser entendido como uma composição de várias funções aplicadas em sequência, formando um modelo de múltiplas camadas (**??**).

A arquitetura do MLP segue uma lógica de entrada $\rightarrow$ camadas ocultas $\rightarrow$ saída, utilizando uma função de ativação $g(\cdot)$ para introduzir não linearidade em cada camada. Essa relação é expressa por:

$$h^{(l)} = g\left(W^{(l)}h^{(l-1)} + b^{(l)}\right),$$

onde $W^{(l)}$ e $b^{(l)}$ representam, respectivamente, a matriz de pesos e o vetor de vieses da camada l (**??**).

A introdução da função não linear $g(\cdot)$ é essencial, pois permite que o MLP aprenda relações complexas entre as variáveis de entrada e saída. Sem ela,

o modelo se reduziria a uma simples combinação linear, incapaz de representar funções não lineares (**??**).

3.2 Pesquisa Operacional

Como tratado anteriormente, a área da PO consiste em um campo multidisciplinar que aplica modelos matemáticos, estatísticos e computacionais. PO vem sendo amplamente utilizada em diversas áreas organizacionais, tais como manufatura, transportes, construção civil, telecomunicações, planejamento financeiro, planos de saúde, serviço público, entre outros (**??**).

Entre os principais métodos da PO, destacam-se a Programação Linear, a Programação Dinâmica e os Processos de Markov.

3.2.1 Programação Linear (PL)

A Programação Linear (PL) é considerada um dos mais importantes avanços científicos do meio do século 20. Essa ferramenta já foi responsável por economizar milhões de dólares para companhias e negócios ao redor do mundo (**??**).

PL utiliza funções lineares simples para buscar o resultado ótimo (**??**). Um exemplo clássico de PL apresentado por Hillier (2001) é o problema da empresa *Wyndor Glass Co.*.

3.2.1.1 *Wyndor Glass Co.*

A empresa *Wyndor Glass Co.* fabrica produtos de vidro de alta qualidade, incluindo janelas e portas de vidro. Possui três fábricas: a Fábrica 1, que produz molduras de alumínio e ferragens; a Fábrica 2, que fabrica molduras de madeira; e a Fábrica 3, responsável pela produção do vidro e pela montagem dos produtos. Devido a uma reestruturação, a empresa decidiu lançar dois novos produtos: o Produto 1, uma porta de vidro de 8 pés com moldura de alumínio, e o Produto 2, uma janela dupla de madeira de 4x6 pés. Cada produto exige capacidade produtiva

específica das fábricas. O Produto 1 utiliza as Fábricas 1 e 3, enquanto o Produto 2 depende das Fábricas 2 e 3. O objetivo do problema é determinar a combinação ideal de produção desses produtos para maximizar o lucro total.

Definem-se as seguintes variáveis de decisão:

- x_1: número de lotes do Produto 1 a serem produzidos por semana.
- x_2: número de lotes do Produto 2 a serem produzidos por semana.

As restrições de capacidade produtiva devem ser respeitadas conforme os limites de produção de cada fábrica:

- **Fábrica 1**: Pode produzir no máximo 4 unidades do Produto 1 por semana:

$$x_1 \leq 4 \tag{3.1}$$

- **Fábrica 2**: Pode produzir no máximo 6 unidades do Produto 2 por semana:

$$x_2 \leq 6 \tag{3.2}$$

- **Fábrica 3**: Possui um limite semanal de 18 horas de produção:

$$3x_1 + 2x_2 \leq 18 \tag{3.3}$$

Os dados apresentados encontram-se ilustrados na Figura **??**

O objetivo é determinar a combinação de produção que maximize o lucro total. A equação que representa essa otimização é:

$$\max Z = 3.000x_1 + 5.000x_2 \tag{3.4}$$

Figura 3.2 – Dados da Wyndor Glass Co.

Fábrica	**Tempo de Produção por lote (horas)**		**Tempo de produção disponível por semana (horas)**
	Produto		
	1	**2**	
1	1	0	4
2	0	2	12
3	3	2	18
Lucro por lote	€ 3.000,00	€ 5.000,00	

Fonte: Hillier, 2001 (Adaptado)

onde cada lote do Produto 1 gera um lucro de \$ 3.000 e cada lote do Produto 2 gera um lucro de \$ 5.000. Além disso, deve-se garantir que os valores das variáveis de decisão sejam não negativos:

$$x_1 \geq 0, \quad x_2 \geq 0 \tag{3.5}$$

Uma maneira intuitiva de resolver esse problema é por meio da representação gráfica. As restrições são desenhadas no plano cartesiano, delimitando uma região viável. O ponto ótimo é encontrado na interseção das restrições ativas, onde a função objetivo atinge seu valor máximo dentro da região factível. Tal solução pode ser vista na Figura **??**.

Após essa análise, a solução ótima encontrada é:

$$x_1 = 2, \quad x_2 = 6 \tag{3.6}$$

O lucro máximo alcançado pela empresa ao adotar essa estratégia de produção será:

Figura 3.3 – Valores de (x_1, x_2) que maximizam $3x_1 + 5x_2$.

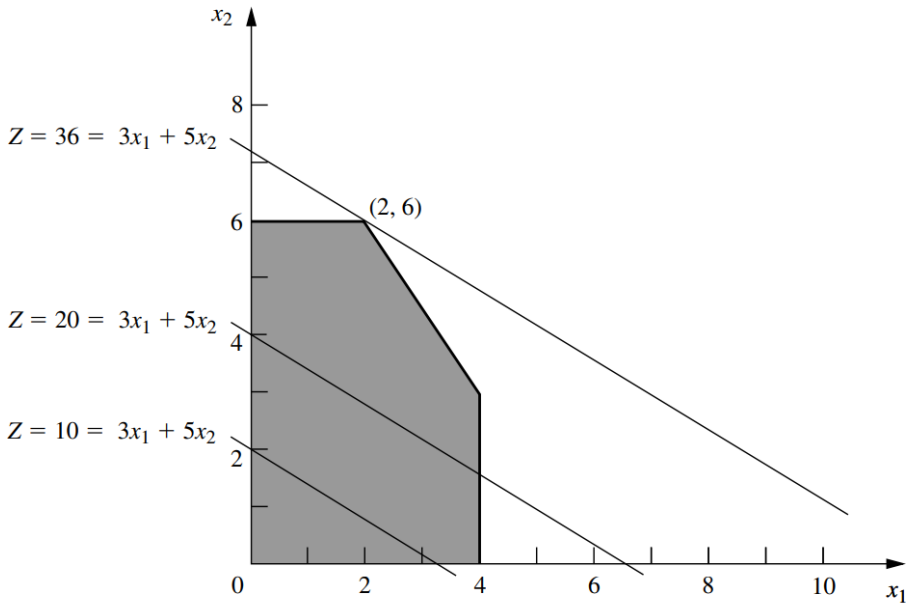

Fonte: Hillier, 2001

$$Z^* = 3.000(2) + 5.000(6) = 36.000 \tag{3.7}$$

Portanto, a Wyndor Glass Co. deve produzir 2 lotes do Produto 1 e 6 lotes do Produto 2 por semana para maximizar seus lucros.

Embora a PL seja uma ferramenta poderosa para problemas de otimização linear, existem outras abordagens que lidam com problemas mais complexos. A Programação Dinâmica (PD), por exemplo, trata de decisões sequenciais, enquanto os Processos de Markov são amplamente utilizados para modelagem de processos estocásticos. Essas abordagens serão discutidas a seguir.

3.2.2 Programação Dinâmica (PD)

A PD é uma técnica de otimização recursiva aplicada a problemas que podem ser decompostos em subproblemas menores interdependentes (**??**). Esse

método foi formalizado por Richard Bellman na década de 1950, se baseando no princípio da otimalidade, o qual postula que uma solução ótima para um problema contém soluções ótimas para seus subproblemas.

Bellman (1957) demonstrou que problemas de otimização sequencial podem ser resolvidos de maneira eficiente ao quebrá-los em estágios e resolver cada estágio de forma independente. A PD é amplamente utilizada em processos determinísticos e estocásticos, sendo a base para técnicas modernas como aprendizado por reforço. Além disso, essa técnica é muito utilizada na busca por soluções ótimas de problemas clássicos da computação, como o Problema da Mochila (**??**).

O desenvolvimento de um algoritmo de PD segue uma sequência de quatro etapas (**??**):

1. Caracterizar a estrutura de uma solução ótima.

2. Definir recursivamente o valor de uma solução ótima.

3. Calcular o valor de uma solução ótima, normalmente de baixo para cima.

4. Construir uma solução ótima com as informações calculadas.

3.2.3 Processos de Markov

A teoria dos processos de Markov é originária da década de 1950 com R. Bellman e L. Shapley. Essa teoria cresceu ao longo dos anos e encontrou aplicações em diversas áreas, como ciência da computação, engenharia, pesquisa operacional, biologia e economia (**??**).

Os Processos de Decisão de Markov (MDPs) consistem em um modelo matemático para tomada de decisão sequencial sob incerteza (**??**).

Formalmente, a MDP é definida por:

$$(E, A, Q, r)$$

onde:

- E é o espaço de estados, contendo todos os possíveis estados do sistema.
- A é o espaço de ações, representando todas as escolhas disponíveis ao tomador de decisão.
- $Q(x'|x,a)$ é a função de transição de probabilidade, que define a distribuição de probabilidades para o próximo estado x', dado o estado atual x e a ação tomada a.
- $r(x,a)$ é a função de recompensa, que determina o valor imediato recebido ao tomar a ação a no estado x.

O objetivo do MDP é encontrar uma política ótima π, que mapeia cada estado x para uma ação a, de forma a maximizar a soma esperada das recompensas futuras. A equação fundamental para esse cálculo é a Equação de Bellman:

$$V(x) = \max_{a \in A} \left\{ r(x,a) + \sum_{x'} Q(x'|x,a) V(x') \right\} \tag{3.8}$$

onde $V(x)$ representa o valor ótimo esperado de um estado x.

Para resolver um MDP, podem ser usados métodos como, por exemplo, PL, garantido a convergência para a política ótima sob certas condições.

4 OBJETIVOS

4.1 Objetivo Geral

O presente estudo tem como objetivo principal desenvolver e validar um modelo de AM capaz de prever o desempenho de equipes, partindo de dados estatísticos de desempenho individual de jogadores. Encontrado o modelo, o mesmo será utilizado como função objetivo em algoritmos de otimização, buscando auxiliar no processo de tomada de decisão de contratações por parte dos clubes.

4.2 Objetivos Específicos

Com o intuito de atingir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

1. Coletar, estruturar e processar os dados históricos dos jogadores e partidas, abrangendo múltiplas temporadas, garantindo a qualidade e integridade das informações utilizadas no modelo preditivo.

2. Desenvolver uma metodologia para quantificar o impacto individual dos jogadores, combinando dados estatísticos passados ao longo das temporadas por meio de um sistema de ponderação, priorizando desempenhos mais recentes.

3. Construir um modelo de AM para prever a pontuação de um time em uma determinada temporada, considerando a composição do elenco e os dados históricos dos jogadores.

4. Validar a eficácia do modelo preditivo, comparando as estimativas com os resultados reais de temporadas subsequentes, utilizando métricas estatísticas como erro médio absoluto (MAE) e coeficiente de determinação (R^2).

5. Desenvolver algoritmos de otimização com base no modelo de AM.

Ao combinar aprendizado de máquina e otimização, este estudo busca fornecer uma ferramenta analítica robusta para auxiliar na montagem de elencos no futebol, contribuindo para a evolução da gestão esportiva baseada em dados.

5 METODOLOGIA

5.1 Coleta dos Dados

Com o intuito de coletar os dados, foi desenvolvido um algoritmo de *web scraping*, utilizando a biblioteca *Beautiful Soup* da linguagem *Python*. Essa biblioteca é amplamente utilizada para extração e manipulação de dados a partir de páginas HTML e XML (**??**).

O site utilizado para extração foi o FBref, uma ampla *database* de estatísticas de futebol que contém dados detalhados de jogadores e equipes de diferentes competições ao redor do mundo. O FBref se destaca por disponibilizar estatísticas avançadas, como *Expected Goals (XG)*, pressões, passes progressivos e estatísticas defensivas, tornando-se uma fonte valiosa para análises preditivas e modelagem estatística no futebol.

Com o intuito de utilizar mais dados que *Baboota & Kaur* (2018) e *Joseph, Fenton & Neil* (2006) e evitar *overfitting*, para este estudo foram requisitados os dados de todos os jogadores da *Serie A* italiana e *Premier League* que atuaram ao longo de cinco temporadas (2019-2020, 2020-2021, 2021-2022, 2022-2023, 2023-2024), além da tabela de resultados de todos os jogos disputados nesse mesmo período. Os dados obtidos foram armazenados no formato csv, sendo organizados em arquivos distintos para cada time e temporada. Dessa forma, cada arquivo contém as estatísticas individuais dos jogadores de um determinado clube em uma temporada específica.

5.2 Pré-processamento dos Dados

5.2.1 Base de Dados dos Jogadores

As tabelas extraídas do site FBref para todos os times e temporadas foram estruturadas de forma idêntica, contendo 47 atributos relacionados a idade, posição, minutos jogados, bem como estatísticas ofensivas (gols, assistências, passes

decisivos etc.) e defensivas (bloqueios, desarmes, erros graves etc.) de cada jogador. Esses dados foram carregados em diferentes *dataframes*, um para cada liga considerada, e posteriormente organizados por jogador, incluindo time, temporada e respectivos indicadores. Ressalta-se que um mesmo atleta pode aparecer em diferentes temporadas e clubes dentro da organização adotada.

Os *dataframes* correspondentes a cada liga foram posteriormente concatenados em um único conjunto, englobando todos os jogadores, o qual foi armazenado para as etapas seguintes da análise.

Com o intuito de evitar *overfitting* e melhorar a eficiência computacional, foi aplicada uma técnica de redução de dimensionalidade, o Principal Component Analysis (PCA).

5.2.1.1 Principal Component Analysis (PCA)

Para determinar o número ideal de componentes principais que serão utilizados no PCA, foi gerado um *Scree Plot*, conforme ilustrado na Figura **??**.

O gráfico apresenta a variância explicada acumulada em função do número de componentes principais, permitindo identificar o ponto de inflexão, ou seja, o momento em que a adição de novos componentes passa a contribuir de forma marginal para a variância total dos dados. O eixo x representa o número de componentes principais, enquanto o eixo y exibe a variância explicada acumulada.

A partir da Figura **??**, observa-se que, acima de 20 componentes principais, o ganho de informação adicional se torna insignificante. Com base nessa análise, serão realizados testes com diferentes quantidades de componentes, garantindo que sempre serão utilizados no mínimo 20 componentes, de forma a preservar a maior quantidade possível de variância dos dados sem comprometer a eficiência do modelo.

Figura 5.1 – Escolha do Número Ideal de Componentes do PCA

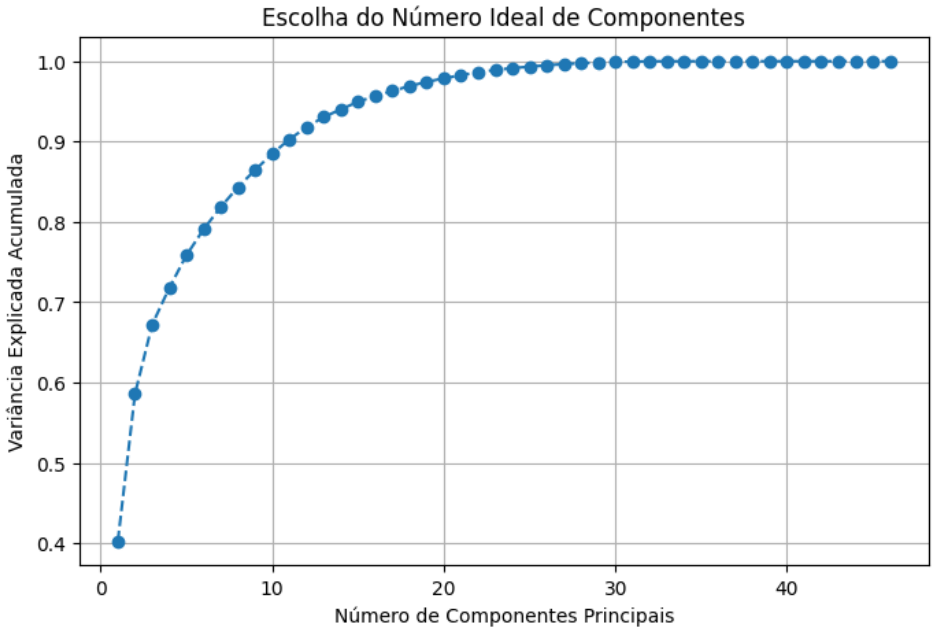

Fonte: do Autor, 2025

5.2.2 Base de Dados dos Jogos

Os dados dos jogos realizados entre as temporadas 2019-2020 e 2023-2024, obtidos na etapa de coleta, estavam organizados em 14 colunas. No entanto, grande parte dessas informações era irrelevante para a análise (por exemplo, horário e data das partidas, público, local e árbitro). Assim, para otimizar o conjunto de dados, foram removidos os atributos considerados ruído, mantendo-se apenas três elementos essenciais: time mandante, time visitante e resultado da partida.

A coluna de resultados foi transformada em valores numéricos por meio de um algoritmo em Python, em processo análogo a um *encoder*: vitória do mandante foi codificada como '1', vitória do visitante como '2' e empate como '0'.

Com base nessa codificação, percorreu-se a base atribuindo três pontos a cada vitória e um ponto a cada empate. O resultado desse processamento foi uma

tabela organizada por temporada, contendo cada clube e a respectiva pontuação acumulada.

5.3 Treinamento do Modelo de AM

Os dados de pontuação dos clubes foram organizados por temporada, enquanto as estatísticas individuais dos jogadores corresponderam sempre à temporada anterior. Dessa forma, o modelo utiliza informações conhecidas de desempenho prévio para estimar a pontuação final do clube na temporada subsequente. Adicionalmente, a pontuação dos clubes na temporada anterior foi incorporada como variável explicativa, de modo a capturar o histórico de desempenho recente da equipe.

O modelo de AM foi desenvolvido para prever a pontuação dos clubes ao longo das temporadas, com base no desempenho individual de seus jogadores. Para evitar vazamento de dados entre treinamento e teste, a base da Série A italiana foi utilizada no treinamento do modelo, enquanto a base da EPL foi destinada à etapa de teste.

5.3.1 Modelo de Aprendizado de Máquina

Para a etapa de previsão da pontuação dos clubes, foi implementado o modelo de MLP utilizando a biblioteca `Keras`. O modelo foi construído no formato *Sequential*, contendo três camadas densamente conectadas. A primeira camada recebe como entrada um vetor com dimensão igual ao número de atributos disponíveis, seguido por uma camada densa com 128 neurônios e função de ativação ReLU. Esta camada foi regularizada por meio de penalização L1, de forma a reduzir o risco de sobreajuste.

Em seguida, aplicou-se normalização em lote (*Batch Normalization*) e uma camada de *Dropout* com taxa de 60%, visando maior robustez e generalização. A segunda camada oculta é composta por 32 neurônios, também com ativação

ReLU e regularização L1, seguida novamente por *Batch Normalization* e *Dropout* de 60%. Por fim, a camada de saída é formada por um único neurônio linear, responsável por produzir a previsão da pontuação final do clube na temporada.

A arquitetura do modelo pode ser resumida da seguinte forma:

- Camada de entrada: vetor de dimensão n (atributos do jogador e do clube).
- Primeira camada oculta: `Dense(128)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.
- Segunda camada oculta: `Dense(32)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.
- Camada de saída: `Dense(1)`, ativação linear.

O MLP foi escolhido como base para o modelo de previsão de pontuação no contexto do futebol por reunir propriedades teóricas e práticas que o tornam adequado para lidar com a natureza complexa e não linear dos dados esportivos. Entre as principais razões para essa escolha, destacam-se:

1. **Capacidade de representação universal** — Um MLP com pelo menos uma camada oculta e funções de ativação não lineares é capaz de aproximar qualquer função mensurável (**??**). No contexto do futebol, isso significa que o modelo pode aprender padrões não lineares entre variáveis de desempenho (como gols, desarmes, progressão). Assim, o MLP não depende de hipóteses rígidas sobre a forma das relações entre variáveis, sendo capaz de aprendê-las diretamente dos dados.

2. **Flexibilidade para entradas de alta dimensão** — De acordo com *Goodfellow et. al., 2016*, cada camada de uma rede *feedforward* aprende uma representação do vetor de entrada que torna mais fácil a predição da saída desejada. Essa característica confere ao MLP flexibilidade para lidar com conjuntos de dados de alta dimensionalidade, nos quais múltiplas variáveis interagem de forma não linear. Mesmo com a aplicação prévia da técnica de *Principal Component Analysis* (PCA), que reduz a dimensionalidade de 48 para 20 componentes principais, o problema ainda envolve um espaço vetorial de considerável complexidade. Nesse contexto, o MLP é capaz de explorar as relações não lineares entre os componentes principais, aprendendo representações mais informativas que auxiliam na previsão de desempenho esportivo.

3. **Treinamento eficiente via retropropagação** — O algoritmo de *backpropagation*, apresentado em (**??**), permite o cálculo eficiente dos gradientes de erro e a atualização simultânea dos pesos da rede por meio de gradiente descendente. Isso viabiliza o treinamento em grandes bases de dados de futebol, reduz o tempo de convergência e possibilita otimizar métricas contínuas.

   Além dessas vantagens teóricas, o MLP oferece um equilíbrio entre capacidade de generalização, interpretabilidade e eficiência computacional, características desejáveis em modelos aplicados ao futebol, onde os dados são heterogêneos, ruidosos e interdependentes.

5.4 Predição de Impacto de um Jogador

Com o intuito de prever o impacto de jogadores no time, o algoritmo de AM

Em um primeiro momento, busca-se desenvolver um algoritmo capaz de predizer o impacto de um jogador em um time. Para essa tarefa, serão utilizadas três variáveis: *team_target*, *season_target* e *player_added*. O objetivo dessa abordagem é simular a busca de um time por um jogador antes do início da temporada, permitindo prever o impacto que ele terá ao longo da competição.

Conforme discutido por *Baboota & Kaur* (2018), a variável com maior influência na predição de resultados foi a forma recente do time. Seguindo esse princípio, serão aplicados pesos à forma do jogador, atribuindo maior relevância ao desempenho recente. Estatísticas mais antigas também serão consideradas, porém com um peso reduzido, garantindo que o modelo priorize informações mais atuais.

Com os dados preparados para análise, busca-se encontrar o melhor modelo de ML a partir de experimentação com diferentes algoritmos. O modelo base será selecionado a partir de métricas como o MAE (*Mean Absolute Error*) e o R^2 *score*.

5.5 Otimização

Após a definição do melhor modelo de ML, um *loop* será aplicado de forma a buscar o jogador, ou um grupo de jogadores, que terão maior impacto dentro do time naquela temporada. Esse será o primeiro exemplo de otimização a ser obtido.

Além disso, serão explorados outros modelos e abordagens da Pesquisa Operacional, com o objetivo de desenvolver soluções para otimização do elenco, estratégias, táticas e escalações. Dessa forma, busca-se auxiliar os clubes na tomada de decisão, oferecendo uma abordagem baseada em estatísticas e dados.

6 CRONOGRAMA

A Figura **??** apresenta o cronograma previsto para realização das atividades. As colunas representam os meses, sendo 24 a partir do ingresso no programa. As atividades são representadas nas linhas. Os quadrados marcados de cor cinza representam o mês que cada atividade foi/será realizada.

Figura 6.1 – Cronograma de atividades

	Meses																							
Atividades	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
A																								
B																								
C																								
D																								
E																								
F																								
G																								
H																								
I																								
J																								

Fonte: do Autor, 2025

A. Revisão de Literatura.

   Pesquisa de trabalhos e bibliografias relacionados ao tema.

B. Disciplinas.

   Cumprimento de disciplinas exigidas pelo programa de mestrado.

C. Estágio Docência.

   Estágio docência em disciplina de graduação.

D. Coleta de Dados.

Desenvolvimento de algoritmo para realizar a raspagem dos dados (*web scraping*) a partir da base de dados do Fbref.

E. Tratamento dos Dados.

   Desenvolvimento de algoritmos para realizar o tratamento adequado dos dados coletados no item anterior.

F. Desenvolvimento dos Modelos Preditivos (ML).

   Desenvolvimento de modelos preditivos de ML buscando uma previsão razoável de desempenho dos times.

G. Experimentos (ML).

   Teste dos algoritmos obtidos.

H. Desenvolvimento da Pesquisa Operacional.

   Desenvolvimento de modelos de otimização para tarefas no contexto do futebol.

I. Experimentos (Pesquisa Operacional).

   Teste dos modelos obtidos.

J. Escrita da Tese.

   Escrita e apresentação do documento final do trabalho.

7 RESULTADOS E DISCUSSÕES

7.1 Modelo de Aprendizado de Máquina

O melhor modelo de AM desenvolvido neste estudo apresentou acurácia máxima de aproximadamente 60% na tarefa de prever a pontuação final de um time em sua liga nacional, utilizando como base os dados estatísticos de desempenho individual de seus jogadores na temporada anterior.

Para avaliar o desempenho dos diferentes algoritmos aplicados à tarefa de previsão, foram calculadas métricas amplamente utilizadas em problemas de regressão, incluindo o coeficiente de determinação (R^2), o erro absoluto médio (MAE), o erro quadrático médio (MSE), a raiz do erro quadrático médio (RMSE), o erro percentual absoluto médio (MAPE) e o tempo de processamento de cada modelo. A Tabela **??** apresenta um resumo comparativo dos resultados obtidos, permitindo analisar tanto a qualidade preditiva quanto o custo computacional de cada abordagem.

Tabela 7.1 – Comparação de desempenho entre os modelos de Machine Learning avaliados

Modelo	**R^2**	**MAE**	**MSE**	**RMSE**	**MAPE**	**Tempo (s)**
RL	0.41	11.48	191.78	13.85	0.2580	2.15
RF	0.28	12.05	234.05	15.30	0.2690	423.13
XGBoost	0.41	11.48	191.78	13.85	0.2580	2.86
MLP	0.48	11.08	170.42	13.05	0.2424	161.68

4. Fonte: Elaborado pelo autor.

7.2 Otimização de Montagem de Elenco