LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL: APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA IMPREVISIBILIDADE EM CONTRATAÇÕES

Exame de Qualificação

LAVRAS – MG

2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
Exame de Qualificação

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

LUCIO VARGAS DE ALBUQUERQUE NUNES

OTIMIZAÇÃO DA MONTAGEM DE ELENCO NO FUTEBOL:
APRENDIZADO DE MÁQUINA PARA REDUÇÃO DA
IMPREVISIBILIDADE EM CONTRATAÇÕES
OPTIMIZATION OF SQUAD BUILDING IN FOOTBALL: MACHINE
LEARNING FOR REDUCING UNCERTAINTY IN PLAYER RECRUITMENT

Tese apresentada à Universidade Federal de Lavras, como parte das exigências do Programa de Pós-Graduação em Ciência da Computação, para a obtenção do título de Mestre.

APROVADA em 24 de Março de 2025.

Prof. Dr. Luiz Henrique de Campos Merschmann	UFLA
Prof. Dr. Júlio Cesar Alves	UFLA
Profa. Dra. Elaine Cecília Gatto	UFLA

Prof. Dr. Dilson Lucas Pereira
Orientador

LAVRAS – MG
2025

RESUMO

O futebol, o esporte mais popular do mundo, é marcado por sua alta imprevisibilidade, o que dificulta a montagem de elencos, as escolhas táticas e a seleção de jogadores para cada partida. Este estudo explora o uso de técnicas de Aprendizado de Máquina (AM) e Pesquisa Operacional (PO) como ferramentas de apoio à tomada de decisão no contexto esportivo. O objetivo é desenvolver um modelo preditivo capaz de estimar o desempenho dos clubes com base em dados estatísticos individuais dos jogadores. A partir dessas previsões, são aplicados algoritmos de otimização para orientar estratégias de contratações, permitindo decisões mais eficientes e fundamentadas em dados. Essa abordagem visa reduzir a subjetividade nos processos de gestão esportiva, promovendo maior assertividade nas decisões de mercado por parte dos clubes.

Palavras-chave: Futebol. Aprendizado de Máquina. Elenco.

ABSTRACT

Football, the most popular sport in the world, is marked by a high degree of unpredictability, which makes squad building, tactical planning, and player selection particularly challenging. This study explores the use of Machine Learning (ML) and Operations Research (OR) techniques as decision-support tools in the sports context. The objective is to develop predictive models capable of estimating club performance based on individual player statistics. These predictions are then used as inputs for optimization algorithms aimed at guiding player recruitment strategies, enabling more efficient and data-driven decisions. This approach seeks to reduce subjectivity in sports management processes, promoting greater accuracy in market decisions and contributing to a more strategic, evidence-based decision-making framework within football clubs.

Keywords: Football. Machine Learning. Squad.

LISTA DE FIGURAS

Figura 4.1 – AD para Iris 28
Figura 4.2 – Dados da Wyndor Glass Co. 35
Figura 4.3 – Valores de (x_1, x_2) que maximizam $3x_1 + 5x_2$. 36
Figura 5.1 – Escolha do Número Ideal de Componentes do PCA 45
Figura 6.1 – Relação entre pontuações reais e previstas pelo modelo MLP na Premier League. 55

SUMÁRIO

1 INTRODUÇÃO

Futebol é o esporte mais popular do mundo (**??**). Nas últimas décadas, sua evolução tecnológica e analítica tem sido notável, acompanhada por um crescimento expressivo nos lucros gerados pelas atividades esportivas (**??**). No entanto, o futebol é um esporte altamente imprevisível. Um exemplo notável dessa imprevisibilidade foi a surpreendente conquista da English Premier League (EPL) pelo Leicester City em 2016, um feito que surpreendeu especialistas e torcedores em todo o mundo (**??**).

Dada a relevância econômica e o impacto do futebol como forma de entretenimento, pesquisadores da academia e profissionais da indústria têm se dedicado ao desafio de prever seus resultados (**??**). O crescimento do mercado de apostas reflete essa busca, impulsionando também os lucros da indústria de prognósticos esportivos (**??**). Para se ter uma noção da magnitude econômica do futebol, entre 1º de junho e 1º de setembro de 2023, as transferências de jogadores movimentaram R$ 36,6 bilhões, conforme relatório divulgado pela Federação Internacional de Futebol (FIFA) (**??**). No Brasil, em 2025, a janela de transferências da Série A brasileira bateu a marca de R$ 1 bilhão em movimentações financeiras (**??**).

No campo da Ciência da Computação, diversos estudos têm explorado técnicas de análise de dados e estatística com o objetivo de modelar padrões e realizar predições em ambientes complexos. Um exemplo relevante é o estudo de Joseph, Fenton e Neil (2006), que investigou o uso de redes Bayesianas e outras técnicas de Aprendizado de Máquinas (AM) para prever resultados do Tottenham Hotspur entre 1995 e 1997. Outro caso notável de aplicação de dados no futebol envolve o *Brighton & Hove Albion*, clube inglês que, sob a gestão de Tony Bloom, implementou uma estratégia fortemente orientada por análises estatísticas para recrutamento e tomada de decisões. Essa filosofia refletiu-se diretamente na política de transferências do clube, com a identificação sistemática de atletas subvalorizados no mercado. Entre os exemplos mais emblemáticos está Moisés Caicedo, contra-

tado junto ao Independiente Del Valle em 2021 por cerca de £4,5 milhões e negociado com o Chelsea em 2023 por valores próximos a 115 milhões €, tornando-se uma das maiores vendas da história da EPL (**????**). O mesmo caso de altos lucros em revendas se aplica a outros jogadores, como Alexis Mac Allister e Marc Cucurella, abordagem que permitiu que o *Brighton* se consolidasse como um dos clubes mais eficientes do mercado de transferências da EPL, reinvestindo os recursos obtidos e mantendo a competitividade sustentável na elite do futebol inglês (**??**).

Na literatura acadêmica, observa-se que a maioria dos trabalhos envolvendo AM no futebol concentra-se na previsão de resultados de partidas, probabilidades de vitória ou otimização de ganhos no contexto de apostas esportivas. Em contraste, menos estudos direcionam esforços à construção e otimização de elencos com foco na avaliação e seleção de jogadores (**??**). Essa lacuna é particularmente relevante, uma vez que a escolha de um atleta para compor um elenco envolve a análise simultânea de múltiplos parâmetros técnicos, físicos e mentais, além de fatores contextuais como estilo de jogo da equipe, liga disputada e momento da carreira do jogador (**??**). A natureza não determinística inerente ao futebol torna esse processo ainda mais desafiador, pois mesmo contratações que aparentam ser ideais sob múltiplos critérios podem não atingir o desempenho esperado.

Segundo Ian Graham (2024), uma transferência pode ser considerada um sucesso se o jogador iniciar 50% das partidas nas primeiras duas temporadas ("The 50% rule"). Considerando todas as transferências de mais de € 10 milhões que ocorreram na EPL entre os anos de 1992 e 2021, perto da metade (46%) não atingiram o critério estabelecido e, portanto, podem ser classificadas como falhas (**??**). Entre os principais fatores associados a esses insucessos, destacam-se:

1. O jogador atual é melhor que o novo jogador;

2. O jogador não é tão bom quanto se pensava inicialmente;

3. O jogador não se encaixa no estilo do time;

4. O jogador joga fora de posição;

5. O técnico não aprova o jogador;

6. O jogador tem problemas de condicionamento físico ou pessoais.

Nos últimos anos, o Aprendizado de Máquinas tem ampliado significativamente a capacidade de análise de dados esportivos, permitindo a identificação de padrões antes imperceptíveis em grandes volumes de informação. Técnicas avançadas vêm sendo aplicadas para estimar desde a probabilidade de vitória em uma partida até o impacto de decisões táticas ao longo de uma temporada. Entretanto, tais modelos não eliminam a incerteza inerente ao futebol, atuando como ferramentas de apoio à tomada de decisão humana, com o objetivo de reduzir riscos e embasar escolhas estratégicas.

Neste contexto, o presente trabalho investiga o uso de modelos preditivos para converter estatísticas históricas de desempenho individual em estimativas de desempenho esperado de jogadores quando inseridos em contextos específicos de equipe e temporada. Diferentemente de abordagens voltadas à previsão direta de resultados de partidas ou à avaliação de talento de forma isolada, a proposta concentra-se na análise contextualizada do jogador como parte de um sistema coletivo. As previsões geradas são utilizadas como subsídio em um processo de simulação e avaliação de cenários de contratação, visando apoiar decisões de mercado no futebol profissional de forma orientada por dados e alinhada a critérios de eficiência esportiva e financeira.

2 OBJETIVOS

2.1 Objetivo Geral

O presente estudo tem como objetivo principal desenvolver, avaliar e comparar modelos de Aprendizado de Máquinas (AM) capazes de prever o desempenho de equipes, entendido neste trabalho como a pontuação esperada ao longo da competição, a partir de dados estatísticos de desempenho individual de jogadores. Uma vez definido o modelo preditivo com melhor desempenho, este será utilizado como função objetivo em modelos simples de otimização, com o intuito de auxiliar o processo de tomada de decisão em contratações, buscando identificar soluções de mercado mais adequadas para a composição de elencos no futebol profissional.

2.2 Objetivos Específicos

Com o intuito de atingir o objetivo geral, foram estabelecidos os seguintes objetivos específicos:

1. Coletar, estruturar e processar dados históricos de jogadores e partidas, abrangendo múltiplas temporadas, garantindo a qualidade e a integridade das informações utilizadas no desenvolvimento dos modelos preditivos.

2. Desenvolver uma metodologia para quantificar o impacto individual dos jogadores, combinando estatísticas históricas ao longo das temporadas por meio de um sistema de ponderação temporal, priorizando desempenhos mais recentes.

3. Construir modelos de AM para prever o desempenho agregado de uma equipe em uma determinada temporada, considerando a composição do elenco e os dados históricos dos jogadores.

4. Validar a eficácia dos modelos preditivos, comparando as estimativas com os resultados reais de temporadas subsequentes, utilizando métricas esta-

tísticas como erro médio absoluto (MAE) e coeficiente de determinação (R^2).

5. Desenvolver modelos simples de otimização baseados no modelo de AM selecionado, visando a identificação de combinações de jogadores que maximizem o desempenho esperado da equipe sob restrições de mercado.

Ao integrar técnicas de AM e otimização, este estudo busca fornecer uma ferramenta analítica de apoio à decisão para a montagem de elencos no futebol profissional, contribuindo para práticas de gestão esportiva orientadas por dados.

3 REVISÃO DE LITERATURA

3.1 Aprendizado de Máquina no contexto esportivo

Em 2020, *Horvat Job* apresentaram uma revisão abrangente sobre o uso de Aprendizado de Máquina (AM) na predição de resultados esportivos, com foco principal em esportes coletivos, especialmente o futebol. Os autores destacam que o AM é particularmente adequado a essa tarefa, uma vez que modalidades esportivas geram grandes volumes de dados estruturados e não estruturados, provenientes de eventos de jogo, sistemas de *tracking*, probabilidades associadas às partidas e bases históricas consolidadas (**??**).

Conforme apontado por *Horvat Job* (2020), a maior parte dos estudos que empregam métodos preditivos no contexto esportivo concentra-se na predição de resultados de partidas individuais, especialmente na classificação de vitórias, empates e derrotas. Essa predominância pode ser explicada tanto pelo interesse mercadológico associado às apostas esportivas, que incentiva o desenvolvimento de modelos voltados à antecipação de resultados (**??**), quanto pela própria natureza técnica do problema, que se ajusta adequadamente aos algoritmos supervisionados mais difundidos e à disponibilidade de bases históricas amplamente registradas no futebol (**??**). Nesse contexto, observa-se menor atenção a problemas relacionados ao desempenho agregado ao longo de uma temporada, especialmente quando este é modelado de forma prospectiva como função da composição individual do elenco.

Em contraste com essa predominância de estudos voltados à predição de partidas isoladas, a revisão conduzida por (**??**) identifica, ainda que em menor número, trabalhos que abordam diretamente o problema de seleção e formação de equipes sob uma perspectiva multicritério e de otimização. Entre os estudos mencionados, destacam-se (**??**), que propõem um sistema de inferência fuzzy em duas fases para seleção de jogadores e posterior arranjo tático da equipe, e (**??**), que estruturam o problema de escolha de atletas como uma análise multicritério

baseada em múltiplas métricas de desempenho. Tais abordagens representam esforços relevantes no sentido de formalizar o processo de composição de elencos, ainda que se apoiem predominantemente em modelos fuzzy ou técnicas de agregação determinística, sem incorporar mecanismos de aprendizado supervisionado voltados à predição prospectiva de desempenho coletivo.

Os estudos voltados à predição de resultados, por sua vez, identificam o uso recorrente de algoritmos como regressão logística, *Support Vector Machines* (SVM), *Random Forest* e redes neurais, destacando que modelos que integram múltiplas fontes de informação — incluindo estatísticas tradicionais, indicadores derivados e variáveis contextuais — tendem a apresentar melhor desempenho preditivo (**??**). Ainda assim, a tarefa permanece desafiadora devido à natureza estocástica do futebol e à ausência de padronização entre bases de dados utilizadas em diferentes estudos. Cabe ressaltar que, nos últimos anos, a geração de dados aumentou significativamente com a maior disponibilidade de dados esportivos em larga escala, impulsionada pela expansão de sistemas de *tracking* e por bancos estruturados como *Opta* e *StatsBomb* (**??**).

3.1.1 Previsão de resultados de partidas

Conforme ressaltado anteriormente, os modelos de previsão de resultados de partidas constituem uma das aplicações mais tradicionais do AM no futebol, com foco na classificação de vitórias, empates e derrotas. A seguir, apresentam-se alguns estudos representativos dessa linha de pesquisa, com o objetivo de evidenciar sua evolução metodológica.

Um dos trabalhos pioneiros é o de *Joseph, Fenton & Neil* (2006) (**??**), que empregaram redes Bayesianas para prever resultados a partir de um conjunto reduzido de dados do *Tottenham Hotspur Football Club* (1995–1997). A base analisada compreendeu 76 partidas e 30 atributos, sendo 28 jogadores representados por variáveis binárias (presença ou ausência), além do local da partida e da quali-

dade do adversário. Os próprios autores reconhecem tratar-se de um cenário com disponibilidade limitada de dados, o que impõe desafios adicionais aos métodos de aprendizado supervisionado. Ainda assim, os resultados indicaram que a rede Bayesiana construída com conhecimento especializado apresentou melhor desempenho relativo nos experimentos realizados, mesmo diante da limitação amostral. Esse resultado reforça que, em contextos com bases reduzidas e forte especificidade estrutural, a modelagem explícita das relações entre variáveis pode mitigar parcialmente os efeitos da escassez de dados. Entretanto, o estudo permanece circunscrito à predição de partidas individuais e a uma equipe específica.

Em contexto mais recente, *Baboota & Kaur* (2018) (**??**) investigaram a predição multiclasse de resultados na Premier League utilizando dados de duas temporadas (2014–2015 e 2015–2016). O estudo incorporou variáveis relacionadas ao desempenho recente das equipes, estatísticas técnicas de jogo (finalizações, posse de bola, escanteios), *ratings* derivados do FIFA Index e fator casa/fora. Foram avaliados algoritmos como *Random Forest*, SVM, Naive Bayes e XGBoost, sendo o *Gradient Boosting* o modelo de melhor desempenho. Ainda assim, os autores observam que os modelos não superaram as previsões das casas de apostas, que incorporam variáveis não observáveis pelos modelos estatísticos. Embora represente uma ampliação substancial em relação a trabalhos anteriores — tanto em volume de dados quanto na diversidade de algoritmos avaliados — o problema permanece centrado na predição do desfecho de partidas individuais.

No âmbito do Aprendizado Profundo, *Awadallah & Khandelwal* (2020) (**??**) compararam regressão logística, *Random Forest*, redes neurais densas (DNN) e LSTM na predição de resultados da EPL ao longo de dez temporadas (2008–2019), utilizando aproximadamente 4.180 partidas e um conjunto reduzido de 24 *features*. O modelo LSTM apresentou o melhor desempenho, alcançando cerca de 58% de acurácia em teste. Apesar do avanço metodológico representado pelo uso

de redes neurais profundas, os autores destacam limitações relacionadas à generalização e à natureza estocástica do futebol.

De modo geral, observa-se uma evolução metodológica significativa, desde bases reduzidas com forte dependência de conhecimento especializado até modelos supervisionados e redes neurais aplicados a bases mais amplas. Ainda assim, a unidade analítica predominante permanece sendo a partida individual, com ênfase na classificação do resultado do jogo.

3.1.2 Aplicações recentes do AM no futebol

Para além da predição de partidas isoladas, a literatura recente evidencia uma ampliação do escopo de aplicação do AM no futebol. *Rico-González et al.* (2023) demonstram que o AM tem sido empregado em diversas frentes, como análise de desempenho físico, detecção de padrões táticos, avaliação de risco de lesões e modelagem espacial com dados de *tracking* (**??**). A crescente disponibilidade de dados tem impulsionado abordagens metodológicas cada vez mais complexas, incluindo redes neurais profundas, modelos probabilísticos e métodos baseados em séries temporais.

Além das aplicações voltadas à predição de partidas, estudos recentes evidenciam a incorporação crescente de dados espaciais e fisiológicos na modelagem do desempenho esportivo. O volume *Machine Learning and Data Mining for Sports Analytics* (MLSA, 2023) destaca a integração entre dados de eventos e informações de *tracking*, ressaltando que modelos exclusivamente baseados em eventos enfrentam limitações estruturais pela ausência de contexto espacial e pressão defensiva (**??**). De forma complementar, pesquisas como a de Majumdar et al. (2022) exploram a aplicação de AM na predição de lesões a partir de variáveis relacionadas à carga de treino e competição, utilizando desde regressão logística até redes neurais artificiais. Essas abordagens evidenciam a ampliação temática e metodológica do campo, mas permanecem majoritariamente voltadas à mode-

lagem de situações específicas de jogo ou risco individual, não se direcionando à modelagem prospectiva do desempenho agregado de temporada como função da composição do elenco.

No contexto nacional, observa-se também o crescimento da área de *sports analytics*, com iniciativas acadêmicas como o Sports Analytics Lab (SALab) da UFMG, voltadas à aplicação de métodos quantitativos no futebol.

Apesar dessa expansão metodológica e temática, observa-se que a maior parte dos estudos ainda se concentra na modelagem de eventos específicos ou na predição de partidas isoladas, conforme destacado por *Horvat & Job* (2020). Em contraste, verifica-se menor atenção a abordagens voltadas à modelagem do desempenho agregado das equipes ao longo de uma temporada, especialmente quando esse desempenho é tratado como função da composição individual do elenco. Essa constatação reforça a necessidade de examinar de forma mais sistemática como a literatura tem abordado o desempenho agregado sob perspectivas estatísticas e econômicas.

3.1.3 Desempenho agregado e determinantes de temporada

Além da predição de partidas individuais, parte da literatura tem investigado determinantes do desempenho agregado ao longo de uma temporada. Lago-Ballesteros e Lago-Peñas (2010), ao analisarem todas as 380 partidas da temporada 2008–2009 da La Liga espanhola, identificaram diferenças estatisticamente significativas entre equipes do topo e da parte inferior da tabela em variáveis como gols marcados, total de finalizações, finalizações no alvo, assistências e posse de bola (**??**). Os resultados indicam que o sucesso competitivo agregado pode ser parcialmente explicado por padrões estatísticos observáveis ao longo da temporada.

Sob a ótica econômica, estudos como os de Carmichael, McHale e Thomas (2011) analisam o desempenho agregado das equipes a partir de variáveis estruturais, como gastos salariais e receitas, evidenciando associação entre inves-

timento financeiro e posição final na liga (**??**). De forma complementar, Totty e Owens (2011) discutem como mecanismos institucionais, como tetos salariais, influenciam o equilíbrio competitivo das ligas profissionais (**??**). Essas abordagens indicam que o desempenho ao longo de uma temporada pode ser parcialmente explicado por fatores estruturais e de alocação de recursos, reforçando a ideia de que o sucesso competitivo agregado não é puramente aleatório.

Herold, Memmert e Perl (2019) investigaram a aplicação de AM no futebol profissional masculino, utilizando variáveis como passes, finalizações, dribles e métricas derivadas, como Gols Esperados (xG). O estudo demonstra que padrões técnicos individuais podem ser representados matematicamente e modelados por meio de algoritmos supervisionados e não supervisionados, incluindo redes neurais, árvores de decisão e regressão logística (**??**). Tais evidências reforçam que estatísticas de desempenho individual constituem insumos mensuráveis e potencialmente preditivos do sucesso competitivo.

Complementarmente, Kite e Nevill (2017) investigaram preditores de sucesso ao longo de temporadas consecutivas de uma mesma equipe, demonstrando que determinados indicadores de desempenho apresentam capacidade explicativa sobre a posição final e os resultados obtidos (**??**). Tais resultados evidenciam que métricas de jogo podem ser utilizadas para modelar o sucesso competitivo.

Embora o estudo de *Kite e Nevill* (2017) represente um avanço ao empregar modelos estatísticos com finalidade preditiva, sua modelagem permanece centrada no nível da partida individual. O sucesso é operacionalizado a partir do desfecho dos jogos (vitória, empate ou derrota), e as variáveis explicativas derivam predominantemente de indicadores agregados por partida (**??**). Dessa forma, ainda que tais contribuições ampliem a compreensão dos determinantes estatísticos do desempenho competitivo, não há uma modelagem explícita do desempenho agregado da temporada como função da composição estrutural do elenco. Essa lacuna torna-se particularmente relevante quando se considera que decisões estratégicas

no futebol profissional — especialmente no mercado de transferências — são tomadas com base na expectativa de desempenho ao longo de toda a competição, e não apenas em resultados isolados.

De modo semelhante, embora essas contribuições identifiquem determinantes técnicos e econômicos do sucesso competitivo, elas concentram-se majoritariamente na análise de resultados já observados ou em relações estruturais agregadas. Não modelam explicitamente, de forma prospectiva, a pontuação esperada de uma equipe como função direta da composição individual do elenco, tampouco integram tais estimativas a problemas formais de decisão.

3.2 Pesquisa Operacional no contexto esportivo

A Pesquisa Operacional (PO) constitui um conjunto de métodos analíticos voltados à modelagem e otimização de processos decisórios (**????**). No contexto esportivo, sua aplicação abrange desde problemas estratégicos, como o gerenciamento de equipes, até decisões táticas e logísticas (**??**).

Técnicas como Programação Linear, Programação Dinâmica e Processos de Markov têm sido empregadas na análise de substituições, estratégias de jogo e planejamento competitivo (**????**). Em muitos casos, tais problemas apresentam natureza combinatória e elevada complexidade computacional.

Conforme discutido por (**??**), diversos problemas de organização competitiva e escalonamento esportivo (*sports scheduling*) apresentam elevada complexidade combinatória, sendo muitos deles classificados como NP-difíceis ou NP-completos em suas versões formais. Entre os exemplos destacados estão o Traveling Tournament Problem (TTP), que busca minimizar as distâncias percorridas pelas equipes sob restrições estruturais de calendário; o problema de minimização de *breaks* em torneios round-robin, cuja versão com calendário parcial é NP-difícil; e variantes do problema de alocação de árbitros, cuja versão de decisão é NP-completa. Diante dessa complexidade, especialmente em instâncias de grande

porte e com múltiplas restrições, a literatura recorre amplamente a heurísticas e metaheurísticas, como busca local, *simulated annealing*, *tabu search* e métodos híbridos, visando à obtenção de soluções de alta qualidade em tempo computacional viável.

Além da dificuldade computacional inerente a esses problemas, observa-se também uma limitação recorrente na modelagem adotada. Na maior parte dos trabalhos, a função objetivo é definida por métricas simplificadas ou parâmetros fixos, não incorporando modelos preditivos baseados no desempenho individual de atletas como componente central do problema decisório. Assim, permanece inexplorada a integração entre modelos preditivos de desempenho agregado e técnicas de otimização aplicadas à montagem de elenco.

Problemas de montagem de elenco também têm sido abordados sob a ótica da otimização matemática. Pantuso (**??**) propõe o *Football Team Composition Problem* por meio de um modelo de programação estocástica multietapa, no qual a incerteza sobre o desenvolvimento futuro dos atletas é incorporada explicitamente à formulação. De forma complementar, Boon e Sierksma (**??**) modelam a formação de equipes como um problema de alocação ótima jogador–posição, formulado via programação linear inteira e equivalente a um problema de *matching* máximo ponderado. Já Becker e Sun (**??**) aplicam uma estrutura análoga ao problema da mochila para otimizar decisões de seleção em *fantasy football* sob restrições orçamentárias.

Embora esses trabalhos avancem na formalização matemática da montagem de equipes, observa-se que a função objetivo permanece baseada em avaliações previamente definidas, pontuações atribuídas a priori ou estimativas paramétricas fixadas antes do processo de otimização. Não há, nesses estudos, a incorporação explícita de modelos preditivos de desempenho agregado aprendidos diretamente a partir de dados históricos como componente central da função objetivo.

Dessa forma, permanece uma lacuna na literatura quanto à integração estruturada entre modelos de AM e problemas combinatórios de montagem de elenco.

3.2.1 Otimização Prescritiva e Problemas Combinatórios no Esporte

A transição de *predictive analytics* para *prescriptive analytics*, conforme discutido por (**??**), consiste na integração entre modelos preditivos e problemas de otimização, permitindo que estimativas estatísticas sejam incorporadas diretamente na definição de políticas ótimas de decisão. Nesse paradigma, modelos de AM deixam de atuar apenas como ferramentas de previsão e passam a compor a função objetivo de problemas decisórios.

Além das abordagens clássicas de otimização, a literatura recente evidencia uma aproximação crescente entre PO e métodos de Inteligência Artificial (IA). Conforme discutido por (**??**), técnicas como aprendizado por reforço e algoritmos evolutivos vêm sendo empregadas em problemas decisórios no esporte, aproximando modelos de aprendizado e processos de otimização. Esse movimento reforça a convergência entre predição estatística e decisão prescritiva, abrindo espaço para estruturas integradas nas quais modelos de AM podem ser incorporados diretamente à função objetivo de problemas combinatórios.

No contexto esportivo, decisões estratégicas como montagem de elenco e planejamento competitivo podem ser formalizadas como problemas de otimização sob restrições orçamentárias e estruturais. Tais problemas frequentemente assumem estrutura combinatória análoga àquela observada em problemas clássicos de escalonamento esportivo (**??**), o que justifica o uso de heurísticas e metaheurísticas para obtenção de soluções viáveis.

O presente estudo insere-se explicitamente nessa interseção entre AM e PO, ao propor um modelo capaz de estimar a pontuação esperada de uma equipe em uma temporada a partir do desempenho individual de seus jogadores na temporada anterior. Diferentemente das abordagens focadas na previsão de partidas

isoladas ou na análise retrospectiva de determinantes agregados, o modelo desenvolvido busca capturar prospectivamente o impacto da composição do elenco sobre o desempenho competitivo. Posteriormente, essa estimativa é incorporada como função objetivo em um problema combinatório de montagem de elenco sob restrição orçamentária, aproximando predição estatística e decisão prescritiva no contexto do futebol profissional.

4 REFERENCIAL TEÓRICO

4.1 Aprendizado de Máquina

Aprendizado de Máquina (AM) é o estudo de algoritmos e modelos estatísticos empregados por sistemas computacionais para realizar tarefas específicas de forma autônoma. Essa abordagem permite que as máquinas aprendam a partir de dados e melhorem seu desempenho sem necessidade de reprogramação explícita (**??**). Segundo Geron (2019), AM pode ser descrito como a ciência (ou arte) de programar computadores para que aprendam com os dados.

Um exemplo clássico de aplicação de AM é o filtro de *spam*, que permite que o sistema identifique automaticamente emails indesejados, diferenciando-os de mensagens legítimas com base em padrões aprendidos (**??**).

Com a crescente disponibilidade de *datasets*, o uso de AM tem apresentado um notável crescimento (**??**). Esse avanço pode ser atribuído à maior disponibilidade de dados e ao aumento da capacidade computacional. A constante conexão das pessoas a dispositivos digitais gera volumes massivos de dados, enquanto tecnologias modernas permitem o processamento eficiente dessas grandes quantidades de informação (**??**).

Muitas indústrias têm adotado o AM com o objetivo de extrair insights relevantes de *databases*, facilitando o aprendizado a partir dos dados (**??**). Além disso, o AM tem sido amplamente aplicado em diversas áreas, incluindo reconhecimento facial, segmentação de imagens, detecção de câncer e previsão de classes e resultados, destacando-se também no contexto esportivo (**??**).

AM utiliza diferentes algoritmos para resolver problemas relacionados com dados. Cientistas de dados destacam que não há um único algoritmo universalmente superior para resolver todos os tipos de problemas (**??**). Esta seção apresenta uma breve descrição de alguns dos modelos mais comumente utilizados em AM para a resolução de problemas.

4.1.1 Árvore de Decisão (AD)

As Árvores de Decisão são algoritmos versáteis de AM que podem ser utilizados tanto para tarefas de classificação, quanto para tarefas de regressão (**??**). Esses algoritmos recebem um *input* de dados de treinamento (conjunto de atributos independentes + atributo classe) e retornam como saída uma árvore de decisão que permite classificar uma nova instância a partir de seus atributos independentes (**??**).

Um exemplo de AD pode ser visto na Figura **??**

Figura 4.1 – AD para Iris

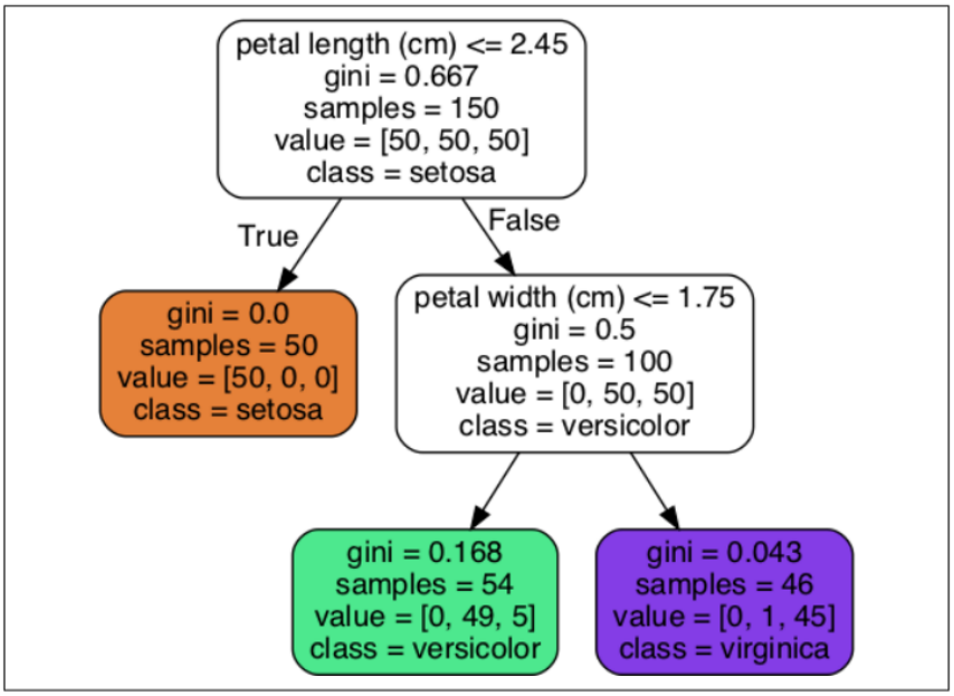

Fonte: Geron, 2019

Na Figura **??**, é possível observar uma árvore de decisão utilizada para classificar flores do conjunto de dados *Iris*. O nó raiz divide as amostras com base no comprimento da pétala (*petal length* ≤ 2.45), separando a classe *setosa* (pura, Gini = 0). As amostras restantes são subdivididas pelo critério de largura da pétala

(*petal width* ≤ 1.75), onde as classes *versicolor* e *virginica* são diferenciadas com alta precisão (Gini próximo de 0 nos nós finais). A árvore otimiza a classificação minimizando o índice de Gini em cada divisão (**??**).

4.1.2 Random Forest (RF)

O RF consiste em uma combinação de AD, geralmente treinadas por meio do método *bagging* (**??**). Diferente das ADs, RF utiliza uma randomização extra no crescimento das árvores. Ao invés de buscar a melhor *feature* para dividir o nó, utiliza-se da melhor dentro de um *subset* randômico. Nesse caso, busca-se reduzir a variância do modelo por meio da agregação de múltiplas árvores, mantendo um viés relativamente baixo quando comparado a modelos excessivamente regularizados.

4.1.3 Support Vector Machine (SVM)

O *Support Vector Machine* (SVM) é um algoritmo de AM supervisionado utilizado para tarefas de classificação e regressão. O seu princípio básico é encontrar um hiperplano ótimo que separe os dados em diferentes classes, maximizando a margem entre os pontos mais próximos das classes opostas (**??**).

O hiperplano utilizado pelo SVM consiste em uma superfície de decisão que separa os pontos de dados em classes distintas. Em um espaço 2D, ele é uma linha; em 3D, um plano e, em dimensões superiores, uma hiper-superfície (**??**)

Cabe ressaltar que nem sempre os dados são linearmente separáveis. Sendo assim, o SVM utiliza funções *kernel* para projetar os dados em um espaço de maior dimensão, onde a separação linear se torna possível (**??**). As principais funções *kernel* são:

1. **Linear**: Quando os dados já são linearmente separáveis.

2. **Polinomial**: Para capturar relações não lineares.

3. **RBF (Radial Basis Function - Gaussiana)**: Amplamente usada para capturar padrões complexos.

4. **Sigmoid**: Similar a redes neurais.

4.1.4 Gradient Boosting (XGBoost)

O *Gradient Boosting* é uma técnica de aprendizado baseada na combinação sequencial de modelos fracos, geralmente árvores de decisão rasas, com o objetivo de minimizar uma função de perda diferenciável (**??**). Diferentemente do *bagging*, no qual os modelos são treinados de forma independente, o *boosting* constrói cada novo preditor de maneira iterativa, ajustando-o aos resíduos (erros) cometidos pelo modelo anterior. Esse processo pode ser interpretado como uma otimização por gradiente no espaço funcional, na qual cada novo modelo aproxima a direção de maior redução da função de custo.

Formalmente, a cada iteração m, busca-se adicionar um novo modelo $h_m(x)$ de forma que o modelo final seja dado por:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x),$$

onde γ_m representa o passo ótimo na direção do novo preditor.

O *XGBoost* (*Extreme Gradient Boosting*) constitui uma implementação otimizada do *Gradient Boosting*, incorporando técnicas de regularização, paralelização e controle eficiente de memória (**??**). Além disso, sua função objetivo inclui termos de penalização que auxiliam na prevenção de *overfitting*, tornando-o especialmente eficaz em problemas de alta dimensionalidade e grandes volumes de dados.

4.1.5 Multilayer Perceptron (MLP)

O *Multilayer Perceptron* (MLP) é uma função matemática parametrizada que aprende a melhor forma de transformar um vetor de entrada $\mathbf{x}$ em uma saída $\mathbf{y}$. Assim, o MLP pode ser entendido como uma composição de várias funções aplicadas em sequência, formando um modelo de múltiplas camadas (**??**).

A arquitetura do MLP segue uma lógica de entrada $\rightarrow$ camadas ocultas $\rightarrow$ saída, utilizando uma função de ativação $g(\cdot)$ para introduzir não linearidade em cada camada. Essa relação é expressa por:

$$h^{(l)} = g\left(W^{(l)}h^{(l-1)} + b^{(l)}\right),$$

onde $W^{(l)}$ e $b^{(l)}$ representam, respectivamente, a matriz de pesos e o vetor de vieses da camada l (**??**).

A introdução da função não linear $g(\cdot)$ é essencial, pois permite que o MLP aprenda relações complexas entre as variáveis de entrada e saída. Sem ela, o modelo se reduziria a uma simples combinação linear, incapaz de representar funções não lineares (**??**).

4.1.6 Generalização, Viés e Variância

Um dos principais desafios em AM é garantir que o modelo apresente boa capacidade de generalização, isto é, desempenho satisfatório em dados não utilizados durante o treinamento (**??**).

Modelos excessivamente complexos podem se ajustar não apenas aos padrões relevantes, mas também ao ruído presente no conjunto de treinamento, fenômeno conhecido como *overfitting*. Em contrapartida, modelos demasiadamente simples podem não capturar relações importantes nos dados, resultando em *underfitting*.

Esse comportamento está diretamente relacionado ao equilíbrio entre viés e variância. Modelos com alto viés tendem a apresentar subajuste, enquanto modelos com alta variância tornam-se excessivamente sensíveis às particularidades do conjunto de treinamento. Técnicas como validação cruzada, regularização e controle da complexidade do modelo são estratégias amplamente utilizadas para mitigar esses problemas (**??**).

4.1.7 Seleção de Atributos e Redução de Dimensionalidade

Em problemas com elevado número de variáveis explicativas, a presença de atributos redundantes ou irrelevantes pode impactar negativamente o desempenho dos modelos preditivos. A seleção de atributos busca identificar subconjuntos de variáveis que contribuam de forma significativa para a tarefa de aprendizagem (**??**).

Os métodos de seleção podem ser classificados em três categorias principais: filtros, que utilizam medidas estatísticas independentes do modelo; wrappers, que avaliam subconjuntos de atributos com base no desempenho de um algoritmo específico; e métodos embutidos, nos quais a seleção ocorre durante o próprio processo de treinamento (**??**).

Além da seleção direta de atributos, técnicas de redução de dimensionalidade, como a Análise de Componentes Principais (PCA), realizam uma transformação linear das variáveis originais em um novo conjunto de componentes ortogonais que preservam a maior parte da variância dos dados. Essa abordagem pode reduzir complexidade computacional e mitigar problemas de multicolinearidade. Cabe ressaltar que a PCA não consiste em um método de seleção de atributos, mas sim em uma técnica de extração de atributos, pois cria novas variáveis a partir de combinações lineares das variáveis originais (**??**).

As técnicas apresentadas nesta seção constituem a base teórica para os modelos preditivos empregados neste trabalho, sendo posteriormente integradas a métodos de otimização para apoio à tomada de decisão no contexto esportivo.

4.2 Pesquisa Operacional

Como tratado anteriormente, a área da PO consiste em um campo multidisciplinar que aplica modelos matemáticos, estatísticos e computacionais. PO vem sendo amplamente utilizada em diversas áreas organizacionais, tais como manufatura, transportes, construção civil, telecomunicações, planejamento financeiro, planos de saúde, serviço público, entre outros (**??**).

Conforme discutido na seção anterior, problemas esportivos como montagem de elenco e planejamento competitivo podem ser formalizados como problemas de otimização matemática sob restrições estruturais e orçamentárias. Dependendo da natureza do problema, tais formulações assumem a forma de modelos de Programação Linear, Programação Inteira e abordagens heurísticas para problemas de natureza combinatória, entre outros.

Nos tópicos seguintes, são detalhados os principais métodos de otimização utilizados na modelagem de problemas combinatórios, com destaque para abordagens heurísticas que fundamentam a metodologia proposta neste trabalho.

4.2.1 Programação Linear (PL)

A Programação Linear (PL) é considerada um dos mais importantes avanços científicos do meio do século 20. Essa ferramenta já foi responsável por economizar milhões de dólares para companhias e negócios ao redor do mundo (**??**).

PL utiliza funções lineares simples para buscar o resultado ótimo (**??**). Um exemplo clássico de PL apresentado por Hillier (2001) é o problema da empresa *Wyndor Glass Co.*.

4.2.1.1 *Wyndor Glass Co.*

A empresa *Wyndor Glass Co.* fabrica produtos de vidro de alta qualidade, incluindo janelas e portas de vidro. Possui três fábricas: a Fábrica 1, que produz molduras de alumínio e ferragens; a Fábrica 2, que fabrica molduras de madeira; e a Fábrica 3, responsável pela produção do vidro e pela montagem dos produtos. Devido a uma reestruturação, a empresa decidiu lançar dois novos produtos: o Produto 1, uma porta de vidro de 8 pés com moldura de alumínio, e o Produto 2, uma janela dupla de madeira de 4x6 pés. Cada produto exige capacidade produtiva específica das fábricas. O Produto 1 utiliza as Fábricas 1 e 3, enquanto o Produto 2 depende das Fábricas 2 e 3. O objetivo do problema é determinar a combinação ideal de produção desses produtos para maximizar o lucro total.

Definem-se as seguintes variáveis de decisão:

- x_1: número de lotes do Produto 1 a serem produzidos por semana.
- x_2: número de lotes do Produto 2 a serem produzidos por semana.

As restrições de capacidade produtiva devem ser respeitadas conforme os limites de produção de cada fábrica:

- **Fábrica 1**: Pode produzir no máximo 4 unidades do Produto 1 por semana:

$$x_1 \leq 4 \tag{4.1}$$

- **Fábrica 2**: Pode produzir no máximo 6 unidades do Produto 2 por semana:

$$x_2 \leq 6 \tag{4.2}$$

- **Fábrica 3**: Possui um limite semanal de 18 horas de produção:

$$3x_1 + 2x_2 \leq 18 \tag{4.3}$$

Os dados apresentados encontram-se ilustrados na Figura **??**

Figura 4.2 – Dados da Wyndor Glass Co.

Fábrica	**Tempo de Produção por lote (horas)**		**Tempo de produção disponível por semana (horas)**
	Produto		
	1	**2**	
1	1	0	4
2	0	2	12
3	3	2	18
Lucro por lote	€ 3.000,00	€ 5.000,00	

Fonte: Hillier, 2001 (Adaptado)

O objetivo é determinar a combinação de produção que maximize o lucro total. A equação que representa essa otimização é:

$$\max Z = 3.000x_1 + 5.000x_2 \tag{4.4}$$

onde cada lote do Produto 1 gera um lucro de \$ 3.000 e cada lote do Produto 2 gera um lucro de \$ 5.000. Além disso, deve-se garantir que os valores das variáveis de decisão sejam não negativos:

$$x_1 \geq 0, \quad x_2 \geq 0 \tag{4.5}$$

Uma maneira intuitiva de resolver esse problema é por meio da representação gráfica. As restrições são desenhadas no plano cartesiano, delimitando uma região viável. O ponto ótimo é encontrado na interseção das restrições ativas, onde a função objetivo atinge seu valor máximo dentro da região factível. Tal solução pode ser vista na Figura **??**.

Após essa análise, a solução ótima encontrada é:

Figura 4.3 – Valores de (x_1, x_2) que maximizam $3x_1 + 5x_2$.

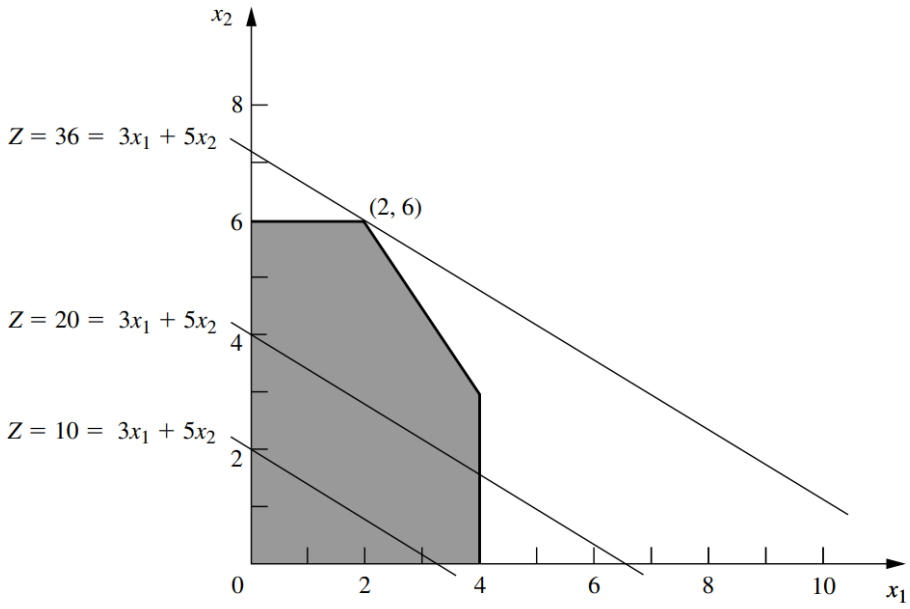

Fonte: Hillier, 2001

$$x_1 = 2, \quad x_2 = 6 \tag{4.6}$$

O lucro máximo alcançado pela empresa ao adotar essa estratégia de produção será:

$$Z^* = 3.000(2) + 5.000(6) = 36.000 \tag{4.7}$$

Portanto, a Wyndor Glass Co. deve produzir 2 lotes do Produto 1 e 6 lotes do Produto 2 por semana para maximizar seus lucros.

Embora a PL seja uma ferramenta poderosa para problemas de otimização linear, existem outras abordagens que lidam com problemas mais complexos. A Programação Dinâmica (PD), por exemplo, trata de decisões sequenciais, enquanto os Processos de Markov são amplamente utilizados para modelagem de processos estocásticos. Essas abordagens serão discutidas a seguir.

4.2.2 Algoritmo Guloso

Em problemas de otimização, um algoritmo é dito guloso quando o mesmo faz uma escolha localmente ótima, na esperança de que essa escolha leve a uma solução globalmente ótima (**??**). Diferentemente de abordagens exaustivas, algoritmos gulosos tomam decisões irrevogáveis a cada etapa, baseando-se apenas na informação disponível no momento da escolha. É importante destacar que, conforme ressaltado por (**??**), algoritmos gulosos não garantem, em geral, a obtenção de soluções globalmente ótimas, sendo necessários argumentos específicos de corretude para justificar quando a estratégia gulosa é válida.

Conforme discutido por (**??**), algoritmos gulosos podem ser formulados de maneira iterativa ou recursiva. Na forma recursiva, o método costuma seguir um padrão *top-down*: realiza-se uma escolha gulosa, reduz-se o problema a um subproblema estritamente menor e repete-se o processo até a construção completa de uma solução. A justificativa de corretude, quando possível, normalmente se apoia em dois ingredientes: (i) a *propriedade da escolha gulosa*, isto é, a existência de uma solução ótima que contém a decisão local tomada; e (ii) a *subestrutura ótima*, segundo a qual, após fixar a decisão gulosa, o restante do problema preserva a mesma estrutura do original, de modo que uma solução ótima do subproblema completa uma solução ótima do problema inicial.

Como exemplo didático, (**??**) apresenta o *activity-selection problem*, no qual há um conjunto de atividades $S = \{a_1, \ldots, a_n\}$, cada uma definida por um tempo de início s_i e um tempo de término f_i, e deseja-se selecionar um subconjunto máximo de atividades mutuamente compatíveis, isto é, que não se sobreponham no tempo. Intuitivamente, a escolha gulosa consiste em selecionar, dentre as atividades ainda viáveis, aquela que termina primeiro. A motivação é que, ao finalizar mais cedo, essa atividade tende a liberar o recurso para acomodar o maior número possível de atividades futuras, reduzindo o risco de bloquear intervalos de tempo extensos.

A corretude dessa estratégia pode ser compreendida por meio de um argumento de *troca* (*exchange argument*), descrito em (**??**). Seja a_m a atividade com menor tempo de término dentre as disponíveis no início do problema. Considere uma solução ótima qualquer $A^\star$ e seja a_k a primeira atividade de $A^\star$ a ocorrer (aquela com menor término dentro de $A^\star$). Como $f_m \leq f_k$, substituir a_k por a_m não torna a solução inviável: qualquer atividade compatível com a_k após o término f_k também permanece compatível após f_m, já que a_m termina no máximo no mesmo instante. Logo, existe uma solução ótima que contém a_m, o que estabelece a *propriedade da escolha gulosa*. Em seguida, ao fixar a_m, o problema remanescente consiste em escolher o máximo de atividades que começam após f_m, isto é, um subproblema da mesma natureza. Assim, uma solução ótima para esse subproblema, combinada com a_m, produz uma solução ótima para o problema original, caracterizando a *subestrutura ótima*. Assumindo as atividades previamente ordenadas por tempo de término (isto é, $f_1 \leq f_2 \leq \cdots \leq f_n$), o algoritmo guloso iterativo apresentado por (**??**) é mostrado no Algoritmo **??**.

[H] Vetores $s[1..n]$ e $f[1..n]$ (início e término), com atividades ordenadas por f crescente Conjunto A de atividades compatíveis de cardinalidade máxima $A \leftarrow \{a_1\}$ $k \leftarrow 1$ $m \leftarrow 2$ n $s[m] \geq f[k]$ $A \leftarrow A \cup \{a_m\}$ $k \leftarrow m$ A

No contexto deste trabalho, um algoritmo guloso é utilizado de forma recursiva com o objetivo de gerar uma solução inicial para o problema de otimização da montagem de elencos. Dado um time e um orçamento, a cada iteração, o jogador com menor minutagem do elenco é removido e substituído por candidatos externos. Para cada substituição possível, o modelo de AM é empregado como função objetivo, estimando a pontuação esperada do time resultante. A escolha gulosa consiste, portanto, em selecionar o(s) jogador(es) que cabem no orçamento do time e cuja inclusão maximiza a pontuação prevista, mantendo-se fixas as demais variáveis do elenco. Assim como no exemplo discutido anteriormente, a solução é construída incrementalmente por decisões locais irrevogáveis, produ-

zindo rapidamente uma solução factível que servirá como ponto de partida para os procedimentos de refinamento descritos na próxima seção. Nesse processo, o modelo de AM atua como função objetivo, avaliando o desempenho esperado das diferentes composições de elenco geradas pelo algoritmo de otimização.

4.2.3 Algoritmo de Busca Local

A busca local é uma técnica heurística amplamente utilizada em problemas de otimização combinatória, cujo objetivo é aprimorar uma solução inicial factível por meio da exploração iterativa de sua vizinhança (**??**). Diferentemente de métodos exatos, a busca local não realiza uma exploração global do espaço de soluções, concentrando-se na melhoria incremental da solução corrente a partir de movimentos locais.

Conforme descrito por (**??**), um algoritmo de busca local é composto essencialmente por quatro elementos: uma solução inicial, a definição de uma vizinhança, um critério de aceitação de movimentos e uma condição de parada. A vizinhança determina o conjunto de soluções que podem ser alcançadas a partir da solução atual por meio de pequenas modificações estruturais, enquanto o critério de aceitação estabelece se uma solução vizinha deve ou não substituir a solução corrente. O processo é repetido iterativamente até que nenhuma melhoria adicional seja encontrada ou que um critério de parada seja satisfeito.

Em contraste com algoritmos gulosos, métodos de busca local partem de uma solução inicial e buscam iterativamente soluções vizinhas que melhorem o valor da função objetivo. O processo continua enquanto existirem melhorias locais, terminando quando se atinge um ponto no qual nenhuma modificação local resulta em melhora adicional.

Um exemplo clássico apresentado por (**??**) surge no problema de agrupamento (*k-means clustering*). Dado um conjunto de pontos e um número fixo de centros k, deseja-se encontrar uma configuração de centros que minimize a soma

das distâncias quadráticas entre cada ponto e o centro mais próximo. Como esse problema é NP-difícil, não se conhece um algoritmo polinomial que garanta a obtenção do ótimo global.

Nesse contexto, Lloyd propôs um procedimento iterativo simples que encontra um mínimo local da função objetivo. O método inicia com uma escolha inicial de centros e repete duas etapas: (i) atribuir cada ponto ao centro mais próximo; e (ii) recalcular cada centro como a média dos pontos atribuídos ao respectivo cluster. O processo é repetido até que nenhuma alteração reduza o valor da função objetivo, caracterizando a convergência para um mínimo local.

Esse procedimento ilustra claramente o princípio da busca local: a partir de uma solução inicial, o algoritmo explora soluções vizinhas obtidas por pequenas modificações estruturais, aceitando apenas mudanças que melhoram a função objetivo.

No problema abordado neste trabalho, a busca local é empregada para avaliar diferentes conjuntos de jogadores candidatos a contratação, respeitando uma restrição de orçamento. Cada solução é representada por um conjunto de jogadores de cardinalidade fixa, sendo a vizinhança definida por operações de substituição unitária (*swap neighborhood*). Em cada iteração, os jogadores do conjunto atual com menor minutagem são selecionados como candidatos à remoção e substituídos por jogadores externos ainda não selecionados, produzindo soluções vizinhas que preservam o tamanho do elenco. Cada solução vizinha gerada é avaliada por meio de uma função objetivo, implementada como um modelo de aprendizado de máquina, responsável por estimar a pontuação esperada do time na temporada considerada.

A restrição orçamentária é tratada como condição de factibilidade: soluções que excedem o orçamento estabelecido são descartadas durante o processo de busca. O critério de aceitação adotado é de melhoria estrita, isto é, uma solução vizinha é aceita apenas se apresentar valor superior da função objetivo em relação

à solução corrente. O algoritmo é encerrado quando nenhuma substituição viável resulta em melhoria adicional, caracterizando a convergência para um ótimo local, conforme descrito em (**??**).

5 METODOLOGIA

5.1 Coleta dos Dados

Com o intuito de coletar os dados, foi desenvolvido um algoritmo de *web scraping*, utilizando a biblioteca *Beautiful Soup* da linguagem *Python*. Essa biblioteca é amplamente empregada para extração e manipulação de informações a partir de páginas HTML e XML, permitindo a coleta automatizada e estruturada de grandes volumes de dados provenientes da web (**??**). O algoritmo implementado automatiza o acesso às páginas de estatísticas, realiza a extração das tabelas correspondentes a cada clube e temporada e armazena os dados de forma padronizada para posterior análise.

O site utilizado para a extração foi o FBref, uma ampla base de dados de estatísticas de futebol que disponibiliza dados detalhados de jogadores e equipes de diversas competições ao redor do mundo. O FBref se destaca por fornecer estatísticas avançadas, como gols esperados (xG), ações de pressão, passes progressivos e estatísticas defensivas, tornando-se uma fonte relevante para análises preditivas e modelagem estatística no contexto do futebol.

Com o objetivo de utilizar um volume de dados superior ao empregado por *Baboota & Kaur* (2018) e *Joseph, Fenton & Neil* (2006), bem como reduzir o risco de *overfitting*, foram coletados os dados de todos os jogadores da *Serie A* italiana e da *Premier League* que atuaram ao longo de cinco temporadas (2019-2020, 2020-2021, 2021-2022, 2022-2023 e 2023-2024), além das tabelas de resultados de todos os jogos disputados nesse mesmo período.

A utilização de duas ligas distintas neste estudo possui o papel metodológico deevitar a ocorrência de *data leakage* entre os conjuntos de treinamento, teste e validação dos modelos de aprendizado de máquina. Para isso, os dados de uma liga são utilizados exclusivamente na etapa de treinamento, enquanto os dados da outra liga são reservados para teste e validação. Essa estratégia asse-

gura que o modelo seja avaliado em um contexto completamente distinto daquele empregado no aprendizado, eliminando dependências estruturais entre amostras e proporcionando uma avaliação mais realista de sua capacidade de generalização.

Os dados obtidos foram armazenados no formato CSV, organizados em arquivos distintos para cada clube e temporada. Dessa forma, cada arquivo contém as estatísticas individuais dos jogadores de um determinado time em uma temporada específica, facilitando a organização, o pré-processamento e as etapas subsequentes da análise.

5.2 Pré-processamento dos Dados

5.2.1 Base de Dados dos Jogadores

As tabelas extraídas do site FBref para todos os times e temporadas foram estruturadas de forma idêntica, contendo 47 atributos relacionados à idade, posição, minutos jogados, bem como estatísticas ofensivas (gols, assistências, passes decisivos, entre outras) e defensivas (bloqueios, desarmes, erros graves, entre outras) de cada jogador. Esses dados foram carregados em diferentes *dataframes*, um para cada liga considerada, e posteriormente organizados por jogador, incluindo informações de clube, temporada e respectivos indicadores de desempenho. Ressalta-se que um mesmo atleta pode aparecer em diferentes temporadas e clubes dentro da organização adotada.

Após a etapa de organização, os dados estruturados foram armazenados em um repositório público na plataforma GitHub, com o objetivo de garantir reprodutibilidade, transparência metodológica e facilidade de acesso para futuras análises. O repositório utilizado neste estudo está disponível em <https://github.com/LunusMax/epl-seriea-data>.

Em seguida, os *dataframes* correspondentes a cada liga foram concatenados em um único conjunto, englobando todos os jogadores considerados no estudo, o qual foi utilizado nas etapas subsequentes da análise.

Considerando o elevado número de atributos e a possível correlação entre variáveis, foi aplicada uma técnica de redução de dimensionalidade com o objetivo de mitigar *overfitting* e melhorar a eficiência computacional dos modelos de AM. Para isso, utilizou-se o Principal Component Analysis (PCA), conforme descrito na subseção a seguir.

5.2.1.1 Principal Component Analysis (PCA)

Para determinar o número ideal de componentes principais que a serem utilizados no PCA, foi gerado um *Scree Plot*, conforme ilustrado na Figura **??**.

Figura 5.1 – Escolha do Número Ideal de Componentes do PCA

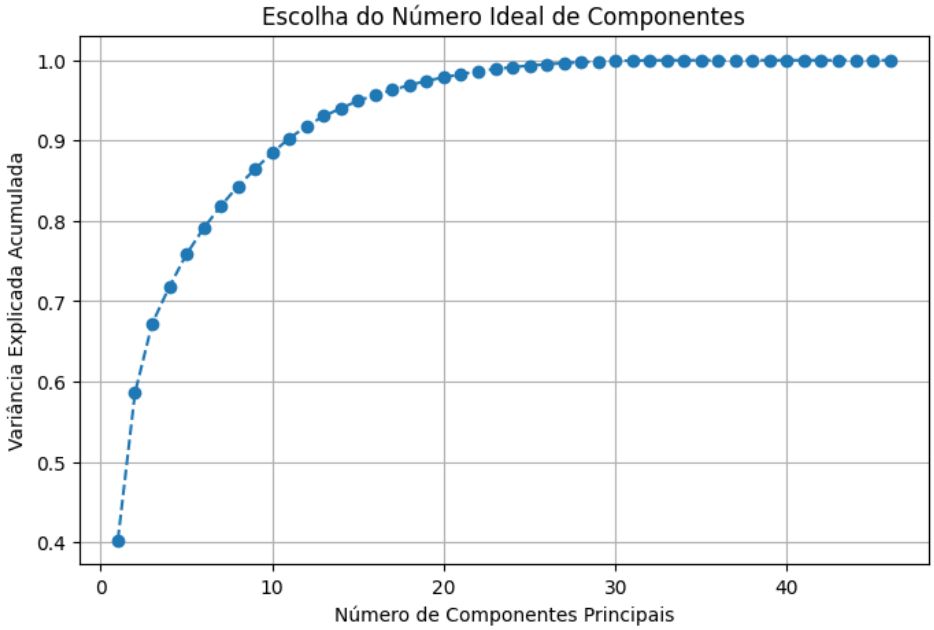

Fonte: do Autor, 2025

O gráfico apresenta a variância explicada acumulada em função do número de componentes principais, permitindo identificar o ponto de inflexão, ou seja, o momento em que a adição de novos componentes passa a contribuir de forma marginal para a variância total dos dados. O eixo x representa o número de componentes principais, enquanto o eixo y exibe a variância explicada acumulada.

A partir da Figura **??**, observa-se que, acima de 20 componentes principais, o ganho de informação adicional se torna insignificante. Com base nessa análise, foram realizados testes com diferentes quantidades de componentes, garantindo que sempre eram utilizados no mínimo 20 componentes, de forma a preservar a maior quantidade possível de variância dos dados sem comprometer a eficiência do modelo.

5.2.2 Base de Dados dos Jogos

Os dados dos jogos realizados entre as temporadas 2019-2020 e 2023-2024, obtidos na etapa de coleta, estavam organizados em 14 colunas. No entanto, grande parte dessas informações era irrelevante para a análise (por exemplo, horário e data das partidas, público, local e árbitro). Assim, para otimizar o conjunto de dados, foram removidos os atributos considerados ruído, mantendo-se apenas três elementos essenciais: time mandante, time visitante e resultado da partida.

A coluna de resultados foi transformada em valores numéricos por meio de um algoritmo em Python, em processo análogo a um *encoder*: vitória do mandante foi codificada como '1', vitória do visitante como '2' e empate como '0'.

Com base nessa codificação, percorreu-se a base atribuindo três pontos a cada vitória e um ponto a cada empate. O resultado desse processamento foi uma tabela organizada por temporada, contendo cada clube e a respectiva pontuação acumulada.

5.3 Treinamento do Modelo de AM

Os dados de pontuação dos clubes foram organizados por temporada, enquanto as estatísticas individuais dos jogadores corresponderam sempre à temporada anterior. Dessa forma, o modelo utiliza informações conhecidas de desempenho prévio para estimar a pontuação final do clube na temporada subsequente. Adicionalmente, a pontuação dos clubes na temporada anterior foi incorporada

como variável explicativa, de modo a capturar o histórico de desempenho recente da equipe.

O modelo de AM foi desenvolvido para prever a pontuação dos clubes ao longo das temporadas, com base no desempenho individual de seus jogadores. Para evitar vazamento de dados entre treinamento e teste, a base da Série A italiana foi utilizada no treinamento do modelo, enquanto a base da EPL foi destinada à etapa de teste.

5.3.1 Modelo de Aprendizado de Máquina

Para a etapa de previsão da pontuação dos clubes, foi implementado o modelo de MLP utilizando a biblioteca *Keras*. O modelo foi construído no formato *Sequential*, contendo três camadas densamente conectadas. A primeira camada recebe como entrada um vetor com dimensão igual ao número de atributos disponíveis, seguido por uma camada densa com 128 neurônios e função de ativação ReLU. Esta camada foi regularizada por meio de penalização L1, de forma a reduzir o risco de sobreajuste.

Em seguida, aplicou-se normalização em lote (*Batch Normalization*) e uma camada de *Dropout* com taxa de 60%, visando maior robustez e generalização. A segunda camada oculta é composta por 32 neurônios, também com ativação ReLU e regularização L1, seguida novamente por *Batch Normalization* e *Dropout* de 60%. Por fim, a camada de saída é formada por um único neurônio linear, responsável por produzir a previsão da pontuação final do clube na temporada.

A arquitetura do modelo pode ser resumida da seguinte forma:

- Camada de entrada: vetor de dimensão n (atributos do jogador e do clube).
- Primeira camada oculta: `Dense(128)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.

- Segunda camada oculta: `Dense(32)`, ativação ReLU, regularização L1.
- `Batch Normalization`.
- `Dropout(0.6)`.
- Camada de saída: `Dense(1)`, ativação linear.

O MLP foi escolhido como base para o modelo de previsão de pontuação no contexto do futebol por reunir propriedades teóricas e práticas que o tornam adequado para lidar com a natureza complexa e não linear dos dados esportivos. Entre as principais razões para essa escolha, destacam-se:

1. **Capacidade de representação universal** — Um MLP com pelo menos uma camada oculta e funções de ativação não lineares é capaz de aproximar qualquer função mensurável (**??**). No contexto do futebol, isso significa que o modelo pode aprender padrões não lineares entre variáveis de desempenho (como gols, desarmes, progressão). Assim, o MLP não depende de hipóteses rígidas sobre a forma das relações entre variáveis, sendo capaz de aprendê-las diretamente dos dados.

2. **Flexibilidade para entradas de alta dimensão** — De acordo com *Goodfellow et. al., 2016*, cada camada de uma rede *feedforward* aprende uma representação do vetor de entrada que torna mais fácil a predição da saída desejada. Essa característica confere ao MLP flexibilidade para lidar com conjuntos de dados de alta dimensionalidade, nos quais múltiplas variáveis interagem de forma não linear. Mesmo com a aplicação prévia da técnica de *Principal Component Analysis* (PCA), que reduz a dimensionalidade de 48 para 20 componentes principais, o problema ainda envolve um espaço vetorial de considerável complexidade. Nesse contexto, o MLP é capaz de explorar as relações não lineares entre os componentes principais,

aprendendo representações mais informativas que auxiliam na previsão de desempenho esportivo.

3. **Treinamento eficiente via retropropagação** — O algoritmo de *backpropagation*, apresentado em (**??**), permite o cálculo eficiente dos gradientes de erro e a atualização simultânea dos pesos da rede por meio de gradiente descendente. Isso viabiliza o treinamento em grandes bases de dados de futebol, reduz o tempo de convergência e possibilita otimizar métricas contínuas.

Além dessas vantagens teóricas, o MLP oferece um equilíbrio entre capacidade de generalização, interpretabilidade e eficiência computacional, características desejáveis em modelos aplicados ao futebol, onde os dados são heterogêneos, ruidosos e interdependentes.

5.4 Otimização

Uma vez identificado o modelo de ML com melhor capacidade de predizer a pontuação final dos times em uma liga a partir das informações estatísticas de seus elencos, inicia-se a segunda etapa do projeto, dedicada à busca de soluções capazes de otimizar esse desempenho. Nessa fase, o problema passa a ser tratado como um processo de otimização sob restrições, no qual diferentes composições de elenco são avaliadas de acordo com sua pontuação estimada pelo modelo de aprendizado de máquina.

5.4.1 Cálculo do Valor de Mercado Sintético

Para viabilizar o processo de otimização, torna-se necessário incorporar restrições financeiras que reflitam, ainda que de forma simplificada, as limitações orçamentárias enfrentadas por clubes de futebol em contextos reais. Nesse sentido,

foi definida uma métrica sintética de valor de mercado dos jogadores, construída a partir de dois fatores principais: idade e desempenho estatístico agregado.

A Equação **??** apresenta formalmente o cálculo adotado para essa métrica.

$$V_i = 1000 \cdot \left(1000 \cdot \max(0, 30 - I_i) + 10 \cdot \sum_{j=1}^{n} x_{ij} \right) \tag{5.1}$$

onde:

- V_i representa o valor de mercado sintético do jogador i;
- I_i corresponde à idade do jogador i;
- x_{ij} representa o valor da j-ésima estatística numérica associada ao jogador i;
- n é o número total de variáveis estatísticas consideradas.

O primeiro termo da equação corresponde a um fator etário, que atribui maior peso a jogadores mais jovens, considerando um limite superior de 30 anos. Jogadores com idade superior a esse limiar não recebem penalização adicional, evitando a atribuição de valores negativos. Essa escolha busca refletir uma característica recorrente do mercado do futebol, no qual atletas mais jovens tendem a apresentar maior potencial de valorização, longevidade esportiva e retorno econômico futuro.

O segundo termo da equação agrega o desempenho estatístico do jogador por meio da soma de suas variáveis numéricas, escalonada por um fator constante. Essa agregação tem como objetivo capturar, de forma simplificada, o impacto global do desempenho esportivo individual, sem privilegiar métricas específicas ou posições em campo.

Por fim, o fator multiplicativo externo é aplicado exclusivamente para reescalonamento da variável, de modo a produzir valores em uma ordem de grandeza mais próxima às estimativas observadas no mercado real. Esse reescalonamento

facilita tanto a interpretação dos valores obtidos quanto a utilização da métrica como restrição orçamentária nos modelos de otimização empregados na etapa subsequente.

Dessa forma, jogadores que combinam alto desempenho estatístico com menor idade tendem a apresentar valores de mercado sintético mais elevados, enquanto atletas mais velhos ou com desempenho inferior são associados a custos reduzidos, em consonância com evidências empíricas da literatura que apontam idade e desempenho como fatores centrais na formação do valor econômico de jogadores profissionais. (**????**) Ressalta-se que essa métrica não tem como objetivo reproduzir valores reais de mercado, mas sim fornecer uma função custo coerente e monotônica, adequada ao processo de otimização proposto.

5.4.2 Busca Local para Otimização do Elenco

O problema de montagem de elenco abordado neste trabalho pode ser caracterizado como um problema de otimização combinatória sob restrições, no qual se busca selecionar um subconjunto de jogadores que maximize a função objetivo — neste caso, a pontuação do time ao final do campeonato —, respeitando limitações orçamentárias e estruturais, conforme formalizado por (**??**).

6 RESULTADOS E DISCUSSÕES

6.1 Modelos de Aprendizado de Máquinas

O melhor modelo de AM desenvolvido neste estudo apresentou acurácia máxima de aproximadamente 60% na tarefa de prever a pontuação final de um time em sua liga nacional, utilizando como base os dados estatísticos de desempenho individual de seus jogadores na temporada anterior.

Para avaliar o desempenho dos diferentes algoritmos aplicados à tarefa de previsão, foram calculadas métricas amplamente utilizadas em problemas de regressão, incluindo o coeficiente de determinação (R^2), o erro absoluto médio (MAE), o erro quadrático médio (MSE), a raiz do erro quadrático médio (RMSE), o erro percentual absoluto médio (MAPE) e o tempo de processamento de cada modelo. A Tabela **??** apresenta um resumo comparativo dos resultados obtidos, permitindo analisar tanto a qualidade preditiva quanto o custo computacional de cada abordagem.

Tabela 6.1 – Comparação de desempenho entre os modelos de Machine Learning avaliados

Modelo	**R^2**	**MAE**	**MSE**	**RMSE**	**MAPE**	**Tempo (s)**
RL	0.41	11.48	191.78	13.85	0.2580	2.15
RF	0.28	12.05	234.05	15.30	0.2690	423.13
XGBoost	0.41	11.48	191.78	13.85	0.2580	2.86
MLP	0.48	11.08	170.42	13.05	0.2424	161.68

Fonte: Elaborado pelo autor.

Os resultados apresentados na Tabela **??** evidenciam um comportamento consistente entre os algoritmos avaliados, com desempenho moderado na tarefa de previsão da pontuação final dos times. Embora a acurácia máxima tenha alcançado aproximadamente 60%, observa-se que todos os modelos enfrentam limitações inerentes à natureza imprevisível, ruidosa e não linear do problema. A pontuação de um time ao longo de uma temporada é influenciada também por fato-

res não refletidos nas estatísticas individuais de jogadores, como variações táticas, mudanças de treinador, lesões, contexto competitivo e dinâmica coletiva, o que naturalmente reduz o teto preditivo esperável.

Entre as abordagens testadas, a Rede Neural Multicamadas (MLP) apresentou o melhor equilíbrio entre qualidade preditiva e estabilidade, alcançando o maior valor de R^2 (0,48) e os menores erros MAE, MSE, RMSE e MAPE. Esse resultado sugere que a arquitetura densa foi mais capaz de capturar as relações não lineares presentes nos componentes principais gerados pelo PCA, aproveitando estruturas de dependência que modelos lineares ou baseados em árvores não exploram de maneira tão eficaz.

O desempenho mais modesto dos modelos de *Random Forest* (RF) e *XGBoost* indica que, apesar de serem métodos robustos e amplamente utilizados em tarefas de AM, quando reduzidos por PCA, funcionaram de forma mais limitada. Além disso, o custo computacional do RF foi significativamente superior, tornando-o menos atrativo para cenários de larga escala ou simulações repetidas de montagem de elenco.

O modelo de Regressão Linear (RL) apresentou desempenho comparável ao *XGBoost*, demonstrando que uma parte da variabilidade explicável está capturada em relações aproximadamente lineares entre os componentes principais do PCA e a pontuação final dos times. No entanto, o ganho obtido pela MLP reforça que há padrões não lineares relevantes que justificam a adoção de modelos mais complexos.

6.1.1 Predição do Modelo MLP

Com o intuito de compreender a predição realizada pelo melhor modelo (MLP) foi realizada uma análise visual da relação entre as pontuações reais dos clubes da Premier League na temporada e as pontuações previstas pelo modelo.

A Figura **??** apresenta o gráfico de comparação entre as pontuações reais e previstas pelo modelo MLP.

Figura 6.1 – Relação entre pontuações reais e previstas pelo modelo MLP na Premier League.

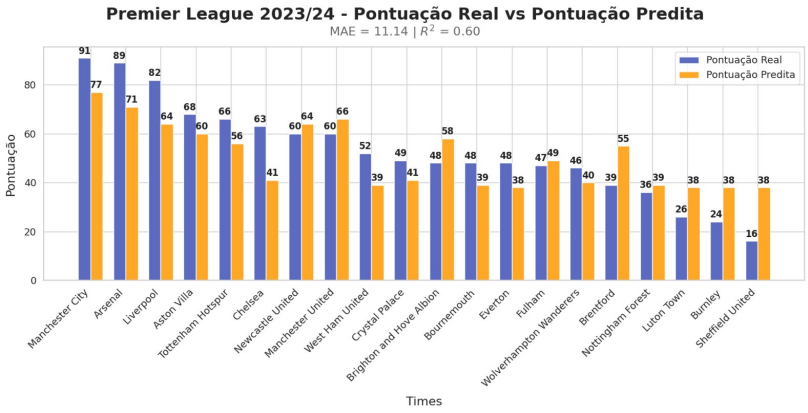

Os resultados apresentados na Figura **??** indicam que o modelo MLP apresenta maior precisão ao estimar as pontuações de clubes que terminaram a temporada com valores próximos da média da liga. Times posicionados no centro da distribuição como Fulham, Manchester United e Newcastle United tendem a ter suas pontuações previstas com menor erro, comportamento comum em modelos preditivos sob alta incerteza: quando os atributos disponíveis não capturam toda a variabilidade do fenômeno, as previsões convergem naturalmente para valores intermediários. Esse resultado alinha-se com a literatura clássica, segundo a qual modelos preditivos em ambientes de alta variabilidade, como é o caso do futebol, tendem a gerar funções de saída menos extremas e com menor amplitude, aproximando-se de valores centrais, devido a mecanismos de *shrinkage* e ao balanço entre viéses e variância discutidos por Bishop (**??**). Esse comportamento é análogo ao fenômeno estatístico conhecido como regressão à média.

Dessa forma, observa-se que o modelo MLP é capaz de capturar tendências gerais de desempenho dos clubes com base nas estatísticas individuais de seus jogadores, porém nota-se uma subestimação sistemática das equipes de desempe-

nho elevado, como Manchester City, Arsenal e Liverpool, e uma superestimação das equipes de baixo desempenho, como Sheffield United, Burnley e Luton Town.

6.2 Otimização de Montagem de Elenco

7 CONCLUSÃO

Teste